



UNIVERSIDADE ESTADUAL DE CAMPINAS (UNICAMP)
FACULDADE DE CIÊNCIAS APLICADAS (FCA)
PROGRAMA DE PÓS-GRADUAÇÃO EM ENGENHARIA DE PRODUÇÃO E DE
MANUFATURA

VITOR JARDIM

**ANÁLISE ENVOLTÓRIA DE DADOS COMO INSTRUMENTO DE APOIO À
AVALIAÇÃO DOS OBJETIVOS DE DESENVOLVIMENTO SUSTENTÁVEL**

Limeira

2026

VITOR JARDIM

**ANÁLISE ENVOLTÓRIA DE DADOS COMO INSTRUMENTO DE APOIO À
AVALIAÇÃO DOS OBJETIVOS DE DESENVOLVIMENTO SUSTENTÁVEL**

Dissertação apresentada à Faculdade de Ciências Aplicadas (FCA) da Universidade Estadual de Campinas (UNICAMP) como parte dos requisitos exigidos para a obtenção do título de Mestre em Engenharia de Produção e de Manufatura, na área de concentração Pesquisa Operacional e Gestão de Processos.

Dissertation presented to the School of Applied Sciences of the University of Campinas (UNICAMP) as part of the requirements for the degree of Master in Production and Manufacturing Engineering, in the area of Operations Research and Process Management.

Orientadora: Profa. Dra. Priscila Cristina Berbert Rampazzo

Coorientadora: Profa. Dra. Flávia Barbosa

ESTE TRABALHO CORRESPONDE À VERSÃO FINAL DA DISSERTAÇÃO DEFENDIDA.

Ficha catalográfica
Universidade Estadual de Campinas (UNICAMP)
Biblioteca da Faculdade de Ciências Aplicadas
Renata Eleuterio da Silva - CRB 8/9281

J284a Jardim, Vitor, 1996-
Análise envoltória de dados como instrumento de apoio à avaliação dos
Objetivos de Desenvolvimento Sustentável / Vitor Jardim. – Limeira, SP :
[s.n.], 2026.

Orientador: Priscila Cristina Berbert Rampazzo.
Coorientador: Flávia Barbosa.
Dissertação (mestrado) – Universidade Estadual de Campinas
(UNICAMP), Faculdade de Ciências Aplicadas.

1. Pesquisa operacional. 2. Análise envoltória de dados. 3. Políticas
públicas. 4. Desenvolvimento sustentável. I. Rampazzo, Priscila Cristina
Berbert, 1984-. II. Barbosa, Flávia, 1989-. III. Universidade Estadual de
Campinas (UNICAMP). Faculdade de Ciências Aplicadas. IV. Título.

Informações complementares

Título em outro idioma: Data envelopment analysis as a tool to support the evaluation
of the Sustainable Development Goals

Palavras-chave em inglês:

Operations research

Data envelopment analysis

Public policies

Sustainable development

Área de concentração: Pesquisa Operacional e Gestão de Processos

Titulação: Mestre em Engenharia de Produção e de Manufatura

Banca examinadora:

Priscila Cristina Berbert Rampazzo [Orientador]

Glaucia Jardim Pissinelli

Ellen Marianne Bernal Cavaleiro

Damaris Chierigato Vicentin

Paulo Henrique Ribeiro Gabriel

Data de defesa: 28-08-2026

Programa de Pós-Graduação: Engenharia de Produção e de Manufatura

Objetivos de Desenvolvimento Sustentável (ODS)

ODS: 4. Educação de qualidade

ODS: 8. Trabalho decente e crescimento econômico

Identificação e informações acadêmicas do(a) aluno(a)

- ORCID do autor: <https://orcid.org/0009-0005-3887-586X>

- Currículo Lattes do autor: <http://lattes.cnpq.br/3624225803159808>

FOLHA DE APROVAÇÃO

VITOR JARDIM

Dissertação apresentada ao Programa de Pós-Graduação em Engenharia de Produção e de Manufatura, defendida na data de **28/08/2026**.

Composição da Comissão Examinadora:

Profa. Dra. Glaucia Jardim Pissinelli

Centro Universitário da Fundação Hermínio Ometto (FHO)

Profa. Dra. Ellen Marianne Bernal Cavaleiro

Universidade Federal de Mato Grosso do Sul (UFMS)

Profa. Dra. Damaris Chieregato Vicentin

Faculdade de Ciências Aplicadas – Universidade Estadual de Campinas (FCA-UNICAMP)

Prof. Dr. Paulo Henrique Ribeiro Gabriel

Universidade Federal de Uberlândia (UFU)

DEDICATÓRIA

Deus.

AGRADECIMENTOS

Primeiramente agradeço a Deus, pois tudo que acontece em minha vida, eu peço para que seja mediante a vontade Dele. Logo, acredito que se uma única coisa fosse diferente, talvez eu não estivesse aqui hoje e é isso que sustenta os agradecimentos posteriores.

O presente trabalho foi realizado com apoio da Coordenação de Aperfeiçoamento de Pessoal de Nível Superior – Brasil (CAPES) – Código de Financiamento 001 (Processo nº 88887.993138/ 2024-00).

Agradeço aos meus avós maternos (Pedro e Zéca), à minha avó paterna (Lóla), aos meus avós de consideração (Celso e Vó Nega) e aos meus pais (Ernesto e Magda), pois mesmo com os meus inúmeros defeitos, eles sempre estiveram e estarão presentes em minha vida, mesmo em meus piores dias, sendo meu norte não apenas para quem sou, mas, sobretudo, para quem preciso ser como pessoa.

Agradeço à Tia Márcia Lentz, que não foi a primeira professora que tive na vida, mas foi a primeira que me marcou, sempre com um sorriso contagiante, mesmo em meio às tempestades da vida, o que muitos perderam, ela manteve. Uma das pessoas mais humanas que já conheci na vida.

Agradeço à minha orientadora de iniciação científica Andréa R. Scalco que me introduziu ao mundo das pesquisas acadêmicas, sempre com muita paciência e empatia, me ajudando, mesmo quando não merecia, mesmo quando falhei.

Agradeço ao professor Luís Roberto Almeida Gabriel Filho por me apresentar à Pesquisa Operacional e por me ensinar algo que levo pra vida "Precisamos provar do fel, para darmos valor ao mel".

Agradeço ao professor Marcos dos Santos pelo meu reencontro com a PO, anos depois, e por ter me mostrado o quanto essa área é ampla. Foi ele quem me apresentou o método de Apoio à Tomada de Decisão Multicritério (MCDA) e me convidou para ingressar em outro MBA, onde tive meu primeiro contato com a Análise Envoltória de Dados (DEA).

Agradeço à amiga Quezia Maia, que conheci em uma igreja local e que foi responsável por me apresentar este programa. Desde então, esteve presente como uma grande amiga. Não poderia ter pedido a Deus uma amiga melhor.

Agradeço à professora Flávia Barbosa não só por ter aceitado me coorientar, mas principalmente por ser sempre paciente, objetiva, dedicada e me corrigir quando necessário, além de toda ajuda com o conteúdo e pela disposição inabalável, mesmo com quatro horas de diferença no fuso horário.

Finalmente, agradeço a minha orientadora Priscila Rampazzo, pelos ensinamentos e seu coração enorme, humilde, bondoso e gentil, mesmo em meio às tempestades da vida. Não só aceitou me orientar, apesar dos meus defeitos, mas principalmente por ter acreditado em mim, mesmo quando não fui capaz. Outra das pessoas mais humanas que conheci.

EPÍGRAFES

“A educação é a arma mais poderosa que você pode usar para mudar o mundo.”

Nelson Mandela

“Uma jornada de mil milhas começa com um único passo.”

Lao-Tsé

“Estou sempre (...) tentando mudar a direção do trem.”

Raul Seixas — Carpinteiro do Universo

“Todas as coisas cooperam para o bem daqueles que amam a Deus.”

Romanos 8:28

“Consagre ao Senhor tudo o que você faz, e os seus planos serão bem-sucedidos.”

Provérbios 16:3

Durante uma forte tempestade, Jesus perguntou aos seus discípulos:

“Por que vocês estão com tanto medo, homens de pequena fé?”

Mateus 8:24–26 (NVI-PT)

“When life leaves us blind, love keeps us kind.”

Linkin Park — The Messenger

“Cada vez mais, as pessoas se tornam algo em detrimento da própria humanidade.”

Vitor Jardim

“I will stand my ground and I won’t back down.”

Johnny Cash — I Won’t Back Down

“I’m only a crack in this castle of glass.”

Linkin Park — Castle of Glass

“Todos os modelos estão errados, mas alguns são úteis.”

George E. P. Box

“O teste final de uma teoria é sua capacidade de resolver os problemas que lhe deram origem.”

George B. Dantzig

“É melhor se arrepender do que se fez do que não ter tido a coragem de fazer.”

Ultraje a Rigor — Agora é Tarde

“Valeu a pena? Tudo vale a pena

Se a alma não é pequena.”

Fernando Pessoa — Mar Português

RESUMO

Os indicadores compostos podem apoiar o monitoramento dos Objetivos de Desenvolvimento Sustentável, mas comparações territoriais podem ser inadequadas quando regiões submetidas a condições socioeconômicas distintas são avaliadas sob uma mesma referência. Esta pesquisa propõe uma estratégia sensível ao contexto para avaliar o desempenho multidimensional relativo de regiões europeias de acordo com a Nomenclatura das Unidades Territoriais para Fins Estatísticos (NUTS-I) nos Objetivos de Desenvolvimento Sustentável 4 e 8 (ODS 4 e ODS 8), no período de 2014 a 2019. Inicialmente, 86 regiões foram agrupadas a partir das variáveis contextuais desemprego e cidadania por meio do método *k-means*. A solução com três *clusters* foi selecionada com apoio do método do cotovelo, e sua estabilidade foi examinada em diferentes janelas temporais. Em seguida, após os ajustes de direção e positividade dos indicadores, o método *Benefit-of-the-Doubt* (BoD) foi estimado separadamente para cada *cluster* e ano. A aplicação do ODS 4 utilizou 86 regiões e cinco indicadores educacionais, enquanto a aplicação do ODS 8 utilizou 59 dessas regiões, distribuídas segundo a mesma classificação contextual, e quatro indicadores relacionados a trabalho decente e crescimento econômico. No ODS 4, os escores médios intragrupo foram de 91,43%, 90,66% e 95,83% nos *Clusters* 1, 2 e 3, respectivamente. No ODS 8, considerando a especificação principal de ε correspondente a 1% do menor valor positivo de cada variável submetida à translação, as médias foram de 89,73%, 88,10% e 88,60%. A análise de sensibilidade examinou valores de ε entre 0,1% e 10% e encontrou amplitudes de 0,0507, 0,0356 e 0,0156 pontos percentuais nas médias dos três grupos. Os escores não constituem um *ranking* global entre *clusters* ou entre os dois ODS, pois cada aplicação utiliza indicadores, amostras e fronteiras de referência próprios. A análise conjunta identificou ES3 como a única referência persistente comum aos dois objetivos, enquanto outras regiões mantiveram ou alteraram suas posições relativas entre as aplicações. Os resultados indicam que a clusterização contextual pode apoiar comparações entre regiões com perfis semelhantes quanto às variáveis utilizadas, mas o desempenho observado permanece condicionado ao domínio avaliado, aos indicadores empregados e à composição do conjunto de referência.

Palavras-chave: Pesquisa Operacional, Análise Envoltória de Dados, *Benefit-of-the-Doubt*, Desempenho Multidimensional, Políticas Públicas

ABSTRACT

Composite indicators can support the monitoring of the Sustainable Development Goals, but territorial comparisons may be inappropriate when regions facing different socioeconomic conditions are assessed against a common reference. This study proposes a context-sensitive strategy to assess the relative multidimensional performance of European from Nomenclature of Territorial Units for Statistics (NUTS-I) regions under Sustainable Development Goals 4 and 8 (SDG 4 and SDG 8) from 2014 to 2019. First, 86 regions were grouped according to the contextual variables unemployment and citizenship using the *k-means* method. A three-cluster solution was selected with support from the elbow method, and its stability was examined across different time windows. After directional and positivity adjustments of the indicators, the *Benefit-of-the-Doubt* (BoD) model was estimated separately for each cluster and year. The SDG 4 application included 86 regions and five educational indicators, whereas the SDG 8 application included 59 of those regions, preserving the same contextual classification, and four indicators related to decent work and economic growth. For SDG 4, the within-group mean scores were 91.43%, 90.66%, and 95.83% for Clusters 1, 2, and 3, respectively. For SDG 8, under the main specification in which ϵ corresponded to 1% of the smallest positive value of each translated variable, the mean scores were 89.73%, 88.10%, and 88.60%. The sensitivity analysis examined ϵ values ranging from 0.1% to 10% and found amplitudes of 0.0507, 0.0356, and 0.0156 percentage points in the mean scores of the three groups. The scores do not constitute a global ranking across clusters or between the two SDGs because each application uses its own indicators, sample, and reference frontiers. The joint analysis identified ES3 as the only persistent benchmark common to both goals, whereas other regions maintained or changed their relative positions across the applications. The results indicate that contextual clustering can support comparisons among regions with similar profiles in the contextual variables used, but the observed relative performance remains conditioned by the domain assessed, the indicators employed, and the composition of the reference set.

Keywords: Operations Research, Data Envelopment Analysis, *Benefit-of-the-Doubt*, Multidimensional Performance, Public Policies

LISTA DE ILUSTRAÇÕES

1.1	Eficiências.	24
1.2	Fronteira de Eficiência.	25
1.3	Esquemas de Aglomeração.	72
1.4	Dendrograma.	74
1.5	Clusterização: <i>k-means</i>	75
1.6	Método do Cotovelo.	76
1.7	Clusters RBS.	81
1.8	Overton: Políticas Governamentais em DEA	84
1.9	Overton: Aplicações de DEA nas políticas governamentais	85
1.10	Overton: distribuição dos ODS por continente	86
3.1	Método do cotovelo: aplicação para valores de k entre 1 e 10	105
3.2	Clusters gerados ($k = 3$)	106
3.3	Janelas temporais utilizadas na avaliação da estabilidade dos clusters ($k = 3$) . .	109
3.4	Médias anuais dos escores BoD por <i>cluster</i> (2014–2019)	113
3.5	Distribuição da média dos escores anuais do ODS 4 por <i>cluster</i> (2014–2019) . .	118
3.6	Médias anuais dos escores BoD do ODS 8 por <i>cluster</i> (2014–2019)	121
3.7	Distribuição da média dos escores do ODS 8 por <i>cluster</i> (2014–2019)	125

¹**Declaração de Uso de Assistência por Inteligência Artificial.** Foram utilizadas as ferramentas ChatGPT, da OpenAI, e Gemini e NotebookLM, do Google, para apoio à revisão ortográfica, gramatical e de coesão textual; à reformulação de trechos; à organização da argumentação; à leitura, síntese e compreensão de artigos; à revisão crítica da consistência textual; e à edição de códigos em Python, LaTeX e BibTeX. As ferramentas não foram utilizadas como fontes autônomas de dados, evidências ou resultados empíricos, nem substituíram a análise, a tomada de decisão e a responsabilidade autoral. Todas as sugestões e respostas fornecidas foram avaliadas, verificadas e editadas manualmente pelo autor, que assume integral responsabilidade pelo conteúdo final apresentado. Período de utilização: fevereiro a julho de 2026.

LISTA DE TABELAS

1.1	Notação utilizada nos modelos CCR	28
1.2	Correspondências básicas entre os modelos dos multiplicadores e dos envelopes	35
1.3	Regras para construção do modelo dual	35
1.4	Notação utilizada nos modelos BCC	42
1.5	Indicadores Compostos: Aplicações recentes com <i>BoD</i>	51
1.6	Tipos de restrições aos pesos no modelo DEA	53
1.7	Expressões das medidas de distância	71
1.8	Métodos de Encadeamento.	73
1.9	RBS: Modelos DEA e Sustentabilidade	78
1.10	Clusters Temáticos e Contextos	82
1.11	Classificação de variáveis: inputs e outputs	83
2.1	Descrição das Variáveis Contextuais	91
2.2	Estatísticas descritivas para a variável Z1 (2014-2019)	92
2.3	Estatísticas descritivas para a variável Z2 (2014-2019)	92
2.4	Indicadores de Educação e Competências Digitais	93
2.5	Estatísticas descritivas para a variável Y1 (2014-2019)	94
2.6	Estatísticas descritivas para a variável Y2 (2014-2019)	94
2.7	Estatísticas descritivas para a variável Y3 (2014-2019)	95
2.8	Estatísticas descritivas para a variável Y4 (2014-2019)	95
2.9	Estatísticas descritivas para a variável Y5 (2014-2019)	96
2.10	Indicadores de Trabalho Decente e Crescimento Econômico	98
2.11	Estatísticas descritivas para a variável Y1 do ODS 8 (2014-2019)	99
2.12	Estatísticas descritivas para a variável Y2 do ODS 8 (2014-2019)	99
2.13	Estatísticas descritivas para a variável Y3 do ODS 8 (2014-2019)	100
2.14	Estatísticas descritivas para a variável Y4 do ODS 8 (2014-2019)	100
3.1	Perfil médio das variáveis contextuais por cluster	106
3.2	Distribuição das regiões por país	108
3.3	Estabilidade dos clusters em diferentes janelas temporais	110
3.4	Adequação do número de DMUs ao critério de Banker et al. (1989)	111
3.5	Cluster 1: escores BoD anuais (%)	113
3.6	Cluster 2: escores BoD anuais (%)	115
3.7	Cluster 3: escores BoD anuais (%)	117
3.8	Distribuição das DMUs por faixa de escore médio	119
3.9	Cluster 1: escores BoD anuais do ODS 8 (%)	121

3.10	Cluster 2: escores BoD anuais do ODS 8 (%)	123
3.11	Cluster 3: escores BoD anuais do ODS 8 (%)	124
3.12	Distribuição das DMUs do ODS 8 por faixa de escore médio	126
3.13	Médias gerais dos escores do ODS 8 sob diferentes valores de ϵ	127
3.14	Referências persistentes nos ODS 4 e 8 por <i>cluster</i>	128

SUMÁRIO

INTRODUÇÃO	16
Objetivos	19
Objetivo geral	19
Objetivos específicos	19
1 FUNDAMENTAÇÃO TEÓRICA	21
1.1 Análise Envoltória de Dados (DEA)	21
1.1.1 Eficiência	21
1.1.1.1 Breve Histórico	21
1.1.1.2 Conceito	23
1.1.2 Modelos DEA	27
1.1.2.1 CCR	27
I. Modelo dos Multiplicadores - Orientação ao Input	28
II. Modelo dos Multiplicadores - Orientação ao Output	31
III. Modelo do Envelope - Orientação ao Input	34
IV. Modelo do Envelope - Orientação ao Output	38
1.1.2.2 BCC	41
I. Modelo dos Multiplicadores - Orientação ao Input	42
II. Modelo dos Multiplicadores - Orientação ao Output	45
III. Modelo do Envelope - Orientação ao Input	48
IV. Modelo do Envelope - Orientação ao Output	49
V. Eficiência de Escala (EE)	50
1.1.2.3 BoD - Benefit-of-the-Doubt	51
1.1.3 Estruturas Temporais	53
1.1.3.1 Fronteiras Temporais	54
I. Contemporânea	54
II. Sequencial	55
III. Intertemporal	55
IV. Análise em Janelas	55
1.1.4 Variáveis	56
1.1.4.1 Tipos de Variáveis	56
I. Discricionárias e Não Discricionárias	56
II. Contextuais	56
III. Flexíveis	57
IV. Intermediárias	57

	V. Categóricas	57
	VI. <i>Proxy</i>	58
	VII. Razões, Taxas e Índices	58
	VIII. Indesejáveis	59
1.1.5	Preparação dos Dados	59
1.1.5.1	Consistência dos Dados	59
1.1.5.2	<i>Outliers</i>	60
I.	Detecção Preliminar	60
II.	Tratamento dos <i>Outliers</i>	60
1.1.5.3	Zeros	61
I.	Constante Pequena (ϵ)	61
1.1.5.4	Valores Negativos	63
I.	Translação por Adição de Constante	63
1.1.5.5	Dados Ausentes	64
I.	Exclusão	64
II.	Preenchimento	65
1.1.6	Tratamento das Variáveis	66
1.1.6.1	<i>Outputs</i> indesejáveis	66
I.	Subtração	66
II.	Complemento	67
III.	Inversão	67
IV.	Reclassificação como <i>input</i>	68
1.1.6.2	Transformação das Variáveis	68
I.	Reescala multiplicativa	69
II.	Normalização pelo valor máximo	69
III.	Normalização pela média	70
IV.	Escore z	70
1.2	Clusterização	71
1.2.1	Clusters Hierárquicos	72
1.2.2	Clusters Não-Hierárquicos	74
1.2.3	Método do Cotovelo (Elbow)	76
1.3	Mapeamento de Trabalhos Relacionados	77
1.3.1	Perspectiva Acadêmica: Artigos Científicos	77
1.3.1.1	Revisão Bibliográfica Sistemática (RBS)	77
1.3.2	Perspectiva Governamental: Documentos Políticos	84
2	METODOLOGIA	88
2.1	Abordagem Geral	88
2.2	Metodologia baseada em Indicadores Compostos	88

2.3	Seleção de DMUs	90
2.4	Variáveis Seleccionadas	91
2.4.1	Variáveis Contextuais	91
2.4.2	Variáveis de Estudo - ODS 4	93
2.4.3	Variáveis de Estudo - ODS 8	96
2.5	Procedimento de Clusterização	101
2.6	Modelagem Matemática	103
3	RESULTADOS	105
3.1	Clusters	105
3.1.1	Estabilidade dos Clusters em Diferentes Janelas Temporais	109
3.1.1.1	Número mínimo de DMUs	110
3.2	<i>Benefit-of-the-Doubt</i> : Desempenho dos Indicadores Compostos	112
3.2.1	ODS 4. Educação de Qualidade	112
3.2.2	ODS 8. Trabalho Decente e Crescimento Económico	120
3.2.2.1	Sensibilidade à Escolha de ϵ	126
3.2.3	Análise conjunta dos ODS 4 e 8 por <i>cluster</i>	127
4	CONCLUSÃO	130
	REFERÊNCIAS	133
	APÊNDICES	
A	Outras nomenclaturas e simbologias	154

INTRODUÇÃO

Durante o século XX a humanidade vivenciou um período de crescente industrialização, urbanização e consumo, aumentando a sua capacidade de transformar recursos naturais em bens e serviços, em detrimento dos aspectos ambientais, que ficaram mais visíveis. Tendo em vista a degradação dos ecossistemas, a poluição e a exploração desses recursos, ficou claro que o desenvolvimento econômico não poderia ser entendido apenas pelo aumento da produção e da renda. Gradualmente, a discussão sobre desenvolvimento passou a incorporar os limites ambientais e as consequências sociais dos modelos de crescimento, preparando o caminho para o surgimento do conceito de desenvolvimento sustentável (Mebratu, 1998; Du Pisani, 2006).

Essa nova perspectiva ganhou força entre as décadas de 1960 e 1970, com o aumento da produção científica e do debate público sobre os impactos das atividades humanas no meio ambiente. Nesse contexto, a obra de Meadows *et al.* (1972) contribuiu para apresentar as relações entre crescimento populacional, industrialização, produção de alimentos, poluição e consumo de recursos naturais. Mesmo com as interpretações divergentes oriundas dos diferentes cenários abordados em seu trabalho, o estudo teve importância para a consolidação do entendimento de que a expansão material não poderia ocorrer indefinidamente em um planeta com recursos e capacidades ambientais limitados (Du Pisani, 2006).

A Conferência das Nações Unidas sobre o Meio Ambiente Humano, realizada em Estocolmo em 1972, marcou a maneira como a comunidade internacional começou a tratar a questão ambiental. O evento consolidou a percepção de que a poluição, o uso dos recursos naturais e a deterioração ambiental não eram problemas apenas locais, mas desafios que exigiam cooperação internacional. A Conferência também trouxe à tona as tensões entre proteção ambiental e desenvolvimento econômico, pois países com diferentes níveis de industrialização apresentavam responsabilidades, prioridades e capacidades distintas para enfrentar as questões ambientais (Joos, 2023; Sanwal, 2012).

Ao longo das décadas que se seguiram, a temática ambiental foi se integrando às conversas sobre pobreza, desigualdade e desenvolvimento. Esse conceito foi consolidado pelo desenvolvimento sustentável, difundido internacionalmente por meio do Relatório Brundtland, publicado em 1987. Nesse momento, a sustentabilidade deixou de ser vista apenas como a preservação do meio ambiente e passou a englobar a busca por um equilíbrio entre a proteção ambiental, o desenvolvimento econômico, o bem-estar social e a justiça entre gerações. Apesar da diversidade de interpretações, o conceito passou a ser uma referência para políticas públicas, organismos internacionais e pesquisas acadêmicas (Mebratu, 1998; Hopwood *et al.*, 2005).

A Conferência das Nações Unidas sobre Meio Ambiente e Desenvolvimento, realizada no Rio de Janeiro em 1992, fortaleceu essa conexão entre meio ambiente e desenvolvimento. Desde então, a sustentabilidade se tornou um aspecto central na governança inter-

nacional, englobando temas como produção e consumo, mudanças climáticas, biodiversidade, pobreza e cooperação entre países. Entretanto, uma maior abrangência do conceito também gerou novos desafios relacionados a sua operacionalização, porque conciliar crescimento econômico, justiça social e proteção ambiental passou a depender de decisões políticas, institucionais e metodológicas que nem sempre estão alinhadas (Hopwood *et al.*, 2005; Sanwal, 2012).

No início do século XXI, os Objetivos de Desenvolvimento do Milênio consolidaram o uso de metas e indicadores na governança internacional. Os ODM estavam focados na pobreza, na saúde, na educação, na igualdade de gênero e em outras necessidades sociais. Embora tenham impulsionado a mobilização global sobre esses assuntos, seu foco permaneceu concentrado nos países em desenvolvimento. As discussões sobre suas limitações levaram à busca por uma agenda mais universal e integrada, capaz de contemplar desenvolvimento humano e sustentabilidade ambiental (Sachs, 2012; Fukuda-Parr, 2016).

A busca por esse objetivo ganhou mais clareza durante a Conferência das Nações Unidas sobre Desenvolvimento Sustentável, chamada Rio+20, que ocorreu em 2012. O evento reafirmou os compromissos globais de desenvolvimento sustentável e definiu o processo político que levaria à criação dos Objetivos de Desenvolvimento Sustentável. Ao contrário da agenda anterior, a nova proposta visava integrar questões como pobreza, desigualdade, consumo de recursos, mudanças climáticas e degradação ambiental. A literatura da época defendia que a estabilidade dos sistemas naturais deveria ser parte das metas internacionais de erradicação da pobreza e promoção do bem-estar humano, porque o desenvolvimento social e econômico depende das condições ambientais que tornam possível a vida e a produção (Griggs *et al.*, 2013; Sanwal, 2012; Fukuda-Parr, 2016).

Esse processo culminou, em 2015, na adoção da Agenda 2030 e seus 17 Objetivos de Desenvolvimento Sustentável são: ODS 1 – Erradicação da Pobreza; ODS 2 – Fome Zero e Agricultura Sustentável; ODS 3 – Saúde e Bem-Estar; ODS 4 – Educação de Qualidade; ODS 5 – Igualdade de Gênero; ODS 6 – Água Potável e Saneamento; ODS 7 – Energia Limpa e Acessível; ODS 8 – Trabalho Decente e Crescimento Econômico; ODS 9 – Indústria, Inovação e Infraestrutura; ODS 10 – Redução das Desigualdades; ODS 11 – Cidades e Comunidades Sustentáveis; ODS 12 – Consumo e Produção Responsáveis; ODS 13 – Ação Contra a Mudança Global do Clima; ODS 14 – Vida na Água; ODS 15 – Vida Terrestre; ODS 16 – Paz, Justiça e Instituições Eficazes; e ODS 17 – Parcerias e Meios de Implementação.

Os ODS ampliavam o âmbito dos ODM e estabeleceram uma agenda global, válida para países e territórios de diferentes graus de desenvolvimento. A sua estrutura contempla as dimensões ambiental, econômica, social e institucional, tratando de temas que vão da pobreza à saúde, da educação à água, passando por energia, emprego, infraestrutura, desigualdade, urbanização, consumo, clima, biodiversidade, paz e cooperação. A Agenda 2030 é, portanto, uma forma de governança orientada por objetivos, com metas globais que servem como referências para políticas nacionais e locais, mesmo que a implementação dessas metas dependa das capacidades institucionais e das prioridades de cada contexto (Biermann *et al.*, 2017; Fukuda-Parr,

2016).

Uma outra característica essencial da Agenda 2030 é o entendimento de que os ODS são interligados e se influenciam mutuamente. Políticas que se concentram em um objetivo específico podem ter consequências tanto benéficas quanto prejudiciais para outras áreas. Crescimento econômico, por exemplo, pode reduzir a pobreza e criar empregos, mas pode aumentar o consumo de recursos e as pressões sobre o meio ambiente. De maneira semelhante, melhorias na educação, saúde, energia limpa e infraestrutura podem impactar a produtividade, a inclusão social e a adaptação ao meio ambiente. Por conseguinte, a análise dos ODS deve levar em conta não apenas os resultados isolados, mas também as interações, sinergias e tensões entre suas várias dimensões (Le Blanc, 2015; Pradhan *et al.*, 2017).

Nesse sentido, medir o desempenho passa a ser fundamental para monitorar as metas, comparar resultados e detectar disparidades entre países e regiões. No entanto, a variedade de indicadores e contextos torna difícil elaborar diagnósticos que sejam integrados e comparáveis. Os diferentes indicadores, assim como suas seleções, normalizações, ponderações e agregações, podem ser decididos de maneira diferente entre as unidades territoriais, que podem, por sua vez, ter diferenças em sua estrutura econômica, mercado de trabalho, composição populacional, disponibilidade de recursos e capacidade institucional. A maneira como avaliamos e classificamos pode ser fortemente impactada por essas decisões metodológicas (Greco *et al.*, 2019).

Portanto, este trabalho emprega a Análise Envoltória de Dados como ferramenta auxiliar na avaliação de dois objetivos da Agenda 2030: o ODS 4, associado à Educação de Qualidade, e o ODS 8, relacionado a Trabalho Decente e Crescimento Econômico. A educação permanece como um eixo relevante porque constitui um objetivo em si e se relaciona com saúde, emprego, redução das desigualdades, inovação e construção de sociedades mais sustentáveis (Boeren, 2019). A inclusão do ODS 8 amplia a aplicação para um domínio econômico e laboral, permitindo examinar se regiões inseridas em contextos socioeconômicos semelhantes mantêm posições relativas semelhantes entre duas aplicações que diferem quanto ao domínio avaliado, aos indicadores empregados e à composição dos conjuntos de referência.

Assim, o foco da pesquisa consiste em avaliar o desempenho multidimensional relativo por meio de uma estratégia que combina clusterização contextual e indicadores compostos. A clusterização é utilizada para formar grupos de regiões semelhantes segundo as condições contextuais observadas, enquanto o método *Benefit-of-the-Doubt* (BoD) é aplicado separadamente em cada grupo e ano. Essa estrutura busca reduzir comparações diretas entre regiões com perfis contextuais distintos e, ao mesmo tempo, preservar a natureza multidimensional dos ODS analisados.

No que se refere aos indicadores compostos, o estudo adota uma metodologia fundamentada no modelo BoD utilizado por Durães *et al.* (2026), uma aplicação específica da DEA que permite agregar indicadores sem impor um conjunto único de pesos fixos a todas as unidades. Os pesos são determinados de forma endógena para cada Unidade Tomadora de Decisão

(Decision Making Unit – DMU), sujeitos a restrições mínimas de contribuição que impedem que uma dimensão incluída no modelo seja desconsiderada na composição do escore. Os resultados são, portanto, interpretados como medidas de desempenho relativo às fronteiras formadas em cada *cluster* e ano, e não como medidas de cumprimento absoluto das metas dos ODS.

OBJETIVOS

Objetivo geral

Avaliar o desempenho multidimensional relativo de unidades tomadoras de decisão por meio da combinação entre clusterização contextual e o método *Benefit-of-the-Doubt*, no contexto da Agenda 2030.

Objetivos específicos

1. Caracterizar as regiões europeias NUTS-I com base nas variáveis contextuais de desemprego e cidadania.
2. Agrupar as regiões europeias NUTS-I em conjuntos com características socioeconômicas semelhantes por meio do método *k-means*.
3. Estimar indicadores compostos anuais associados aos ODS 4 e 8 por meio do método *Benefit-of-the-Doubt*, separadamente para cada agrupamento.
4. Analisar a distribuição intragrupo dos escores BoD dos ODS 4 e 8 no período de 2014 a 2019.

Estrutura da Dissertação

Esta dissertação está organizada em quatro capítulos. No Capítulo 1 são apresentados os principais conceitos que sustentam o desenvolvimento do trabalho, incluindo eficiência, Análise Envoltória de Dados (DEA), os modelos CCR, BCC e *Benefit-of-the-Doubt* (BoD), estruturas temporais, variáveis, preparação e tratamento dos dados e métodos de clusterização. O capítulo também apresenta uma Revisão Bibliográfica Sistemática (RBS) sobre aplicações de DEA relacionadas à sustentabilidade e discute documentos políticos e outros trabalhos associados à DEA, aos Objetivos de Desenvolvimento Sustentável e às políticas públicas.

O Capítulo 2 descreve os procedimentos metodológicos adotados na pesquisa, incluindo a origem e o tratamento dos dados, a seleção das regiões e das variáveis, a formação e a análise de estabilidade dos agrupamentos contextuais e a formulação do modelo *Benefit-of-the-Doubt* utilizado na construção dos indicadores compostos associados aos ODS 4 e 8.

No Capítulo 3 são apresentados e analisados os resultados da clusterização e da aplicação do método *Benefit-of-the-Doubt*. Inicialmente, são descritos os perfis contextuais dos agrupamentos e sua estabilidade em diferentes janelas temporais. Em seguida, são examinados separadamente os escores BoD dos ODS 4 e 8. Ao final, realiza-se uma análise conjunta das posições relativas observadas nas duas aplicações.

Por fim, o Capítulo 4 sintetiza os principais resultados da dissertação, destacando a contribuição metodológica do estudo. Além disso, são discutidas as limitações da pesquisa e apresentadas sugestões para trabalhos futuros.

CAPÍTULO 1

FUNDAMENTAÇÃO TEÓRICA

Este capítulo apresenta a fundamentação teórica que sustenta o desenvolvimento desta dissertação. Inicialmente, são discutidos os conceitos de eficiência e os fundamentos da Análise Envoltória de Dados (DEA), incluindo os modelos clássicos e o *Benefit-of-the-Doubt* (BoD). Em seguida, são abordadas estruturas temporais, tipos de variáveis, preparação e tratamento dos dados e métodos de clusterização. Por fim, são apresentados o mapeamento de trabalhos acadêmicos relacionados à DEA e à sustentabilidade e documentos políticos associados aos Objetivos de Desenvolvimento Sustentável e às políticas públicas.

1.1 Análise Envoltória de Dados (DEA)

A partir da base teórica desenvolvida por Farrell (1957), a Análise Envoltória de Dados (DEA) surgiu com o trabalho de Charnes *et al.* (1978), tendo como objetivo o estudo de processos produtivos que utilizam múltiplos recursos (*inputs*) e geram mais de um produto (*outputs*).

A metodologia DEA foi concebida para avaliar a eficiência das DMUs, em contextos nos quais não é pertinente, ou não se deseja, considerar apenas o aspecto financeiro. A DEA possibilita uma análise comparativa entre essas unidades, com o objetivo de identificar aquelas que detêm as melhores relações entre os recursos utilizados e os resultados obtidos.

1.1.1 Eficiência

1.1.1.1 Breve Histórico

Ao longo da história, a eficiência está relacionada às mudanças tecnológicas, econômicas e organizacionais que ocorreram desde a consolidação dos sistemas industriais de produção. A ideia de eficiência estava inicialmente associada ao desempenho das máquinas e produção de resultados, sendo gradualmente incorporada à organização do trabalho e à gestão das organizações, orientando a busca por um uso racional dos recursos produtivos (Borges & Bordin, 2023; Matos & Pires, 2006).

À medida que a Revolução Industrial avançava e o sistema fabril se espalhava, as empresas passaram a se preocupar cada vez mais com a coordenação entre trabalhadores, máquinas, materiais e etapas da produção. A maior escala de produção impôs à atividade um planejamento, uma supervisão e um controle mais sistemáticos, possibilitando o surgimento das

primeiras teorias administrativas, todas elas voltadas para a racionalização do trabalho (Borges & Bordin, 2023; Matos & Pires, 2006).

Nesse contexto, a Administração Científica, desenvolvida por Frederick W. Taylor no início do século XX, representou um marco na inclusão da eficiência ao pensamento administrativo. Taylor propôs que a organização do trabalho fosse fundamentada na observação e na análise sistemática das tarefas, ao invés dos métodos empíricos utilizados nas fábricas. Entre os elementos associados a essa abordagem estavam a divisão das tarefas, o estudo dos tempos e movimentos, a padronização dos métodos e a separação entre o planejamento e a execução do trabalho (Taylor, 1911; Matos & Pires, 2006).

A abordagem taylorista refletia um período caracterizado pela industrialização acelerada e pela busca de maior produtividade. A eficiência era associada à organização racional das atividades, à redução do tempo gasto nas tarefas e à padronização de procedimentos para aumentar produção. Ao mesmo tempo, esse modelo fortaleceu uma visão mecanicista da organização, marcada pela divisão das atividades e pela pouca participação dos trabalhadores nas decisões relacionadas ao processo produtivo (Matos & Pires, 2006).

O surgimento da produção em massa expandiu essa lógica organizacional. A Ford Motor Company foi, nas primeiras décadas do século XX, a principal responsável pela difusão de sistemas produtivos pautados na padronização, no uso de peças intercambiáveis, na especialização das tarefas e na organização das operações em sequência, em linhas de montagem. Esse modelo impulsionou tanto o aumento da produção quanto a diminuição dos custos por unidade, reforçando uma ideia de eficiência ligada à escala e à constância do fluxo de produção (Hounshell, 1984).

A consolidação do Sistema Toyota de Produção, que mais tarde se espalhou pelo mundo como produção enxuta, trouxe uma nova perspectiva de gestão na segunda metade do século XX. Ao contrário dos sistemas inflexíveis de produção em massa, a produção enxuta destacou a eliminação do desperdício, a melhoria contínua, a qualidade e a integração dos diversos processos organizacionais. Dessa maneira, a eficiência da administração não foi mais entendida apenas em termos de rapidez ou quantidade produzida, mas passou a incluir também o desempenho conjunto de todo o sistema produtivo (Womack *et al.*, 2007).

Essa evolução mostra que a Administração se concentrou, em grande parte, em criar princípios que ajudam a organizar o trabalho, a coordenar os processos e a otimizar o uso dos recursos. No entanto, tais visões tinham um caráter, em grande parte, gerencial e normativo, pois procuravam determinar as maneiras tidas como mais apropriadas para a organização das atividades, sem, necessariamente, estabelecer um procedimento geral para avaliar e comparar o desempenho de distintas unidades produtivas (Borges & Bordin, 2023; Matos & Pires, 2006).

Ao lado da vertente administrativa, nasceu uma perspectiva econômica e quantitativa da eficiência. Enquanto as teorias de administração focavam na estruturação dos processos de trabalho, a análise econômica começou a explorar de que maneira o desempenho produtivo poderia ser quantificado e comparado de forma empírica. Essa transformação possibilitou que

a eficiência não fosse apenas um conceito de gestão, mas também uma medida quantitativa de avaliação (Borges & Bordin, 2023; Farrell, 1957).

Um dos marcos dessa linha de pesquisa foi o estudo de Farrell (1957), no qual foi proposta uma estrutura para medir a eficiência produtiva e para comparar o desempenho de diferentes unidades analisadas. Sua contribuição lançou as bases do desenvolvimento posterior dos métodos de avaliação que se fundamentam em fronteiras de eficiência, cuja definição e representação aparecem na próxima subseção (Farrell, 1957).

Posteriormente, Charnes *et al.* (1978) desenvolveram o primeiro modelo formal de Análise Envoltória de Dados (*Data Envelopment Analysis* – DEA), que passou a ser conhecido como modelo CCR. Este trabalho pôs em prática e estendeu os fundamentos quantitativos da avaliação de eficiência, ajudando a aplicar esses conceitos em variados tipos de organizações e atividades (Charnes *et al.*, 1978).

A trajetória histórica da eficiência revela, portanto, duas vertentes complementares. A vertente administrativa contribuiu para a racionalização do trabalho, a padronização das operações, a organização dos processos e a redução de desperdícios. A vertente econômica e quantitativa, por sua vez, converteu a eficiência em uma comparação de desempenho, estabelecendo as bases dos métodos de mensuração que viriam a se desenvolver. Essa evolução possibilita entender como se deu a transição de uma visão majoritariamente mecânica e organizacional para uma perspectiva econômica e matemática da eficiência (Borges & Bordin, 2023; Matos & Pires, 2006; Farrell, 1957; Charnes *et al.*, 1978).

1.1.1.2 Conceito

A eficiência é um conceito relativo. Em linhas gerais, a eficiência pode ser definida como a relação entre os resultados (*outputs*) obtidos e os recursos (*inputs*) utilizados em uma ação qualquer. Assim, o aumento da eficiência pode ocorrer tanto pela maximização dos resultados obtidos quanto pela minimização do uso dos recursos disponíveis, reconhecendo que inputs e outputs estão intrinsecamente relacionados, conforme expresso na Equação 1.1 (Bilos-lavo *et al.*, 2013; Grateron, 1999).


$$\text{Eficiência} = \frac{\text{Resultado (output)}}{\text{Recurso (input)}} \quad (1.1)$$

A Equação 1.1 expressa a lógica geral de relacionar resultados e recursos, mas essa razão, isoladamente, não possui necessariamente limite superior igual a uma unidade: seu valor depende das grandezas e das unidades de medida utilizadas. A interpretação de eficiência igual a 1 ou 100% surge quando a medida é normalizada em relação a um referencial, como ocorre posteriormente nas formulações DEA. Em governos e sistemas públicos, a aplicação dessa lógica também envolve maior complexidade, pois esses contextos incluem diferentes perspectivas, restrições institucionais e dimensões de desempenho que vão além de critérios puramente

econômicos (Borges & Bordin, 2023).

Farrell (1957) trouxe um progresso na avaliação da eficiência ao apresentar a distinção entre dois componentes que se complementam: a eficiência técnica e a eficiência de preço (ou alocativa). A eficiência técnica é a habilidade de uma unidade produtiva de gerar o maior nível possível de *output* com os insumos que possui. A eficiência de preços, por sua vez, relaciona-se ao uso de recursos nas proporções ideais, levando em conta seus preços, de forma a reduzir o custo para um nível de produção específico. Essas duas noções de eficiência são ilustradas graficamente na Figura 1.1, que representa uma tecnologia de produção com dois *inputs*, dispostos nos eixos *X* e *Y*, destinados à obtenção de um único *output*.

Figura 1.1: Eficiências.



Fonte: Farrell (1957).


Em termos gráficos, a eficiência técnica é representada pela razão OQ/OP . O ponto *P* é a unidade que está sendo avaliada e o ponto *Q* é o *benchmark* técnico da unidade, ou seja, a sua referência de eficiência. Esse ponto é encontrado onde o raio *OP* cruza o isoquante *SS'*, que representa as combinações de insumos tecnicamente eficientes capazes de produzir o mesmo nível de *output*. Dessa forma, mesmo que *P* e *Q* resultem no mesmo produto, *Q* emprega uma quantidade menor de insumos em relação a *P*, o que evidencia a ineficiência técnica do ponto *P*.

A razão OR/OQ é o que mensura a eficiência de preços (ou a eficiência alocativa). Seu *benchmark* é o ponto *Q'*, que também faz parte do isoquante *SS'*, mas é caracterizado como a combinação de insumos que resulta no menor custo de produção, levando em conta o vetor de preços relativos. Esse ponto é onde o isoquante toca a reta de isocusto *AA'*. Apesar de o ponto *Q* ser eficiente em termos de produção, isso não significa que ele seja a combinação de custos mais baixos, resultando em uma eficiência de preços que é inferior à de *Q'*. A distância entre *Q* e *R* demonstra a ineficiência alocativa decorrente da escolha subótima dos insumos.

Por fim, temos a eficiência econômica (ou eficiência global), que decorre da combinação das eficiências técnica e de preços, podendo ser expressa pela razão OR/OP . Essa de-

composição, que foi proposta por Farrell (1957), oferece uma maneira prática e aplicável para avaliar o desempenho produtivo, trocando um referencial puramente teórico por uma fronteira baseada nas melhores práticas observadas. Nesse contexto, empresas eficientes são aquelas que utilizam a relação insumo-produto de forma mais adequada, posicionando-se sobre o isoquanto eficiente SS' , conforme ilustrado na Figura 1.2.

Figura 1.2: Fronteira de Eficiência.



Fonte: Farrell (1957).

No estudo de Farrell (1957) também são discutidas as limitações das tentativas anteriores de mensuração da eficiência, especialmente aquelas baseadas apenas em indicadores de produtividade ou na redução do vetor de insumos a um único escalar. A proposta de Farrell possibilitou a análise simultânea de múltiplos *inputs*, apoiada em premissas como convexidade, retornos constantes de escala e eficiência relativa. Nesse sentido, a eficiência é avaliada em relação à melhor prática observada, e não a um referencial ideal puramente teórico. O autor também destaca que, para que a comparação entre as unidades produtivas seja válida, elas devem ser analisadas sob as mesmas condições, sendo agrupadas por porte e características produtivas para garantir a homogeneidade do estudo. É importante ressaltar também que a falta de um insumo significativo pode prejudicar o desempenho comparativo de uma unidade em relação às outras. Essas premissas foram a base teórica para a criação do primeiro modelo de Análise Envoltória de Dados, chamado DEA-CCR.

Em linhas gerais, os métodos paramétricos partem do princípio de que há uma relação funcional entre *inputs* e *outputs*, especificada com antecedência e normalmente estimada a partir de médias, para avaliar o nível de produção potencial. Diferentemente, metodologias não paramétricas, como a Análise Envoltória de Dados, comparam a eficiência entre unidades sem estabelecer uma estrutura funcional prévia, permitindo uma avaliação mais flexível,

particularmente em cenários onde as unidades produtivas são diversas.

Para introduzir os modelos clássicos de DEA, é necessário compreender a forma matemática da eficiência apresentada na Equação 1.2, reescrita a partir da Equação 1.1.

$$\text{Eficiência} = \frac{\text{Soma ponderada dos resultados}}{\text{Soma ponderada dos recursos}} \quad (1.2)$$

Os modelos de DEA representam essa relação por meio das somas ponderadas dos *outputs* e dos *inputs*:

$$E_o = \frac{u_1 y_{1o} + u_2 y_{2o} + \dots + u_s y_{so}}{v_1 x_{1o} + v_2 x_{2o} + \dots + v_r x_{ro}} \quad (1.3)$$

A Equação 1.3 também pode ser reescrita de modo mais geral, conforme a Equação 1.4.

$$E_o = \frac{\sum_{j=1}^s u_j y_{jo}}{\sum_{i=1}^r v_i x_{io}} \quad (1.4)$$

Sendo que:

- x_{ik} : valor do *input* i pertencente à k -ésima DMU.
- y_{jk} : valor do *output* j pertencente à k -ésima DMU.
- x_{io} : valor do *input* i pertencente à DMU avaliada.
- y_{jo} : valor do *output* j pertencente à DMU avaliada.

Os modelos de DEA começam a partir da Função Objetivo que visa a maximização ou minimização da Equação 1.4.

1.1.2 Modelos DEA

1.1.2.1 CCR

O modelo CCR, apresentado por Charnes *et al.* (1978), constitui a formulação inaugural da Análise Envoltória de Dados. A sigla deriva dos sobrenomes Charnes, Cooper e Rhodes. Esse modelo é conhecido como *Constant Returns to Scale* (CRS), uma vez que assume que estamos lidando com retornos de escala constantes: uma mudança proporcional no input resulta em uma mudança proporcional no output. A orientação para os *inputs* analisa a redução proporcional dos recursos, enquanto a orientação para os *outputs* analisa o aumento proporcional dos resultados. Em ambas as abordagens, cada DMU seleciona os pesos que resultam na avaliação mais favorável, desde que esses pesos sejam consistentes para todas as unidades da amostra (Charnes *et al.*, 1978; Seiford & Thrall, 1990; Cook & Seiford, 2009).

A formulação original é fracionária (Equação 1.5) e expressa a eficiência da DMU *o* como a razão entre a soma ponderada de seus *outputs* e a soma ponderada de seus *inputs*. As restrições impõem que essa razão não ultrapasse uma unidade para nenhuma das DMUs. Como os pesos u_j e v_i são variáveis de decisão presentes no numerador e no denominador, o modelo é não linear. A razão deve ter um dos dois termos normalizados para que possamos realizar a transformação em programação linear (Charnes *et al.*, 1978; Cooper *et al.*, 2007; Thanassoulis, 2001).

$$\begin{aligned}
 \max \quad E_o &= \frac{\sum_{j=1}^s u_j y_{jo}}{\sum_{i=1}^r v_i x_{io}} \\
 \text{s.a.} \quad &\frac{\sum_{j=1}^s u_j y_{jk}}{\sum_{i=1}^r v_i x_{ik}} \leq 1 \quad \forall k = 1, \dots, n \\
 &u_j \geq 0 \quad \forall j = 1, \dots, s \\
 &v_i \geq 0 \quad \forall i = 1, \dots, r
 \end{aligned} \tag{1.5}$$

Considere um conjunto de n DMUs. A unidade avaliada é indicada por o , cada DMU utiliza r *inputs* e produz s *outputs*. A Tabela 1.1 reúne a notação utilizada nas formulações dos multiplicadores e dos envelopes (Cooper *et al.*, 2007; Thanassoulis, 2001).

Tabela 1.1: Notação utilizada nos modelos CCR

Símbolo	Definição
o	Índice da DMU sob avaliação.
k	Índice das DMUs em comparação, com $k = 1, \dots, n$.
i	Índice dos <i>inputs</i> , com $i = 1, \dots, r$.
j	Índice dos <i>outputs</i> , com $j = 1, \dots, s$.
x_{ik}	Quantidade do <i>input</i> i utilizada pela DMU k .
y_{jk}	Quantidade do <i>output</i> j produzida pela DMU k .
v_i	Peso atribuído ao <i>input</i> i .
u_j	Peso atribuído ao <i>output</i> j .
h_k	Intensidade associada à DMU k na construção da referência virtual.
h_o	Fator radial aplicado à DMU avaliada.

Fonte: Elaborado com base em Charnes *et al.* (1978), Thanassoulis (2001) e Cooper *et al.* (2007).

I. Modelo dos Multiplicadores - Orientação ao Input

Na orientação aos *inputs*, a análise concentra-se na possibilidade de reduzir proporcionalmente os recursos utilizados pela DMU avaliada, sem diminuir seus níveis de *outputs*. Na formulação dos multiplicadores, a soma ponderada dos *inputs* da DMU o é normalizada em uma unidade, enquanto a função objetivo maximiza seus *outputs* ponderados. A orientação decorre da dimensão escolhida para a normalização e para o ajuste radial, e não do sentido de maximização da função objetivo. Por isso, sua escolha deve refletir a dimensão sobre a qual existe possibilidade efetiva de atuação gerencial (Charnes *et al.*, 1978; Cooper *et al.*, 2007; Cook *et al.*, 2014).

No modelo fracionário CCR, a eficiência é expressa pela razão entre a soma ponderada dos *outputs* e a soma ponderada dos *inputs*. Uma razão não é alterada quando todos os seus termos são multiplicados por uma mesma constante positiva, e assim, diferentes conjuntos de pesos proporcionais produzem a mesma razão. Para eliminar essa indeterminação de escala e transformar a função objetivo fracionária em uma expressão linear, impõe-se que a soma ponderada dos *inputs* da DMU em avaliação seja igual a uma unidade (Equação 1.6) (Charnes *et al.*, 1978; Cooper *et al.*, 2007; Thanassoulis, 2001):

$$\sum_{i=1}^r v_i x_{io} = 1 \quad (1.6)$$

O valor unitário não representa uma quantidade física de recurso, ele funciona apenas como referência matemática para fixar a escala dos pesos. Ao inserir essa normalização no

denominador da relação de eficiência, temos:

$$E_o = \frac{\sum_{j=1}^s u_j y_{jo}}{\sum_{i=1}^r v_i x_{io}} = \frac{\sum_{j=1}^s u_j y_{jo}}{1} = \sum_{j=1}^s u_j y_{jo} \quad (1.7)$$

Consequentemente, a função objetivo linear consiste em maximizar a soma ponderada dos *outputs* da DMU avaliada:

$$\max \quad E_o = \sum_{j=1}^s u_j y_{jo} \quad (1.8)$$

Depois de linearizar a função objetivo, é preciso remover a razão que aparece nas restrições de eficiência.

Para cada DMU k , parte-se da restrição fracionária utilizada para verificar se o conjunto de pesos escolhido para a DMU o também é válido para todas as unidades da amostra (Charnes *et al.*, 1978; Cooper *et al.*, 2007):

$$\frac{\sum_{j=1}^s u_j y_{jk}}{\sum_{i=1}^r v_i x_{ik}} \leq 1 \quad \forall k = 1, \dots, n \quad (1.9)$$

Como o denominador deve ser positivo no domínio da formulação fracionária, a multiplicação dos dois lados por $\sum_{i=1}^r v_i x_{ik}$ preserva o sentido da desigualdade:

$$\sum_{j=1}^s u_j y_{jk} \leq \sum_{i=1}^r v_i x_{ik} \quad \forall k = 1, \dots, n \quad (1.10)$$

Movendo a soma ponderada dos *inputs* para o lado esquerdo, chega-se à forma linear usada na versão final:

$$\sum_{j=1}^s u_j y_{jk} - \sum_{i=1}^r v_i x_{ik} \leq 0 \quad \forall k = 1, \dots, n \quad (1.11)$$

Essa restrição exige que, para cada DMU, a soma ponderada dos *outputs* não ultrapasse a soma ponderada dos *inputs*. Portanto, a unidade que está sendo avaliada tem a liberdade de escolher os pesos que mais favorecem seu desempenho, desde que esses mesmos pesos não ultrapassem o limite que foi imposto a todas as outras unidades. A eficiência, portanto, é rela-

tiva ao grupo de DMUs que se observa (Charnes *et al.*, 1978; Cooper *et al.*, 2007; Thanassoulis, 2001).

A limitação mencionada anteriormente é válida também para a própria DMU que está sendo analisada. Para $k = o$, a normalização dos *inputs* permite escrever $\sum_{j=1}^s u_j y_{jo} - 1 \leq 0$. Como essa soma é igual à função objetivo, sob as suposições habituais de dados positivos, o valor ótimo atende a:

$$0 < E_o^* = \sum_{j=1}^s u_j^* y_{jo} \leq 1 \quad (1.12)$$

O asterisco indica que E_o^* e os pesos u_j^* são valores obtidos após a resolução do problema. Quando $E_o^* = 1$, a DMU está sobre a fronteira CCR no sentido radial. Quando $0 < E_o^* < 1$, a dualidade forte estabelece que esse mesmo valor corresponde ao fator de contração radial do modelo dos envelopes orientado aos *inputs* (Seiford & Thrall, 1990; Bertsimas & Tsitsiklis, 1997; Cooper *et al.*, 2007).

Por exemplo, se $E_o^* = 0,80$, a DMU pode reduzir proporcionalmente seus *inputs* em $(1 - 0,80) \times 100\% = 20\%$, mantendo pelo menos os níveis observados de *outputs*. Desconsiderando eventuais folgas, o nível radial de cada recurso é dado por:

$$x_{io}^{\text{rad}} = E_o^* x_{io} = 0,80 x_{io} \quad \forall i = 1, \dots, r \quad (1.13)$$

Quando existem folgas de *input*, a projeção completa incorpora também as reduções não proporcionais identificadas pelo modelo:

$$x_{io}^{\text{proj}} = E_o^* x_{io} - s_i^{-*} \quad \forall i = 1, \dots, r \quad (1.14)$$

Assim, a redução radial representa o ajuste proporcional comum a todos os recursos, enquanto s_i^{-*} representa uma redução adicional específica do *input* i . Uma DMU é considerada fortemente eficiente quando o fator radial é igual a um e todas as folgas ótimas são nulas. Quando se pretende modelar ajustes não proporcionais entre os recursos de maneira direta, é possível usar modelos não radiais. A Equação 1.15 corresponde ao modelo final dos multiplicadores, voltado para os *inputs* (Färe *et al.*, 1994; Thanassoulis, 2001; Cooper *et al.*, 2007).

$$\begin{aligned}
\max \quad & \sum_{j=1}^s u_j y_{jo} \\
\text{s.t.} \quad & \sum_{i=1}^r v_i x_{io} = 1 \\
& \sum_{j=1}^s u_j y_{jk} - \sum_{i=1}^r v_i x_{ik} \leq 0 \quad \forall k = 1, \dots, n \\
& u_j \geq 0 \quad \forall j = 1, \dots, s \\
& v_i \geq 0 \quad \forall i = 1, \dots, r
\end{aligned} \tag{1.15}$$

II. Modelo dos Multiplicadores - Orientação ao Output

No modelo CCR dos multiplicadores orientado aos *outputs*, a escala dos pesos é fixada pela soma ponderada dos resultados da DMU avaliada. A formulação linear resultante minimiza a soma ponderada de seus inputs. Pelo modelo dos envelopes dual, o valor ótimo dessa função pode ser interpretado como o fator máximo de expansão radial dos *outputs*, mantendo-se constantes os níveis observados de recursos (Charnes *et al.*, 1978; Cooper *et al.*, 2007; Thanassoulis, 2001; Färe *et al.*, 1994).

No modelo fracionário CCR, a multiplicação simultânea de todos os pesos por uma mesma constante positiva não altera a razão entre *outputs* e *inputs* ponderados. Consequentemente, diferentes conjuntos proporcionais de pesos produzem o mesmo resultado, tornando necessário estabelecer uma escala única. Na orientação aos *outputs*, essa indeterminação é eliminada ao se impor que a soma ponderada dos resultados da DMU avaliada seja igual a uma unidade (Charnes *et al.*, 1978; Cooper *et al.*, 2007; Thanassoulis, 2001):

$$\sum_{j=1}^s u_j y_{jo} = 1 \tag{1.16}$$

O valor 1 constitui apenas uma referência matemática para fixar a escala dos pesos e não representa uma unidade física de produção nem significa que a DMU possua eficiência de 100%. Com essa normalização, a razão fracionária da DMU *o* passa a ser o inverso da soma ponderada de seus *inputs*. Denominando essa soma por E_o , maximizar a razão $1/E_o$ equivale a minimizar E_o , pois o denominador deve ser positivo no domínio da formulação fracionária (Charnes *et al.*, 1978; Cooper *et al.*, 2007):

$$\min \quad E_o = \sum_{i=1}^r v_i x_{io} \tag{1.17}$$

Nesta formulação, E_o designa o valor da função objetivo linear de minimização. A

medida de eficiência limitada ao intervalo $(0, 1]$ corresponde ao seu inverso. Após a otimização, essa relação é expressa por $\theta_o^* = 1/E_o^*$ (Färe *et al.*, 1994; Cooper *et al.*, 2007; Thanassoulis, 2001).

Para cada DMU k , parte-se da restrição fracionária utilizada para verificar se o conjunto de pesos escolhido para a DMU o também é válido para todas as unidades da amostra (Charnes *et al.*, 1978; Cooper *et al.*, 2007; Thanassoulis, 2001):

$$\frac{\sum_{j=1}^s u_j y_{jk}}{\sum_{i=1}^r v_i x_{ik}} \leq 1 \quad \forall k = 1, \dots, n \quad (1.18)$$

Como o denominador deve ser positivo no domínio da formulação fracionária, a multiplicação dos dois lados por $\sum_{i=1}^r v_i x_{ik}$ preserva o sentido da desigualdade:

$$\sum_{j=1}^s u_j y_{jk} \leq \sum_{i=1}^r v_i x_{ik} \quad \forall k = 1, \dots, n \quad (1.19)$$

Ao transferir a soma ponderada dos *inputs* para o lado esquerdo, obtemos a forma linear utilizada no modelo final:

$$\sum_{j=1}^s u_j y_{jk} - \sum_{i=1}^r v_i x_{ik} \leq 0 \quad \forall k = 1, \dots, n \quad (1.20)$$

Essa restrição implica que, para cada DMU, a soma ponderada dos *outputs* não pode exceder a soma ponderada dos *inputs*. Portanto, a unidade em questão pode escolher os pesos que mais favorecem seu desempenho, desde que esses pesos estejam dentro do limite imposto a todas as outras unidades. A comparação se dá entre as medidas compostas que são construídas a partir dos pesos do modelo, e não entre as quantidades físicas que, necessariamente, estão expressas nas mesmas unidades. A eficiência que se consegue é, portanto, em relação ao grupo de DMUs em análise (Charnes *et al.*, 1978; Cooper *et al.*, 2007; Thanassoulis, 2001).

A própria DMU em análise também deve atender à restrição de eficiência de auto-avaliação. Fazendo $k = o$ e utilizando a normalização dos *outputs*, obtém-se $1 - \sum_{i=1}^r v_i x_{io} \leq 0$. Para explicitar a transformação algébrica, multiplica-se toda a desigualdade por -1 , o que inverte seu sentido. Em seguida, reorganizam-se os termos (Cooper *et al.*, 2007; Thanassoulis, 2001):

$$1 - \sum_{i=1}^r v_i x_{io} \leq 0 \quad \Longleftrightarrow \quad \sum_{i=1}^r v_i x_{io} - 1 \geq 0 \quad \Longleftrightarrow \quad \sum_{i=1}^r v_i x_{io} \geq 1 \quad (1.21)$$

Como a função objetivo minimiza essa soma, seu valor ótimo satisfaz (Cooper *et al.*, 2007; Thanassoulis, 2001):

$$E_o^* = \sum_{i=1}^r v_i^* x_{io} \geq 1 \quad (1.22)$$

O símbolo E_o^* representa o menor valor factível da função objetivo para a DMU o , enquanto v_i^* representa o peso ótimo atribuído ao *input* i . O asterisco sinaliza que esses valores foram obtidos através da resolução do problema de otimização, e não estabelecidos anteriormente (Cooper *et al.*, 2007; Thanassoulis, 2001).

Pelo envelope dual equivalente, E_o^* também representa o fator de expansão radial dos *outputs*. Quando $E_o^* = 1$, não há possibilidade de expansão radial. Quando $E_o^* > 1$, a expansão proporcional possível é $(E_o^* - 1) \times 100\%$. Assim, se $E_o^* = 1,25$, os resultados podem ser ampliados radialmente em 25%, mantendo-se os níveis observados de *inputs*. Desconsiderando eventuais folgas, a projeção radial de cada *output* é: (Färe *et al.*, 1994; Cooper *et al.*, 2007; Thanassoulis, 2001).

$$y_{jo}^{\text{proj}} = E_o^* y_{jo} \quad \forall j = 1, \dots, s \quad (1.23)$$

Quando existe uma folga ótima de *output* s_j^{+*} , a projeção completa incorpora, além da expansão radial, o aumento adicional necessário no resultado j (Färe *et al.*, 1994; Cooper *et al.*, 2007; Thanassoulis, 2001):

$$y_{jo}^{\text{proj}} = E_o^* y_{jo} + s_j^{+*} \quad \forall j = 1, \dots, s \quad (1.24)$$

O fator $E_o^* = 1,25$ não representa eficiência de 125%, mas a proporção pela qual os *outputs* podem ser expandidos. O mesmo resultado pode ser expresso em uma escala limitada ao intervalo $(0, 1]$ por meio da medida recíproca (Färe *et al.*, 1994; Cooper *et al.*, 2007; Thanassoulis, 2001):

$$\theta_o^* = \frac{1}{E_o^*} = \frac{1}{1,25} = 0,80 \quad (1.25)$$

Assim, E_o^* e θ_o^* descrevem o mesmo desempenho sob escalas diferentes. A avaliação do valor ótimo vem antes da investigação de potenciais excessos de entradas e carências adicionais de saídas em que uma DMU é fortemente eficiente apenas quando o fator radial é 1 e todas as folgas ótimas são nulas. A Equação 1.26 corresponde ao modelo final dos multiplicadores, orientado aos *outputs* (Färe *et al.*, 1994; Cooper *et al.*, 2007; Thanassoulis, 2001).

$$\begin{aligned}
\min \quad & E_o = \sum_{i=1}^r v_i x_{io} \\
\text{s.t.} \quad & \sum_{j=1}^s u_j y_{jo} = 1 \\
& \sum_{j=1}^s u_j y_{jk} - \sum_{i=1}^r v_i x_{ik} \leq 0 \quad \forall k = 1, \dots, n \\
& u_j \geq 0 \quad \forall j = 1, \dots, s \\
& v_i \geq 0 \quad \forall i = 1, \dots, r
\end{aligned} \tag{1.26}$$

III. Modelo do Envelope - Orientação ao Input

O modelo CCR dos envelopes orientado aos *inputs* procura o menor fator radial h_o que permite contrair proporcionalmente os recursos da DMU o , sem reduzir os níveis de *outputs* observados. Desse modo, h_o representa a proporção dos *inputs* que a unidade precisaria continuar utilizando após a projeção radial sobre a fronteira eficiente (Cooper *et al.*, 2007; Thanassoulis, 2001).

Os coeficientes h_k , denominados variáveis de intensidade, indicam a participação das DMUs observadas na construção de uma referência virtual para a unidade avaliada. Essa referência combina desempenhos existentes na própria amostra e permite verificar se a DMU o poderia manter seus resultados com uma quantidade proporcionalmente menor de recursos (Cooper *et al.*, 2007; Thanassoulis, 2001).

Como o modelo CCR pressupõe retornos constantes de escala, não se inclui a restrição de convexidade $\sum_{k=1}^n h_k = 1$. As intensidades h_k não precisam necessariamente se somar a uma unidade, e a referência virtual pode funcionar em uma escala que é proporcionalmente maior ou menor do que a das DMUs analisadas (Charnes *et al.*, 1978; Seiford & Thrall, 1990; Cooper *et al.*, 2007).

O modelo dos envelopes focado em *inputs* é o dual do modelo dos multiplicadores com a mesma orientação. Embora utilizem variáveis distintas, ambos avaliam a DMU o em relação à mesma fronteira: o modelo dos multiplicadores utiliza pesos associados aos *inputs* e aos *outputs*, enquanto o modelo dos envelopes utiliza o fator radial e as variáveis de intensidade (Charnes *et al.*, 1978; Seiford & Thrall, 1990; Cooper *et al.*, 2007).

As transições entre os dois modelos revelam que cada restrição do modelo dos multiplicadores corresponde a uma variável no modelo dos envelopes, e vice-versa, cada variável do primeiro modelo resulta em uma restrição no segundo. A Tabela 1.2 reúne as correspondências específicas que serão utilizadas na derivação (Seiford & Thrall, 1990; Bertsimas & Tsitsiklis, 1997).

Tabela 1.2: Correspondências básicas entre os modelos dos multiplicadores e dos envelopes

Modelo dos multiplicadores	Modelo dos envelopes
Restrição associada à DMU k	Variável de intensidade h_k
Normalização dos <i>inputs</i> da DMU o	Fator radial h_o
Peso de <i>output</i> u_j	Restrição de <i>output</i> j
Peso de <i>input</i> v_i	Restrição de <i>input</i> i
Valor ótimo E_o^*	Valor ótimo h_o^*

Fonte: Elaborado com base em Cooper *et al.* (2007) e Thanassoulis (2001).

De acordo com a dualidade forte da programação linear, se ambos os problemas tiverem soluções ótimas viáveis, os valores das funções objetivo serão os mesmos (Bertsimas & Tsitsiklis, 1997; Cooper *et al.*, 2007):

$$E_o^* = h_o^* \quad (1.27)$$

Nessa igualdade, E_o^* é o valor ótimo obtido no modelo dos multiplicadores, enquanto h_o^* é o fator radial ótimo do modelo dos envelopes. As duas definições, então, medem a mesma eficiência usando diferentes notações matemáticas (Cooper *et al.*, 2007; Thanassoulis, 2001).

Para apoiar as etapas seguintes, a Tabela 1.3 apresenta as regras gerais de correspondência entre restrições e variáveis em problemas primal e dual (Bertsimas & Tsitsiklis, 1997).

Tabela 1.3: Regras para construção do modelo dual

Problema de Maximização		Problema de Minimização
Restrições	$\Leftrightarrow$	Variáveis
$\geq$	$\Leftrightarrow$	≤ 0
$\leq$	$\Leftrightarrow$	≥ 0
$=$	$\Leftrightarrow$	Irrestrita
Variáveis	$\Leftrightarrow$	Restrições
≥ 0	$\Leftrightarrow$	$\geq$
≤ 0	$\Leftrightarrow$	$\leq$
Irrestrita	$\Leftrightarrow$	$=$

Fonte: Adaptado de Bertsimas e Tsitsiklis (1997).

O modelo dos multiplicadores possui n restrições de eficiência, uma para cada DMU k , e uma restrição de normalização. Cada restrição de eficiência, escrita no sentido $\leq$ em um problema de maximização, origina uma variável dual não negativa (Seiford & Thrall, 1990; Bertsimas & Tsitsiklis, 1997):

$$h_k \geq 0 \quad \forall k = 1, \dots, n \quad (1.28)$$

A igualdade de normalização origina uma variável inicialmente livre em sinal:

$$h_o \in \mathbb{R} \quad (1.29)$$

Essa liberdade é parte da construção formal do dual. Após a resolução do modelo e sob as suposições habituais de dados positivos, o valor ótimo é equivalente ao fator radial de contração e atende a (Cooper *et al.*, 2007; Thanassoulis, 2001):

$$0 < h_o^* \leq 1 \quad (1.30)$$

As condições $u_j \geq 0$ e $v_i \geq 0$ do modelo dos multiplicadores determinam, por sua vez, os sentidos das restrições correspondentes no modelo dos envelopes (Bertsimas & Tsitsiklis, 1997).

A função objetivo dual é criada a partir dos lados direitos das restrições do modelo dos multiplicadores. Como as n restrições de eficiência possuem lado direito zero e a normalização possui lado direito um, somente a variável associada à normalização permanece no objetivo. Como o problema original é de maximização, o dual é de minimização (Seiford & Thrall, 1990; Bertsimas & Tsitsiklis, 1997):

$$0h_1 + 0h_2 + \dots + 0h_n + 1h_o = h_o \quad (1.31)$$

Como o modelo dos multiplicadores é de maximização, seu dual é de minimização:

$$\min \quad E_o = h_o \quad (1.32)$$

Cada peso u_j origina uma restrição de *output* no modelo dos envelopes. Na coluna correspondente a u_j , os coeficientes são y_{jk} nas restrições de eficiência, zero na normalização e y_{jo} na função objetivo. Usando a correspondência dual e rearranjando os termos, obtemos (Seiford & Thrall, 1990; Bertsimas & Tsitsiklis, 1997):

$$\sum_{k=1}^n y_{jk} h_k + 0h_o \geq y_{jo} \quad \forall j = 1, \dots, s \quad (1.33)$$

Eliminando o termo nulo e transferindo y_{jo} para o lado esquerdo:

$$-y_{jo} + \sum_{k=1}^n y_{jk} h_k \geq 0 \quad \forall j = 1, \dots, s \quad (1.34)$$

A soma $\sum_{k=1}^n y_{jk} h_k$ representa a quantidade do *output* j produzida pela referência virtual. A restrição exige que essa referência produza, pelo menos, o nível observado na DMU avaliada (Charnes *et al.*, 1978; Cooper *et al.*, 2007; Thanassoulis, 2001).

Cada peso v_i origina uma restrição de *input*. Na coluna correspondente a v_i , os coeficientes são $-x_{ik}$ nas restrições de eficiência, x_{io} na normalização e zero na função objetivo. Ao se aplicar as regras de dualidade (Seiford & Thrall, 1990; Bertsimas & Tsitsiklis, 1997), obtemos:

$$-\sum_{k=1}^n x_{ik} h_k + x_{io} h_o \geq 0 \quad \forall i = 1, \dots, r \quad (1.35)$$

Reordenando os termos:

$$h_o x_{io} - \sum_{k=1}^n x_{ik} h_k \geq 0 \quad \forall i = 1, \dots, r \quad (1.36)$$

O termo $h_o x_{io}$ representa a quantidade radialmente reduzida do *input* i da DMU avaliada, enquanto $\sum_{k=1}^n x_{ik} h_k$ representa a quantidade desse recurso utilizada pela referência virtual. A limitação obriga a referência a não usar mais do que o que resta depois da contração radial (Charnes *et al.*, 1978; Cooper *et al.*, 2007; Thanassoulis, 2001).

O valor ótimo h_o^* é aplicado simultaneamente a todos os *inputs*, de modo que a contração radial ocorre na mesma proporção para cada recurso. Desconsiderando folgas, o valor-alvo do *input* i é (Färe *et al.*, 1994; Cooper *et al.*, 2007; Thanassoulis, 2001):

$$x_{io}^{\text{proj}} = h_o^* x_{io} \quad \forall i = 1, \dots, r \quad (1.37)$$

Se $h_o^* = 0,80$, a redução radial possível é:

$$(1 - h_o^*) \times 100\% = (1 - 0,80) \times 100\% = 20\% \quad (1.38)$$

Portanto, a DMU precisaria utilizar 80% dos recursos observados, mantendo os níveis de *outputs*.

Quando existe folga de *input*, representada por s_i^- , a projeção completa incorpora uma redução adicional específica no recurso i (Cooper *et al.*, 2007; Thanassoulis, 2001):

$$x_{io}^{\text{proj}} = h_o^* x_{io} - s_i^{-*} \quad \forall i = 1, \dots, r \quad (1.39)$$

Assim, a eficiência radial é caracterizada por $h_o^* = 1$, enquanto a eficiência forte requer, além desse valor, ausência de folgas adicionais nos *inputs* e nos *outputs*. O modelo final dos envelopes, voltado para os *inputs* está representado pela Equação 1.40 (Cooper *et al.*, 2007; Thanassoulis, 2001).

$$\begin{aligned} \min \quad & E_o = h_o \\ \text{s.t.} \quad & h_o x_{io} - \sum_{k=1}^n x_{ik} h_k \geq 0 \quad \forall i = 1, \dots, r \\ & -y_{jo} + \sum_{k=1}^n y_{jk} h_k \geq 0 \quad \forall j = 1, \dots, s \\ & h_k \geq 0 \quad \forall k = 1, \dots, n \end{aligned} \quad (1.40)$$

IV. Modelo do Envelope - Orientação ao Output

O envelope CCR orientado aos *outputs* determina o maior fator radial h_o pelo qual os resultados da DMU avaliada podem ser expandidos proporcionalmente, mantendo constantes seus níveis de *inputs*. Os coeficientes de intensidade h_k combinam as DMUs observadas para construir uma referência virtual que respeita os limites de recursos e domina radialmente os resultados da unidade analisada (Cooper *et al.*, 2007; Thanassoulis, 2001; Färe *et al.*, 1994).

O modelo dos multiplicadores orientado aos *outputs* é formulado como um problema de minimização. Para aplicar diretamente as regras de dualidade, cada restrição de eficiência é reescrita no sentido $\geq$. Parte-se de (Seiford & Thrall, 1990; Bertsimas & Tsitsiklis, 1997):

$$\sum_{j=1}^s u_j y_{jk} - \sum_{i=1}^r v_i x_{ik} \leq 0 \quad (1.41)$$

Multiplicando todos os termos por -1 , o sentido da desigualdade é invertido sem alterar o conjunto de soluções:

$$-\sum_{j=1}^s u_j y_{jk} + \sum_{i=1}^r v_i x_{ik} \geq 0 \quad (1.42)$$

Cada restrição de eficiência padronizada origina uma variável de intensidade $h_k \geq 0$, enquanto a normalização $\sum_{j=1}^s u_j y_{jo} = 1$ origina o fator radial h_o . Como somente essa normalização possui lado direito igual a uma unidade, a função objetivo do modelo dual é (Seiford &

Thrall, 1990; Bertsimas & Tsitsiklis, 1997):

$$\max \quad E_o = h_o \quad (1.43)$$

Na forma padronizada, o coeficiente de v_i na restrição correspondente à DMU k é x_{ik} . Na normalização dos *outputs* é zero. Na função objetivo do modelo dos multiplicadores, é x_{io} . Portanto, a restrição dual associada ao *input* i é (Seiford & Thrall, 1990; Bertsimas & Tsitsiklis, 1997):

$$x_{io} - \sum_{k=1}^n x_{ik} h_k \geq 0 \quad \forall i = 1, \dots, r \quad (1.44)$$

Essa restrição assegura que a referência virtual não utilize uma quantidade de *input* superior à observada na DMU avaliada.

O coeficiente de u_j é $-y_{jk}$ nas restrições de eficiência padronizadas, y_{jo} na normalização e zero na função objetivo. A restrição dual intermediária é (Seiford & Thrall, 1990; Bertsimas & Tsitsiklis, 1997):

$$-\sum_{k=1}^n y_{jk} h_k + y_{jo} h_o \leq 0 \quad (1.45)$$

Multiplicando a desigualdade por -1 e reorganizando os termos, obtém-se sua forma usual:

$$-h_o y_{jo} + \sum_{k=1}^n y_{jk} h_k \geq 0 \quad \forall j = 1, \dots, s \quad (1.46)$$

A restrição estabelece que, para cada *output* j , a quantidade produzida pela referência construída pelo modelo ($\sum_{k=1}^n y_{jk} h_k$) deve ser maior ou igual ao valor observado na DMU avaliada multiplicado pelo fator de expansão ($h_o y_{jo}$). Dessa forma, o modelo procura o maior valor de h_o para o qual a relação $\sum_{k=1}^n y_{jk} h_k \geq h_o y_{jo}$ ainda pode ser satisfeita para todos os *outputs*.

Após a resolução, o valor ótimo h_o^* indica o maior fator de expansão proporcional dos *outputs*. Assim, cada *output* observado y_{jo} é multiplicado por h_o^* , resultando em $h_o^* y_{jo}$. Por exemplo, se $h_o^* = 1,20$, um *output* igual a 100 passa a ter como referência radial o valor 120. Desconsiderando eventuais folgas, essa multiplicação define a projeção proporcional dos *outputs* em direção à fronteira. Desconsiderando eventuais folgas, a projeção radial de cada resultado é dada por:

$$y_{jo}^{\text{rad}} = h_o^* y_{jo} \quad \forall j = 1, \dots, s \quad (1.47)$$

Se $h_o^* = 1,25$, os *outputs* podem ser ampliados radialmente em 25%. O mesmo desempenho pode ser expresso em uma escala limitada ao intervalo $(0, 1]$ pela medida recíproca:

$$\theta_o^* = \frac{1}{h_o^*} = \frac{1}{1,25} = 0,80 \quad (1.48)$$

Portanto, $h_o^* = 1,25$ e $\theta_o^* = 0,80$ representam o mesmo desempenho em escalas distintas. Quando existem folgas ótimas de *output*, a projeção completa incorpora também o aumento não radial específico de cada resultado:

$$y_{jo}^{\text{proj}} = h_o^* y_{jo} + s_j^{+*} \quad \forall j = 1, \dots, s \quad (1.49)$$

Uma DMU é fortemente eficiente quando $h_o^* = 1$ e todas as folgas ótimas são nulas (Färe *et al.*, 1994; Thanassoulis, 2001; Cooper *et al.*, 2007).

$$\begin{aligned} \max \quad & E_o = h_o \\ \text{s.t.} \quad & x_{io} - \sum_{k=1}^n x_{ik} h_k \geq 0 \quad \forall i = 1, \dots, r \\ & -h_o y_{jo} + \sum_{k=1}^n y_{jk} h_k \geq 0 \quad \forall j = 1, \dots, s \\ & h_k \geq 0 \quad \forall k = 1, \dots, n \end{aligned} \quad (1.50)$$

1.1.2.2 BCC

O modelo BCC, apresentado por Banker *et al.* (1984), é uma extensão do modelo CCR, pois considera os retornos variáveis de escala, ou seja, os *Variable Returns to Scale* (VRS). No modelo dos envelopes, essa hipótese é representada pela restrição de convexidade $\sum_{k=1}^n h_k = 1$, que limita a referência virtual a uma combinação convexa das DMUs observadas. No modelo dos multiplicadores, a mesma igualdade origina uma variável livre em sinal: u_* na orientação aos *inputs* e v_* na orientação aos *outputs*. Com isso, torna-se possível separar a eficiência técnica pura dos efeitos relacionados à escala de operação (Banker *et al.*, 1984; Cook & Seiford, 2009).

A forma dual pode ser obtida diretamente pelas regras de dualidade da programação linear. Em cada orientação, a sequência conceitual é:

$$\boxed{\text{CCR multiplicadores} \xrightarrow{\text{dualidade}} \text{CCR envelope} \xrightarrow{\sum_{k=1}^n h_k = 1} \text{BCC envelope} \xrightarrow{\text{dualidade}} \text{BCC multiplicadores}} \quad (1.51)$$

Assim, para construir o BCC dos multiplicadores orientado aos *inputs*, parte-se conceitualmente do CCR envelope orientado aos *inputs*, acrescenta-se $\sum_k h_k = 1$ para obter o envelope BCC e, somente então, aplica-se a dualidade para chegar aos multiplicadores BCC. O mesmo encadeamento é empregado na orientação aos *outputs*. Quando a meta for desenvolver um modelo do envelope, a referência inicial será o modelo BCC dos multiplicadores da mesma direção (Charnes *et al.*, 1978; Banker *et al.*, 1984; Seiford & Thrall, 1990).

A mudança entre os modelos dos envelopes e dos multiplicadores será feita diretamente de acordo com as regras de dualidade da programação linear. Não será preciso desenvolver a função Lagrangiana, uma vez que as correspondências entre restrições, variáveis, coeficientes e lados direitos já são suficientes para extrair completamente o problema dual. Essa opção mantém o rigor matemático e torna mais visível a única alteração estrutural introduzida pelo BCC em relação ao CCR (Banker *et al.*, 1984; Seiford & Thrall, 1990):

$$\sum_{k=1}^n h_k = 1 \quad (1.52)$$

Nos modelos BCC, as restrições do envelope originam:

$$\begin{aligned} \text{restrição de input } i &\longrightarrow v_i \geq 0, \\ \text{restrição de output } j &\longrightarrow u_j \geq 0, \\ \sum_{k=1}^n h_k = 1 &\longrightarrow u_* \in \mathbb{R} \text{ ou } v_* \in \mathbb{R}. \end{aligned} \quad (1.53)$$

A variável que se relaciona à convexidade é livre, pois ela provém de uma igualdade.

Por último, a função objetivo do dual é constituída pelos lados direitos das restrições do problema primal, cada um multiplicado pelas variáveis duais correspondentes. A derivação, portanto, divide-se em quatro etapas: 1. identificação das variáveis duais; 2. construção da função objetivo; 3. leitura da coluna do fator radial; e 4. leitura da coluna de cada intensidade.

Esse método de leitura matricial conduz aos mesmos modelos duais obtidos por uma derivação Lagrangiana, sem a necessidade de introduzir uma expressão auxiliar para desenvolver o problema dual.

O termo livre possibilita mover o hiperplano de suporte, assim a fronteira eficiente não precisa obrigatoriamente passar pela origem. Na formulação dos *inputs*, a linearização é conseguida através da normalização do denominador. Na orientação aos *outputs*, normaliza-se o numerador e utiliza-se a variável livre v_* . A Tabela 1.4 engloba os termos adotados nessa seção referentes ao modelo BCC (Banker *et al.*, 1984; Seiford & Thrall, 1990).

Tabela 1.4: Notação utilizada nos modelos BCC

Símbolo	Definição
o	Índice da DMU avaliada.
k	Índice das DMUs em comparação, com $k = 1, \dots, n$.
i	Índice dos <i>inputs</i> , com $i = 1, \dots, r$.
j	Índice dos <i>outputs</i> , com $j = 1, \dots, s$.
x_{ik}	Quantidade do <i>input</i> i utilizada pela DMU k .
y_{jk}	Quantidade do <i>output</i> j produzida pela DMU k .
v_i	Peso atribuído ao <i>input</i> i .
u_j	Peso atribuído ao <i>output</i> j .
u_*	Variável livre em sinal do modelo BCC dos multiplicadores orientado aos <i>inputs</i> .
v_*	Variável livre em sinal do modelo BCC dos multiplicadores orientado aos <i>outputs</i> .
h_k	Intensidade associada à DMU k na composição da referência virtual.
h_o	Fator radial associado à DMU avaliada.

Fonte: Elaborado com base em Banker *et al.* (1984), Thanassoulis (2001) e Cooper *et al.* (2007).

I. Modelo dos Multiplicadores - Orientação ao Input

No BCC orientado aos *inputs*, a soma ponderada dos recursos da DMU avaliada é normalizada em uma unidade, enquanto a função objetivo maximiza os *outputs* ponderados acrescidos do termo livre u_* . Essa variável resulta da simetria convexa do envelope, possibilitando mover o hiperplano de suporte sem a necessidade de manter retornos constantes de escala (Banker *et al.*, 1984; Seiford & Thrall, 1990).

Parte-se do envelope BCC orientado aos *inputs*, obtido pela inclusão da restrição de convexidade no envelope CCR:

$$\begin{aligned}
 \min \quad & E_o = h_o \\
 \text{s.t.} \quad & h_o x_{io} - \sum_{k=1}^n x_{ik} h_k \geq 0 \quad \forall i = 1, \dots, r \\
 & -y_{jo} + \sum_{k=1}^n y_{jk} h_k \geq 0 \quad \forall j = 1, \dots, s \\
 & \sum_{k=1}^n h_k = 1 \\
 & h_k \geq 0 \quad \forall k = 1, \dots, n
 \end{aligned} \tag{1.54}$$

Associam-se $v_i \geq 0$ às restrições de *input*, $u_j \geq 0$ às restrições de *output* e $u_* \in \mathbb{R}$ à igualdade de convexidade. A liberdade de sinal de u_* decorre do fato de a restrição correspondente ser uma igualdade (Banker *et al.*, 1984; Seiford & Thrall, 1990).

O envelope BCC orientado aos *inputs* tem três categorias de restrições. A associação direta é:

$$\begin{aligned}
 h_o x_{io} - \sum_{k=1}^n x_{ik} h_k \geq 0 &\longrightarrow v_i \geq 0, \quad \forall i, \\
 \sum_{k=1}^n y_{jk} h_k \geq y_{jo} &\longrightarrow u_j \geq 0, \quad \forall j, \\
 \sum_{k=1}^n h_k = 1 &\longrightarrow u_* \in \mathbb{R}.
 \end{aligned} \tag{1.55}$$

A convexidade igual gera uma variável livre, enquanto as desigualdades geram pesos não negativos (Banker *et al.*, 1984; Seiford & Thrall, 1990).

Os lados direitos das restrições de *input* são nulos, os lados direitos das restrições de *output* são y_{jo} e o lado direito da convexidade é um. Multiplicando esses valores pelas variáveis duais correspondentes, obtém-se a função objetivo:

$$\max \quad E_o = \sum_{j=1}^s u_j y_{jo} + u_* \tag{1.56}$$

Assim, u_* aparece na função objetivo porque é a variável dual associada à igualdade cujo lado direito é igual a uma unidade. A coluna de h_o no envelope contém:

$$\begin{aligned}
x_{io} & \text{ nas restrições de } input, \\
0 & \text{ nas restrições de } output, \\
0 & \text{ na convexidade.}
\end{aligned} \tag{1.57}$$

O coeficiente de h_o na função objetivo do envelope é um. Logo:

$$\sum_{i=1}^r v_i x_{io} + 0 \sum_{j=1}^s u_j + 0 u_* = 1 \tag{1.58}$$

Retirando os termos nulos:

$$\sum_{i=1}^r v_i x_{io} = 1 \tag{1.59}$$

Aqui é feita a normalização dos *inputs* da DMU em análise.

Para uma intensidade $h_k \geq 0$, a coluna correspondente contém:

$$\begin{aligned}
-x_{ik} & \text{ nas restrições de } input, \\
y_{jk} & \text{ nas restrições de } output, \\
1 & \text{ na convexidade.}
\end{aligned} \tag{1.60}$$

Como o coeficiente de h_k na função objetivo é zero, a restrição dual intermediária é:

$$-\sum_{i=1}^r v_i x_{ik} + \sum_{j=1}^s u_j y_{jk} + u_* \leq 0 \tag{1.61}$$

Reordenando:

$$\sum_{j=1}^s u_j y_{jk} - \sum_{i=1}^r v_i x_{ik} + u_* \leq 0 \quad \forall k = 1, \dots, n \tag{1.62}$$

A presença de u_* em todas as restrições decorre diretamente do coeficiente unitário de cada h_k na igualdade de convexidade.

O valor ótimo E_o^* representa a eficiência técnica pura da DMU sob retornos variáveis de escala. Na orientação aos *inputs*, $0 < E_o^* \leq 1$. Um valor de um significa que não é possível nenhuma contração radial sob a tecnologia BCC. Valores abaixo de um indicam a fração de recursos que permaneceria após a contração radial, antes de considerar quaisquer folgas. Após

as demonstrações anteriores, o modelo BCC no formato dos multiplicadores e com orientação aos *inputs* assume a seguinte formulação (Banker *et al.*, 1984; Cook & Seiford, 2009):

$$\begin{aligned}
 \max \quad & E_o = \sum_{j=1}^s u_j y_{jo} + u_* \\
 \text{s.t.} \quad & \sum_{i=1}^r v_i x_{io} = 1 \\
 & \sum_{j=1}^s u_j y_{jk} - \sum_{i=1}^r v_i x_{ik} + u_* \leq 0 \quad \forall k = 1, \dots, n \\
 & u_j \geq 0 \quad \forall j = 1, \dots, s \\
 & v_i \geq 0 \quad \forall i = 1, \dots, r \\
 & u_* \in \mathbb{R}
 \end{aligned} \tag{1.63}$$

II. Modelo dos Multiplicadores - Orientação ao Output

Na orientação aos *outputs*, a soma ponderada dos resultados da DMU avaliada é normalizada em uma unidade. A função objetivo minimiza os *inputs* ponderados acrescidos de v_* . Assim como ocorre na orientação aos *inputs*, a variável livre traduz no modelo dos multiplicadores a igualdade de convexidade do envelope (Banker *et al.*, 1984; Seiford & Thrall, 1990). Partindo do envelope BCC orientado aos *outputs*:

$$\begin{aligned}
 \max \quad & E_o = h_o \\
 \text{s.t.} \quad & x_{io} - \sum_{k=1}^n x_{ik} h_k \geq 0 \quad \forall i = 1, \dots, r \\
 & -h_o y_{jo} + \sum_{k=1}^n y_{jk} h_k \geq 0 \quad \forall j = 1, \dots, s \\
 & \sum_{k=1}^n h_k = 1 \\
 & h_k \geq 0 \quad \forall k = 1, \dots, n
 \end{aligned} \tag{1.64}$$

Associam-se $v_i \geq 0$ às restrições de *input*, $u_j \geq 0$ às restrições de *output* e $v_* \in \mathbb{R}$ à igualdade de convexidade (Banker *et al.*, 1984; Seiford & Thrall, 1990).

Para a orientação aos *outputs*, escreve-se o envelope de forma conveniente à leitura dos coeficientes:

$$\begin{aligned}
\sum_{k=1}^n x_{ik} h_k &\leq x_{io}, \quad \forall i = 1, \dots, r \\
-\sum_{k=1}^n y_{jk} h_k + h_o y_{jo} &\leq 0, \quad \forall j = 1, \dots, s \\
\sum_{k=1}^n h_k &= 1
\end{aligned} \tag{1.65}$$

As variáveis duais associadas são:

$$\begin{aligned}
\text{restrição de input } i &\longrightarrow v_i \geq 0, \\
\text{restrição de output } j &\longrightarrow u_j \geq 0, \\
\sum_{k=1}^n h_k = 1 &\longrightarrow v_* \in \mathbb{R}.
\end{aligned} \tag{1.66}$$

Os lados direitos são x_{io} nas restrições de *input*, zero nas restrições de *output* e o termo constante da convexidade é um. Logo:

$$\sum_{i=1}^r v_i x_{io} + 0 \sum_{j=1}^s u_j + 1 v_* \tag{1.67}$$

Eliminando o termo nulo:

$$\sum_{i=1}^r v_i x_{io} + v_* \tag{1.68}$$

Como o envelope é de maximização, seu dual é de minimização:

$$\min \quad E_o = \sum_{i=1}^r v_i x_{io} + v_* \tag{1.69}$$

A coluna do fator radial h_o apresenta coeficiente zero nas restrições de *input*, y_{jo} nas restrições de *output* e zero na convexidade. Como seu coeficiente na função objetivo do envelope é um:

$$0 \sum_{i=1}^r v_i + \sum_{j=1}^s u_j y_{jo} + 0 v_* = 1 \tag{1.70}$$

Portanto:

$$\sum_{j=1}^s u_j y_{jo} = 1 \quad (1.71)$$

Essa é a normalização dos *outputs* da DMU avaliada. Para cada $h_k \geq 0$, os coeficientes são:

$$\begin{aligned} x_{ik} & \text{ nas restrições de } input; \\ -y_{jk} & \text{ nas restrições de } output, \\ 1 & \text{ na igualdade de convexidade.} \end{aligned} \quad (1.72)$$

Como o coeficiente de h_k na função objetivo é zero, a condição dual intermediária é:

$$\sum_{i=1}^r v_i x_{ik} - \sum_{j=1}^s u_j y_{jk} + v_* \geq 0 \quad (1.73)$$

Transferindo os termos ou, de forma equivalente, multiplicando toda a desigualdade por -1 :

$$\sum_{j=1}^s u_j y_{jk} - \sum_{i=1}^r v_i x_{ik} - v_* \leq 0 \quad \forall k = 1, \dots, n \quad (1.74)$$

Assim, o termo $+v_*$ associado ao lado direito unitário da convexidade aparece como $-v_*$ quando a restrição é escrita na forma usual dos multiplicadores.

O termo v_* deve ser interpretado em conjunto com a convenção algébrica adotada, pois seu sinal depende da posição em que aparece na função objetivo e nas restrições. Em termos geométricos, ele representa o intercepto do hiperplano de suporte e participa da identificação local dos retornos de escala. Portanto, é imprudente categorizar retornos como crescentes ou decrescentes apenas com base no sinal isolado do termo sem antes consultar a convenção do modelo e a solução ótima (Banker *et al.*, 1984).

O valor ótimo direto satisfaz $E_o^* \geq 1$ e representa o fator máximo de expansão radial dos *outputs*. A medida recíproca $\theta_o^* = 1/E_o^*$ pertence ao intervalo $(0, 1]$ e pode ser utilizada quando se deseja expressar a eficiência na mesma escala limitada empregada na orientação aos *inputs* (Banker *et al.*, 1984; Cook & Seiford, 2009).

O valor ótimo de v^* fornece informações sobre o tipo de retorno de escala associado à unidade avaliada:

$$\begin{cases} v^* = 0 & \text{Retornos constantes de escala} \\ v^* < 0 & \text{Retornos crescentes de escala} \\ v^* > 0 & \text{Retornos decrescentes de escala} \end{cases} \quad (1.75)$$

Considerando a ideia de Banker *et al.* (2011), quando $v^* < 0$, a unidade opera sob retornos crescentes de escala, indicando que um aumento proporcional nos insumos tende a gerar um aumento mais que proporcional nos produtos. Nessa situação, a unidade pode se beneficiar de uma ampliação de escala. Por outro lado, quando $v^* > 0$, a unidade apresenta retornos decrescentes de escala, indicando que aumentos nos insumos resultam em aumentos menos que proporcionais nos produtos, sugerindo que a unidade pode estar operando em escala excessiva. A formulação final do modelo BCC na forma dos multiplicadores, com orientação aos *outputs*, pode ser escrita da seguinte forma:

$$\begin{aligned} \min \quad & Eff_o = \sum_{i=1}^r v_i x_{io} + v_* \\ \text{s.t.} \quad & \sum_{j=1}^s u_j y_{jo} = 1 \\ & \sum_{j=1}^s u_j y_{jk} - \sum_{i=1}^r v_i x_{ik} - v_* \leq 0 \quad \forall k \\ & v_i, u_j \geq 0 \quad \forall i, \forall j \\ & v_* \in \mathbb{R} \end{aligned} \quad (1.76)$$

III. Modelo do Envelope - Orientação ao Input

O modelo BCC do envelope orientado aos *inputs* constitui uma extensão do modelo CCR da mesma orientação. A função objetivo, as restrições radiais de *inputs* e *outputs* e a não negatividade das intensidades são preservadas, acrescentando-se apenas a restrição de convexidade $\sum_{k=1}^n h_k = 1$. Apesar de sua simplicidade formal, essa mudança elimina a suposição de retornos constantes em favor da suposição de retornos que variam com a escala (Banker *et al.*, 1984; Cooper *et al.*, 2007; Thanassoulis, 2001).

A primeira família de restrições, expressa por $\sum_{k=1}^n x_{ik} h_k \leq h_o x_{io}$, determina que a referência virtual utilize, para cada *input* i , no máximo a quantidade radialmente contraída desse recurso na DMU avaliada. A segunda, dada por $\sum_{k=1}^n y_{jk} h_k \geq y_{jo}$, exige que a referência produza pelo menos os níveis de *outputs* observados na DMU o . Por sua vez, a restrição de convexidade destacada em azul, combinada com $h_k \geq 0$, faz com que as intensidades definam uma combinação convexa das DMUs observadas, permitindo a representação de retornos variáveis de escala. Unindo essas restrições, obtém-se a Equação 1.77 que representa a versão final desse modelo (Banker *et al.*, 1984; Cooper *et al.*, 2007).

$$\begin{aligned}
\min \quad & E_o = h_o \\
\text{s.t.} \quad & h_o x_{io} - \sum_{k=1}^n x_{ik} h_k \geq 0 & \forall i = 1, \dots, r \\
& -y_{jo} + \sum_{k=1}^n y_{jk} h_k \geq 0 & \forall j = 1, \dots, s \\
& \sum_{k=1}^n h_k = 1 \\
& h_k \geq 0 & \forall k = 1, \dots, n
\end{aligned} \tag{1.77}$$

O valor ótimo h_o^* representa a proporção radial dos *inputs* que permaneceria após a projeção sobre a fronteira BCC. Assim, $0 < h_o^* \leq 1$. A razão entre a eficiência técnica pura e a eficiência do CCR, sendo a primeira resultante da convexidade do BCC em relação à escala, permite identificar quanto da ineficiência está relacionada à escala (Banker *et al.*, 1984).

IV. Modelo do Envelope - Orientação ao Output

O modelo BCC do envelope orientado aos *outputs* pode ser apresentado como uma extensão direta do modelo CCR da mesma orientação. A estrutura radial, as restrições de *inputs*, as restrições de *outputs* e a não negatividade das intensidades permanecem inalteradas. A diferença formal consiste na inclusão da restrição de convexidade $\sum_{k=1}^n h_k = 1$, responsável por substituir a hipótese de retornos constantes de escala pela hipótese de retornos variáveis de escala (Banker *et al.*, 1984; Cooper *et al.*, 2007; Thanassoulis, 2001).

Com a inclusão da restrição de convexidade $\sum_{k=1}^n h_k = 1$, o modelo final torna-se:

$$\begin{aligned}
\max \quad & E_o = h_o \\
\text{s.t.} \quad & x_{io} - \sum_{k=1}^n x_{ik} h_k \geq 0 & \forall i = 1, \dots, r \\
& -h_o y_{jo} + \sum_{k=1}^n y_{jk} h_k \geq 0 & \forall j = 1, \dots, s \\
& \sum_{k=1}^n h_k = 1 \\
& h_k \geq 0 & \forall k = 1, \dots, n
\end{aligned} \tag{1.78}$$

A primeira família de restrições impede que a referência virtual utilize uma quantidade de *input* superior à observada na DMU o . A segunda exige que essa referência produza, para cada resultado j , pelo menos h_o vezes o valor observado na unidade avaliada. Em contraste, o CCR aceita retornos constantes de escala, as intensidades não necessitam somar um e

podem gerar combinações cônicas das DMUs analisadas (Charnes *et al.*, 1978; Banker *et al.*, 1984).

O valor ótimo h_o^* mantém a interpretação radial do modelo CCR: ele representa o maior fator pelo qual todos os *outputs* da DMU avaliada podem ser ampliados proporcionalmente, sem aumentar seus *inputs*. No BCC, no entanto, essa expansão é calculada em relação a uma tecnologia com retornos de escala não constantes.

A eficiência recíproca é:

$$\theta_o^* = \frac{1}{h_o^*} \in (0, 1] \quad (1.79)$$

A interpretação radial permanece a mesma que na análise do CCR, porém a fronteira de comparação é definida pela tecnologia convexa BCC, que leva em consideração os efeitos de escala (Banker *et al.*, 1984; Thanassoulis, 2001). Sob as condições usuais, $h_o^* \geq 1$. Se $h_o^* = 1,25$, os resultados podem ser ampliados radialmente em 25%.

V. Eficiência de Escala (EE)

A eficiência técnica pura é calculada pelo modelo BCC, que avalia como a unidade transforma insumos em produtos, sem exigir a condição de operar na escala ótima. O modelo CCR, por sua vez, avalia tanto a eficiência técnica quanto a eficiência em relação à escala de operação ao mesmo tempo. A ligação entre essas duas medidas possibilita o cálculo da eficiência de escala (EE), que é definida como:

$$EE = \frac{\theta_{CCR}}{\theta_{BCC}} \quad (1.80)$$

onde θ_{CCR} e θ_{BCC} representam, respectivamente, os escores de eficiência limitados ao intervalo $(0, 1]$ obtidos sob retornos constantes e variáveis de escala (Bogetoft & Otto, 2010). Na orientação aos *outputs*, quando se utilizam diretamente os fatores de expansão $h_{CCR} \geq 1$ e $h_{BCC} \geq 1$, a mesma relação pode ser escrita como $EE = h_{BCC}/h_{CCR}$, pois $\theta = 1/h$.

Quando $EE = 1$, a unidade opera em escala ótima. Se não for assim, parte da ineficiência observada pode ser atribuída à inadequação da escala de produção em que a unidade opera. A análise conjunta dos modelos CCR e BCC possibilita que se identifique se a unidade em questão opera com retornos crescentes ou decrescentes de escala, o que é fundamental para embasar decisões gerenciais sobre a ampliação ou diminuição da escala de operação (Cooper *et al.*, 2007).

Geometricamente falando, a restrição de convexidade é o que torna a fronteira eficiente uma envoltória convexa de combinações das DMUs observadas. Isso torna o modelo BCC especialmente apropriado para a avaliação de sistemas produtivos onde as unidades analisadas funcionam em diferentes escalas de produção (Bogetoft & Otto, 2010).

1.1.2.3 BoD - Benefit-of-the-Doubt

O método *Benefit-of-the-Doubt* (BoD) consiste em uma abordagem baseada em Análise Envoltória de Dados (DEA), amplamente empregada na construção de indicadores compostos e na avaliação de desempenhos multidimensionais. A Tabela 1.5 reúne um recorte de aplicações publicadas nos últimos cinco anos, selecionado com auxílio de IA e posteriormente verificadas.

Tabela 1.5: Indicadores Compostos: Aplicações recentes com *BoD*

Autor(es)	Revista	JIF 2025	Aplicação
Mergoni <i>et al.</i> (2022)	<i>Utilities Policy</i>	4,9	Avaliação do desempenho ambiental de empresas portuguesas dos setores de água, esgoto e resíduos sólidos.
Ben Lahouel <i>et al.</i> (2022)	<i>Finance Research Letters</i>	7,1	Avaliação da evolução do desempenho socioambiental de empresas.
Fusco (2023)	<i>Socio-Economic Planning Sciences</i>	5,2	Aplicação de um BoD multidirecional ao <i>OECD Better Life Index</i> para identificar dimensões de bem-estar com potencial de melhoria.
Su <i>et al.</i> (2023)	<i>European Journal of Operational Research</i>	7,0	Construção do Índice de Desenvolvimento Humano europeu com abordagem baseada na dominância entre subgrupos.
Walheer (2024)	<i>European Journal of Operational Research</i>	7,0	Aplicação de um BoD sequencial à avaliação da vulnerabilidade, prontidão e resiliência dos países às mudanças climáticas.
Vidoli <i>et al.</i> (2024)	<i>Socio-Economic Planning Sciences</i>	5,2	Avaliação da qualidade dos serviços médicos agudos nos países da OCDE por meio de um indicador multidirecional e robusto.
Giambona <i>et al.</i> (2024)	<i>Socio-Economic Planning Sciences</i>	5,2	Avaliação da sustentabilidade turística da União Europeia e do Reino Unido antes e após a pandemia de COVID-19.
May <i>et al.</i> (2025)	<i>Annals of Operations Research</i>	4,1	Avaliação do desempenho financeiro, operacional e da qualidade dos serviços de água e esgoto em municípios de Santa Catarina.
Pereira <i>et al.</i> (2025)	<i>Annals of Operations Research</i>	4,1	Construção de indicadores de mobilidade educacional no ensino superior europeu, considerando diferenças no desenvolvimento humano.
Blancas e Contre-ras (2025)	<i>Sustainable Development</i>	9,3	Construção de um indicador composto para avaliar os Objetivos de Desenvolvimento Sustentável nos países da OCDE.

Fonte: Elaboração própria com auxílio de IA

Para cada DMU em análise, o modelo determina a combinação de pesos que otimiza seu indicador composto, conferindo-lhe, portanto, o denominado “benefício da dúvida”. Durante a avaliação de uma DMU específica, o vetor de pesos escolhido para favorecê-la é aplicado também às demais DMUs nas restrições de viabilidade. Assim, cada DMU pode pos-

suir um vetor ótimo distinto, mas cada vetor deve respeitar a mesma fronteira de comparação e não pode produzir um indicador composto superior a 1 para nenhuma unidade da amostra. Dessa forma, o método oferece uma base de comparação relativa comum sem impor antecipadamente um único vetor fixo de pesos a todas as unidades. Na sua formulação clássica, o BoD é, formalmente, o mesmo que o modelo CCR, no que se refere aos multiplicadores e ao fato de ser orientado para os *outputs*, porém com um único *input* fictício, que é igual a 1. Essa equivalência é meramente matemática e não significa que o *input* fictício tenha uma interpretação significativa no processo de avaliação (Cherchye *et al.*, 2004, 2007; Van Puyenbroeck, 2018).

No modelo clássico de BoD, os indicadores elementares são considerados como *outputs*, e todas as DMUs recebem um único *input* fictício, com valor igual a um. Os pesos dos *outputs* funcionam como variáveis de decisão, enquanto o *input* unitário serve como uma condição de normalização. Nessas circunstâncias, o escore obtido indica como a DMU se compara às outras unidades da amostra, com resultados que se aproximam de 1 sugerindo um desempenho superior. De uma maneira alternativa, é possível considerar os indicadores como *inputs* e atribuir um único *output* fictício, igual a 1, a todas as DMUs. Há uma relação inversa entre as duas formulações, sob a condição de que se mantenha a constância dos retornos de escala. No entanto, a direção adotada modifica a leitura do escore e das metas de aprimoramento, o que torna essencial que se explicita conforme a natureza dos indicadores e o propósito da avaliação (Cherchye *et al.*, 2007; Van Puyenbroeck, 2018).

O BoD revela-se especialmente apropriado em contextos onde há diversas dimensões de desempenho, pois possibilita o reconhecimento de diferentes perfis de desempenho sem a imposição de uma única ponderação pré-estabelecida. Essa característica reduz a arbitrariedade associada à definição exógena dos pesos, mas não elimina as escolhas normativas envolvidas na construção do indicador composto, como a seleção das variáveis, a definição da orientação, a composição da amostra e a eventual incorporação de restrições aos pesos. Por outro lado, a flexibilidade total pode levar a pesos nulos ou extremamente pequenos, fazendo com que certos indicadores quase não contribuam para o escore de algumas DMUs (Cherchye *et al.*, 2007; Pedraja-Chaparro *et al.*, 1997).

Com o intuito de gerenciar essa flexibilidade e melhorar a interpretabilidade dos resultados, o modelo BoD pode incluir restrições nos pesos ou nas contribuições dos indicadores. Com essas restrições é possível fazer julgamentos de especialistas, estabelecer limites de contribuição mínimos ou máximos, classificar indicadores segundo sua importância relativa e garantir que dimensões que são consideradas relevantes não sejam desconsideradas implicitamente pelo modelo. É fundamental que sua aplicação mantenha um equilíbrio entre a flexibilidade que define o BoD e a adição de informações normativas que sejam justificadas, particularmente em avaliações de políticas públicas, sustentabilidade e desempenho social. Os principais tipos de restrições empregados no modelo estão sintetizados na Tabela 1.6 (Wong & Beasley, 1990; Pedraja-Chaparro *et al.*, 1997; Cherchye *et al.*, 2007; Sarrico & Dyson, 2004).

Tabela 1.6: Tipos de restrições aos pesos no modelo DEA

Tipo de Restrição	Abordagem Matemática
Restrições Absolutas	$\alpha_i \leq u_{j,i} y_{j,i} \leq \beta_i$
Restrições Ordinais	$u_{j,2} y_{j,2} \leq u_{j,3} y_{j,3} \leq u_{j,1} y_{j,1}$
Restrições Relativas	$\alpha_i \leq \frac{u_{j,i} y_{j,i}}{u_{j,k} y_{j,k}} \leq \beta_i$
Restrições Proporcionais	$\alpha_i \leq \frac{u_i y_{j,i}}{\sum_{i=1}^m u_i y_{j,i}} \leq \beta_i$
Restrições de Categorias	$\alpha \leq \frac{\sum_{i \in S_a} u_{j,i} y_{j,i}}{\sum_{i=1}^m u_{j,i} y_{j,i}} \leq \beta$

Fonte: Adaptado de Cherchye *et al.* (2007).

As restrições absolutas delimitam diretamente a contribuição de determinado indicador por meio de limites inferior (α) e superior (β). As restrições ordinais criam uma hierarquia nas contribuições dos indicadores, sendo úteis quando especialistas chegam a um consenso sobre a ordem de importância, mas não conseguem especificar valores numéricos exatos. Essas restrições condicionam a razão entre as contribuições de dois indicadores, permitindo expressar relações como a imposição de que a contribuição de um indicador se mantenha dentro de um certo intervalo em relação à contribuição de outro.

As restrições proporcionais definem a participação mínima ou máxima de cada indicador no total do indicador composto. As categorias restritivas, por outro lado, limitam a contribuição combinada de grupos de indicadores em vez de impor restrições a cada variável individualmente. Essas diversas maneiras de imposição permitem que se adicionem informações normativas ao modelo, sem que haja uma perda total da flexibilidade de ponderação que o BoD (Wong & Beasley, 1990; Cherchye *et al.*, 2007; Sarrico & Dyson, 2004) oferece.

1.1.3 Estruturas Temporais

Quando as mesmas DMUs são observadas em diferentes períodos, a dimensão temporal acrescenta uma decisão à construção do modelo: definir quais observações formarão o conjunto de referência utilizado em cada avaliação. Essa escolha não diz respeito à seleção das variáveis nem ao tratamento dos valores observados, mas à composição do conjunto de possibilidades de produção em relação a qual cada DMU será avaliada. Em dados em painel, uma unidade observada em determinado período pode ser avaliada somente em relação às unidades

daquele mesmo período, em relação às observações acumuladas até então ou em relação ao conjunto formado por todos os períodos da análise (Tulkens & Vanden Eeckaut, 1995).

Tulkens e Vanden Eeckaut (1995) sistematizam essa questão ao distinguir três estruturas de referência em análises não paramétricas com dados em painel: contemporânea, sequencial e intertemporal. As três podem utilizar as mesmas variáveis e a mesma formulação DEA, a diferença reside no conjunto de observações que participa da construção da fronteira. Como consequência, a escolha da estrutura temporal também modifica a interpretação do escore, uma vez que cada resultado permanece relativo ao conjunto de comparação definido pelo pesquisador.

Para representar essas estruturas, considere $\mathcal{T}_t$ como a tecnologia construída a partir das DMUs observadas no período t , para $t = 1, \dots, T$.

1.1.3.1 Fronteiras Temporais

I. Contemporânea

Na abordagem contemporânea, o conjunto de possibilidades de produção é construído separadamente para cada período. Assim, uma DMU observada no período t é comparada apenas com as unidades pertencentes ao mesmo período, conforme a relação apresentada a seguir:

$$\mathcal{T}_t^C = \mathcal{T}_t \quad (1.81)$$

Nessa expressão, $\mathcal{T}_t^C$ representa a tecnologia contemporânea e $\mathcal{T}_t$ o conjunto formado pelas observações do período t . Dessa forma, uma DMU observada em 2014 é avaliada apenas em relação às demais DMUs de 2014. O escore obtido expressa sua posição relativa diante da fronteira construída para aquele mesmo período (Tulkens & Vanden Eeckaut, 1995).

A principal implicação é que as fronteiras podem se deslocar ao longo do tempo. Assim, escores calculados em anos distintos não possuem, necessariamente, o mesmo referencial. Uma alteração no escore entre dois períodos pode refletir mudança da posição relativa da unidade, deslocamento da própria fronteira ou a combinação desses movimentos. Por isso, a comparação direta entre escores contemporâneos deve ser interpretada como mudança de desempenho relativo diante do conjunto observado em cada período, e não, isoladamente, como medida de progresso absoluto ou de variação de produtividade (Tulkens & Vanden Eeckaut, 1995; Färe *et al.*, 1994).

Essa questão também aparece no *Benefit-of-the-Doubt*. Walheer (2024) observa que a aplicação convencional do BoD a dados em painel utiliza informação contemporânea, fazendo com que o conjunto de referência seja atualizado a cada período. Essa estrutura é coerente quando a finalidade é comparar a posição das unidades dentro de cada ano, desde que

a análise longitudinal reconheça que a referência utilizada na construção dos escores também pode ter mudado.

II. Sequencial

Na fronteira sequencial, o conjunto de referência acumula as observações ao longo do tempo. Para avaliar uma DMU no período t , são utilizadas as observações do próprio período e de todos os períodos anteriores:

$$\mathcal{T}_t^S = \bigcup_{\tau=1}^t \mathcal{T}_\tau,$$

em que $\mathcal{T}_t^S$ representa o conjunto sequencial no período t , e o símbolo $\bigcup$ indica a reunião dos conjuntos desde o primeiro período até t . Assim, um exemplo é uma DMU observada em 2016 pode ser comparada com observações de 2014, 2015 e 2016, mas não com observações posteriores (Tulkens & Vanden Eeckaut, 1995).

III. Intertemporal

Na abordagem intertemporal, as observações de todos os períodos formam um único conjunto de referência:

$$\mathcal{T}^I = \bigcup_{t=1}^T \mathcal{T}_t \quad (1.82)$$

em que $\mathcal{T}^I$ representa o conjunto intertemporal e $\bigcup$ indica a reunião dos conjuntos de cada período, de 1 a T . Todas as observações DMU–período são avaliadas diante dessa referência, contendo nT observações em um painel com n DMUs e T períodos (Tulkens & Vanden Eeckaut, 1995).

Como a fronteira reúne todo o período, uma DMU do primeiro ano pode ser comparada com uma prática observada no último ano. Essa estrutura é adequada para avaliações retrospectivas, desde que as variáveis, as unidades analisadas e os critérios de mensuração sejam comparáveis entre os períodos (Tulkens & Vanden Eeckaut, 1995).

IV. Análise em Janelas

Em DEA essa técnica foi introduzida por Charnes *et al.* (1984), organiza períodos consecutivos em janelas móveis e trata cada observação DMU–período como uma unidade distinta. Cada janela forma seu próprio conjunto de referência, o que amplia o número de observações e permite examinar a estabilidade do desempenho ao longo do tempo.

Essa abordagem difere da fronteira intertemporal porque, à medida que a janela

avança, um período entra e outro sai, modificando o conjunto de referência. Na fronteira intertemporal, todos os períodos permanecem reunidos em um único conjunto. A largura da janela define quantos períodos consecutivos participam de cada comparação (Charnes *et al.*, 1984; Tulkens & Vanden Eeckaut, 1995).

A construção do conjunto de referência pode utilizar dados de um único período ou incorporar a dimensão temporal. Em ambos os casos, é necessário estabelecer quais variáveis irão compor a avaliação.

1.1.4 Variáveis

A definição dos *inputs* e *outputs* antecede a estimação da fronteira e determina o conteúdo e o significado da eficiência que será mensurada. Em DEA, o escore expressa desempenho relativo em relação ao conjunto de variáveis, às DMUs e à tecnologia. Por isso, alterações na especificação podem modificar a fronteira, os pesos, os *benchmarks* e a classificação das unidades eficientes e ineficientes (Golany & Roll, 1989; Cook *et al.*, 2014; Smith, 1997). No *Benefit of the Doubt* (BoD), a mesma preocupação se aplica à escolha dos indicadores que compõem o índice: como os pesos são determinados endogenamente em uma estrutura baseada em DEA, alterar o conjunto de indicadores pode modificar tanto os pesos quanto os escores compostos e sua interpretação (Cherchye *et al.*, 2007; Van Puyenbroeck, 2018).

1.1.4.1 Tipos de Variáveis

Uma mesma variável pode apresentar simultaneamente diferentes características e pertencer a mais de uma categoria ao mesmo tempo. Uma medida pode, por exemplo, ser não discricionária em relação ao controle gerencial e ao mesmo tempo ser um índice. A intenção deste segmento é esclarecer como cada atributo desempenha sua função na definição do DEA, evitando a simplificação de considerar todas as variáveis como *inputs* ou *outputs* tradicionais (Cook *et al.*, 2014; Cook & Zhu, 2007; Banker & Morey, 1986a).

I. Discricionárias e Não Discricionárias

As variáveis discricionárias são aquelas sobre as quais a DMU possui capacidade de decisão e controle, podendo alterar suas quantidades de acordo com suas escolhas de gestão. As variáveis não discricionárias, por sua vez, correspondem a fatores que afetam o desempenho da unidade, mas são determinados total ou parcialmente por condições externas e, portanto, não podem ser livremente ajustados pela DMU (Banker & Morey, 1986a).

II. Contextuais

As variáveis contextuais representam condições externas que podem influenciar o desempenho das DMUs, e não precisam ser recursos consumidos ou resultados produzidos. Por esse motivo, sua inclusão como *input* ou *output*, sem considerar o papel que desempenham no

processo avaliado, pode alterar a interpretação da tecnologia representada pelo modelo DEA. Essas variáveis podem refletir características socioeconômicas, demográficas, geográficas, regulatórias ou de mercado que condicionam o ambiente em que as unidades atuam (Daraio & Simar, 2005; Simar & Wilson, 2007).

Mesmo que variáveis contextuais e variáveis não discricionárias compartilhem a característica de não estarem completamente sob o controle da DMU, isso não significa que os dois conceitos sejam equivalentes. A não discricionabilidade destaca a inviabilidade de se adaptar um fator ao definir as metas, enquanto a variável contextual pode ficar fora da matriz principal de *inputs* e *outputs*, servindo para condicionar ou elucidar o ambiente em que se opera (Daraio & Simar, 2005; Simar & Wilson, 2007).

III. Flexíveis

As variáveis flexíveis são aquelas cuja posição no modelo não é evidente, pois podem ser interpretadas como *input* ou *output* dependendo da forma como a atividade da DMU é compreendida. Nesses casos, essa atribuição pode ser definida por um modelo classificador que estabelece endogenamente se a medida será considerada *input* ou *output* (Cook & Zhu, 2007; Toloo, 2009).

IV. Intermediárias

Em processos que têm várias etapas, uma variável pode ser o resultado de uma etapa e, ao mesmo tempo, a entrada para a próxima. Foram criados modelos em rede para que o DEA agregado não considere a organização uma “caixa-preta”. Um exemplo é o tratamento dos depósitos bancários que ao invés de categorizá-los apenas como *input* ou *output*, eles são produtos intermediários entre etapas. Estes elos devem ser identificados na etapa de seleção de variáveis (Cook *et al.*, 2010; Holod & Lewis, 2011).

Um mapeamento de processo pode ser realizado para identificar quais variáveis transitam entre as fases, estabelecendo a ligação entre as etapas do processo. A remoção de uma dessas variáveis devido a uma alta correlação pode comprometer a representação da estrutura que o modelo busca analisar (Cook *et al.*, 2010; Holod & Lewis, 2011).

V. Categóricas

Nem todas as características importantes são contínuas. Conforme mostram Banker e Morey (1986b), é possível incluir variáveis categóricas no DEA para aprimorar a definição de grupos de comparação, mesmo quando essas variáveis representam características do tipo presença/ausência. O exemplo do atendimento *drive-in* em uma rede bancária é utilizado para ilustrar que é possível que unidades com características operacionais diferentes necessitem de restrições na formação dos pares (Banker & Morey, 1986b).

Esse tratamento é diferente de codificar indiscriminadamente uma categoria como número contínuo. Quando a categoria muda a tecnologia ou o grupo de pares plausíveis, ela

passa a servir para organizar a comparação em vez de ser lida como quantidade consumida ou produzida. Por conseguinte, não se deve descartar variáveis qualitativas importantes apenas por não se ajustarem à estrutura numérica tradicional (Banker & Morey, 1986b).

Categorias binárias podem ser registradas por codificação 0–1 quando essa representação for compatível com a formulação empregada. Nesse caso, a codificação funciona apenas como representação da informação categórica, e não como uma classe metodológica distinta de variável (Banker & Morey, 1986a,b).

VI. *Proxy*

Uma variável *proxy* é um indicador observável que serve para representar indiretamente uma variável importante que está indisponível ou que não pode ser medida diretamente com precisão suficiente. No contexto da DEA, a fronteira é formada com base nos valores realmente fornecidos ao modelo e trocar uma medida ideal por uma substituta pode modificar a posição relativa das DMUs, o que, por sua vez, impacta os escores, os pesos e os *benchmarks* (Golany & Roll, 1989; Cook *et al.*, 2014; Dyson *et al.*, 2001).

Quando há múltiplas *proxies* plausíveis para um mesmo conceito, a escolha pode resultar da combinação de fundamentação teórica, evidência de estudos comparáveis e conhecimento especializado. Não é aconselhável optar automaticamente pela *proxy* que resulte no maior escore médio ou no maior número de DMUs eficientes, uma vez que isso pode privilegiar artificialmente uma especificação em detrimento da fidelidade ao conceito que se busca representar (Cook *et al.*, 2014; Smith, 1997; Nataraja & Johnson, 2011).

VII. Razões, Taxas e Índices

As razões são medidas obtidas pela divisão entre duas grandezas, como produtividade por trabalhador, gasto por aluno ou dívida em relação ao patrimônio. Embora possam facilitar comparações entre DMUs de diferentes portes, seu uso em DEA requer cuidado, pois numerador e denominador poderiam, em determinadas aplicações, representar separadamente recursos ou resultados do processo avaliado. Além disso, o uso direto de razões pode prejudicar as propriedades de convexidade do conjunto de possibilidades de produção assumidas pelos modelos DEA convencionais. Assim, antes de utilizá-las, deve-se verificar se a razão representa adequadamente o fenômeno de interesse ou se seus componentes devem ser considerados separadamente ou tratados por uma formulação específica (Hollingsworth & Smith, 2003; Emrouznejad & Amin, 2009; Olesen *et al.*, 2015; Hatami-Marbini & Toloo, 2019).

As taxas expressam a ocorrência ou participação de determinado fenômeno em relação a uma população, exposição ou outra base de referência, como taxa de ocupação, taxa de conclusão ou ocorrências por habitante. Por serem medidas relativas, também favorecem comparações entre unidades de portes distintos, mas podem ocultar diferenças entre os valores que compõem seu numerador e denominador, permitindo duas DMUs apresentarem a mesma taxa a partir de quantidades absolutas bastante diferentes. Seu uso deve, portanto, considerar o sig-

nificado da base de referência e verificar se a representação relativa é coerente com o processo avaliado e com a tecnologia definida no modelo (Hollingsworth & Smith, 2003; Emrouznejad & Amin, 2009; Olesen *et al.*, 2015; Hatami-Marbini & Toloo, 2019).

Os índices são medidas construídas para representar determinado fenômeno por meio da transformação ou combinação de uma ou mais informações. Quando resultam da agregação de diferentes indicadores, seu valor pode depender de escolhas realizadas anteriormente, como normalização, ponderação e forma de agregação. Ao incorporá-los ao DEA, é necessário considerar quais informações já estão reunidas no índice e se essas dimensões poderiam ter papéis distintos no processo analisado. O cuidado consiste em evitar que decisões tomadas durante a construção do índice sejam incorporadas ao modelo sem que sua relação com a interpretação da eficiência esteja claramente estabelecida (Saisana *et al.*, 2005; Cherchye *et al.*, 2007).

VIII. Indesejáveis

As variáveis desejáveis são *outputs* em que maiores quantidades tendem a representar melhor desempenho, enquanto as variáveis indesejáveis são *outputs* ou efeitos cuja redução é preferível no processo avaliado, caracterizando uma condição desfavorável. Em processos produtivos, essas medidas podem surgir conjuntamente aos resultados desejáveis, como ocorre com emissões de poluentes, resíduos, acidentes ou outros efeitos adversos associados à atividade da DMU. Sua classificação depende, portanto, da direção de preferência atribuída à variável e de sua relação com o processo analisado, e não apenas do fato de ela ser produzida pela unidade (Färe *et al.*, 1989; Chung *et al.*, 1997; Scheel, 2001; Seiford & Zhu, 2002).

1.1.5 Preparação dos Dados

A preparação dos dados é necessária antes da estimação, pois inconsistências, diferenças de mensuração, dados ausentes ou observações inadequadas podem alterar a fronteira, os *benchmarks* e os escores de eficiência. Esse processo envolve distinguir situações que possuem naturezas e implicações diferentes. Entre elas estão a comparabilidade das DMUs, a presença de observações atípicas e a ocorrência de valores zero, negativos ou ausentes, que demandam avaliação própria antes da estimação e de eventuais transformações das variáveis (Sarkis, 2007; Silva Portela *et al.*, 2004; Lee & Zhu, 2012; Kuosmanen, 2009).

1.1.5.1 Consistência dos Dados

Antes de utilizar o DEA, é fundamental garantir que a base de dados esteja consistente. Erros de digitação, deslocamento de casas decimais, incompatibilidade de unidades de medida, confusão entre percentuais e frações, ausência de valores representada por zero, sinais trocados, duplicidades etc. podem modificar artificialmente as relações entre as DMUs e, por conseguinte, a fronteira de eficiência (Dyson *et al.*, 2001; Golany & Roll, 1989; Sarkis, 2007).

Um exemplo básico é a confusão entre proporção e percentual. Suponha que uma taxa deva ser registrada entre 0 e 1. Se quatro DMUs apresentam valores próximos de 0,80, mas uma quinta está registrada como 80, o modelo interpreta essa última observação como cem vezes maior do que deveria. Quando a variável é convertida de proporção para percentual, a mesma transformação deve ser aplicada a todas as DMUs, a recíproca também é verdadeira (Lovell & Pastor, 1995; Dyson *et al.*, 2001; Sarkis, 2007).

Outro desafio é registrar uma informação que não está presente como zero. Um valor ausente indica que a informação não foi coletada, enquanto zero é um valor numérico que foi realmente fornecido ao modelo. Equivocar-se entre esses cenários pode modificar a posição da DMU e até mesmo a fronteira de eficiência (Sarkis, 2007; Kuosmanen, 2009; Chen *et al.*, 2014).

A consistência também se refere a garantir que as observações das DMUs sejam comparáveis em termos de definições, períodos e unidades de medida. Valores muito distintos dos outros devem ser verificados antes da estimativa. Uma observação atípica pode ser resultado de um erro de registro, mas também pode refletir uma característica legítima da DMU (Dyson *et al.*, 2001; Wilson, 1995; Banker & Chang, 2006).

1.1.5.2 Outliers

Um *outlier* é uma observação que apresenta um valor discrepante em relação ao padrão predominante dos dados daquela variável. Essa condição não implica, por si só, erro, pois a observação pode representar um caso legítimo. Por isso, *outliers* devem ser identificados e verificados antes da definição de qualquer tratamento (Hoaglin *et al.*, 1986; Frigge *et al.*, 1989).

I. Detecção Preliminar

A triagem inicial pode utilizar mínimos, máximos, quartis, histogramas, gráficos de dispersão e *boxplots*. No *boxplot*, os quartis delimitam a região central dos dados e o intervalo interquartil $IQR = Q_3 - Q_1$ permite estabelecer limites exploratórios. A regra usual sinaliza observações abaixo de $Q_1 - 1,5IQR$ ou acima de $Q_3 + 1,5IQR$. Os pontos identificados dessa forma devem ser tratados como observações que merecem investigação, e não como erros confirmados ou unidades que devam ser excluídas (Hoaglin *et al.*, 1986; Frigge *et al.*, 1989).

II. Tratamento dos Outliers

O tratamento de uma observação sinalizada deve depender da causa identificada na etapa de verificação. A condição de *outlier* não determina, por si só, qual procedimento deve ser adotado, pois valores extremos podem decorrer tanto de erros quanto de características legítimas das DMUs. Assim, as alternativas incluem corrigir o registro, excluir a unidade quando houver justificativa, manter a observação ou utilizar uma abordagem de fronteira menos sensível a

extremos.

- **Correção dos Dados:**

Quando a investigação confirma um erro de registro ou mensuração e o valor correto pode ser recuperado em uma fonte confiável, a correção deve ser realizada antes da estimação, substituindo uma informação incorreta pelo valor efetivamente observado. Procedimentos arbitrários, como truncamento, arredondamento ou substituição apenas em razão da magnitude, alteram os dados utilizados na construção da fronteira e não devem ser tratados como correções de *outliers* (Dyson *et al.*, 2001; Wilson, 1995).

- **Exclusão Justificada:**

A classificação de uma observação como *outlier* por critérios exploratórios, como sua posição além dos limites de $Q_1 - 1,5IQR$ ou $Q_3 + 1,5IQR$ em um *boxplot*, constitui um sinal para investigação e não um critério suficiente para exclusão. A retirada pode ser considerada quando a verificação identifica erro que não possa ser corrigido de forma defensável ou demonstra que a DMU não pertence à população ou tecnologia que define o conjunto de comparação. Uma observação extrema, mas válida e comparável, deve ser preservada, pois sua condição de *outlier* não justifica sua remoção (Hoaglin *et al.*, 1986; Frigge *et al.*, 1989; Wilson, 1995; Dyson *et al.*, 2001).

1.1.5.3 Zeros

Um valor zero pode ter significados diferentes e, por isso, deve ser interpretado antes de qualquer tratamento. O zero é estrutural quando indica a ausência real de determinado componente, como uma atividade que não faz parte daquela DMU. Já o zero incidental ocorre quando a variável se aplica à DMU, mas não apresenta quantidade no período analisado. O zero também pode resultar de problemas nos dados, como erros de registro, falhas de mensuração ou seu uso para codificar uma informação ausente. Nesse caso, não representa o fenômeno observado e deve ser corrigido na base. Assim, é necessário distinguir zeros legítimos de zeros decorrentes de erros antes de qualquer substituição, pois uma exigência da formulação não justifica alterar automaticamente um valor válido. Quando um zero legítimo entra em conflito com uma exigência de positividade, pode ser necessário recorrer a uma pequena constante positiva ϵ (Thompson *et al.*, 1993; Sarkis, 2007; Lee & Zhu, 2012).

I. Constante Pequena (ϵ)

Nessas situações, o zero pode ser substituído por uma pequena constante positiva ϵ para atender à exigência de positividade da formulação ou transformação adotada. A substituição não corrige o dado original, mas permite sua utilização no procedimento. Para zeros incidentais, o valor positivo apenas substitui a ocorrência nula de uma variável que continua aplicável à DMU. Nos zeros estruturais, porém, essa substituição introduz uma quantidade po-

sitiva onde havia ausência real do componente, alterando sua representação original (Thompson *et al.*, 1993; Sarkis, 2007).

- **Escolha de ε :**

O valor escolhido para ε também pode afetar os resultados, pois passa a integrar os dados utilizados na estimação. Sua definição deve considerar a escala da variável e pode ser acompanhada por análise de sensibilidade com diferentes valores da constante. O ε utilizado para substituir zeros nos dados não deve ser confundido com o infinitesimal não arquimediano presente em algumas formulações DEA para pesos ou folgas, pois possuem funções distintas (Thompson *et al.*, 1993).

$$\varepsilon = \frac{\min\{x_k : x_k > 0\}}{100} \quad (1.83)$$

A Equação 1.83 foi proposta para zeros incidentais no contexto do Super-SBM. Quando um zero resulta da translação de uma variável originalmente negativa, sua utilização como referência constitui uma adaptação metodológica, e não uma regra formulada especificamente para dados transladados (Tone, 2002).

- **Sensibilidade à Escolha de ε :**

A definição de um valor inicial não elimina a necessidade de avaliar se os resultados dependem da constante adotada. Perturbações nos dados podem modificar escores e classificações de eficiência e utiliza regiões de estabilidade para identificar intervalos nos quais determinadas propriedades da solução permanecem preservadas. A reestimação com valores alternativos de ε , mantendo inalteradas as demais especificações do modelo, permite avaliar a robustez empírica da escolha (Seiford & Zhu, 1998a,b).

Não existe uma sequência universal de valores de ε para essa comparação. Uma análise pode partir do valor inicial definido com base na escala da variável e testar ordens de grandeza menores e maiores, deixando explícito que a sequência utilizada constitui uma decisão da análise de sensibilidade, e não uma regra universal da DEA (Tone, 2002; Seiford & Zhu, 1998a,b).

- **Interpretação da Estabilidade:**

A estabilidade deve considerar os escores individuais, a classificação das DMUs como eficientes ou ineficientes, alterações na ordenação e os resultados agregados que sustentam as conclusões da análise. A ausência de mudanças para diferentes valores de ε fornece evidência de estabilidade na faixa testada, mas não estabelece invariância matemática da formulação (Seiford & Zhu, 1998a,b).

Não existe um limite percentual universal para definir quando uma alteração causada por ε é irrelevante. A interpretação deve considerar a precisão numérica da estimação e, sobretudo, se a variação da constante modifica a classificação das DMUs ou as conclusões do

estudo. Dessa forma, a escolha final de ε pode ser documentada como uma decisão submetida à análise de sensibilidade, em vez de uma constante arbitrária (Thompson *et al.*, 1993; Seiford & Zhu, 1998a,b).

1.1.5.4 Valores Negativos

Embora valores negativos e variáveis indesejáveis sejam frequentemente tratados em conjunto, eles representam problemas distintos. Um valor negativo indica apenas o sinal da observação como lucro líquido, saldo financeiro ou mudanças na produtividade e no emprego podem assumir valores negativos sem que isso represente erro conceitual. O tratamento desses valores depende do modelo DEA utilizado, pois transformações destinadas a tornar os dados positivos podem preservar ou distorcer os escores de eficiência conforme as propriedades da formulação adotada (Silva Portela *et al.*, 2004; Sharp *et al.*, 2007; Tone *et al.*, 2020; Kao, 2020).

I. Translação por Adição de Constante

A translação por adição de constante consiste em deslocar todas as observações de uma variável pela mesma quantidade, sendo utilizada, entre outras situações, para representar valores negativos em uma faixa positiva. A transformação preserva as diferenças absolutas e a ordenação original das observações, mas altera a origem da escala. Para uma variável x , observada nas DMUs $k = 1, \dots, n$, esse deslocamento é representado pela Equação 1.84 (Ali & Seiford, 1990; Halme *et al.*, 2002).

$$x_k^* = x_k + c, \quad c > -\min_k(x_k) \quad (1.84)$$

Na expressão, x_k corresponde ao valor original da variável x na DMU k , c à constante adicionada e x_k^* ao valor após a translação. A condição $c > -\min_k(x_k)$ garante valores positivos. A transformação preserva a ordem e as diferenças absolutas entre as observações, mas modifica suas proporções em relação à origem da escala. Nos modelos radiais, essa mudança pode alterar a contração dos *inputs* ou a expansão dos *outputs* necessária para alcançar a fronteira e, conseqüentemente, modificar o escore de eficiência (Ali & Seiford, 1990; Lovell & Pastor, 1995).

Uma formulação é invariante à translação quando a adição de uma constante não modifica a medida de eficiência nas dimensões para as quais essa propriedade é válida. A invariância depende da estrutura matemática da formulação, incluindo a presença da restrição de convexidade ($\sum_{k=1}^n h_k = 1$), a orientação do modelo, o conjunto de variáveis transladas e a forma de mensuração da eficiência. Por essa razão, a propriedade pode abranger todas as variáveis ou apenas determinados *inputs* ou *outputs* (Ali & Seiford, 1990; Lovell & Pastor, 1995; Pastor, 1996).

• Verificação da Invariância à Translação:

Nos modelos radiais clássicos, essas características permitem identificar previamente os casos de invariância. O CCR não apresenta garantia geral de invariância à translação. No BCC, a restrição de convexidade permite neutralizar determinados deslocamentos. Na orientação a *inputs*, a invariância dos escores ocorre para a translação dos *outputs*, na orientação a *outputs*, ocorre para a translação dos *inputs*. Quando a formulação não assegura essa propriedade, a comparação dos resultados obtidos com diferentes constantes pode ser utilizada para avaliar a sensibilidade dos escores à transformação (Ali & Seiford, 1990; Lovell & Pastor, 1995; Pastor, 1996).

• Tratamento da Sensibilidade à Translação:

Quando os escores variam em função da constante, a escolha de outro valor de c não elimina a ausência de invariância. O menor deslocamento necessário para obter valores positivos reduz a alteração numérica dos dados, mas não assegura a preservação dos escores. Nesses casos, diferentes constantes podem ser utilizadas para avaliar a sensibilidade dos resultados, enquanto a utilização da translação como transformação neutra deve ser evitada quando essa propriedade não é garantida pela formulação (Lovell & Pastor, 1995; Pastor, 1996).

1.1.5.5 Dados Ausentes

Valores faltantes indicam informações que não estão disponíveis para determinadas observações. Como os modelos DEA tradicionais se baseiam em matrizes de *inputs* e *outputs* observados, é necessário definir um tratamento quando uma célula requerida pelo modelo não possui valor conhecido, seja atuando sobre a DMU, sobre a própria variável ou sobre o valor ausente. Representar uma ausência como zero altera a interpretação da observação e não constitui um tratamento adequado para dados ausentes. Nesse contexto, as alternativas podem ser organizadas em duas estratégias principais: a exclusão, que retira da análise a DMU ou a variável associada à ausência, e o preenchimento, que mantém sua estrutura no modelo mediante a atribuição de um valor ao dado faltante (Kuosmanen, 2009; Chen *et al.*, 2014; Hu & Wang, 2026).

I. Exclusão

A exclusão consiste no tratamento dos dados ausentes por meio da retirada de elementos incompletos da base. Em DEA, esse procedimento pode ocorrer pela exclusão das DMUs que apresentam informações ausentes ou pela retirada das variáveis afetadas, alternativas que modificam, respectivamente, o conjunto de unidades analisadas ou a especificação do modelo (Hu & Wang, 2026).

• **DMUs:**

A exclusão de DMUs com informações incompletas constitui uma alternativa para o tratamento de dados ausentes sem a necessidade de estimar valores substitutos. Entretanto, esse procedimento reduz o conjunto de unidades utilizadas na comparação e pode modificar a representação da fronteira de eficiência, sobretudo quando as observações removidas exercem influência sobre sua formação. Assim, a exclusão deve considerar não apenas a quantidade de dados ausentes, mas também o efeito da retirada dessas unidades sobre os resultados do modelo DEA (Sarkis, 2007; Wilson, 1995).

• **Variáveis:**

A exclusão de uma variável com dados ausentes permite manter as DMUs que possuem informações completas nas demais dimensões, mas altera a dimensionalidade e o conteúdo representado pelo modelo DEA. Por esse motivo, o procedimento é mais adequado quando a variável não é essencial para a avaliação ou quando sua informação é capturada de forma satisfatória por outra medida. Quando a variável desempenha papel central na definição da eficiência analisada, sua retirada deve ser tratada como uma decisão de especificação do modelo e avaliada conforme os critérios de relevância e seleção e não apenas como um procedimento de tratamento de dados ausentes (Hu & Wang, 2026; Wagner & Shimshak, 2007; Cook *et al.*, 2014).

II. Preenchimento

Nos métodos de preenchimento, atribui-se ao modelo um valor estimado ou padrão para a observação que não se conhece. De forma geral, representando o valor preenchido por $\hat{x}_k$,

$$x_k^* = \hat{x}_k \quad (1.85)$$

Essas abordagens mantêm a DMU na análise, mas fazem com que o valor preenchido passe a integrar a matriz utilizada pelo modelo. Por isso, o valor atribuído deve ser compatível com as características da variável e da DMU, além de ser avaliado quanto ao seu efeito sobre a fronteira de eficiência (Chen *et al.*, 2014; Hu & Wang, 2026).

• **Valor conservador:**

O preenchimento conservador, também denominado *dummy entry* em parte da literatura, substitui o dado ausente por um valor artificial desfavorável à DMU, como valores altos para *inputs* e baixos para *outputs* ausentes, evitando que a falta de informação produza uma vantagem na avaliação da unidade. Como os resultados passam a depender do valor escolhido para o preenchimento, valores mais extremos podem penalizar a DMU e alterar os escores obti-

dos, tornando necessário informar o critério adotado e avaliar seu efeito por meio de análise de sensibilidade (Kuosmanen, 2009; Hu & Wang, 2026).

• **Média:**

A imputação pela média substitui o dado ausente pelo valor médio calculado a partir das observações disponíveis da mesma variável. O procedimento mantém a DMU na amostra, mas concentra os valores imputados em torno do centro da distribuição e reduz sua variabilidade, podendo alterar a posição relativa das unidades na análise DEA (Schafer & Graham, 2002; Hu & Wang, 2026).

A subseção a seguir aborda técnicas de transformação que possam ser necessárias ao trabalhar com as variáveis em DEA.

1.1.6 Tratamento das Variáveis

Após a definição das variáveis e a verificação da consistência, adequação e ocorrência de dados ausentes, algumas aplicações de DEA podem exigir ajustes na forma de representação das variáveis antes da estimação. Esses ajustes podem envolver indicadores indesejáveis, a classificação funcional das medidas ou transformações de escala e unidade. Como seus efeitos dependem da formulação DEA adotada, devem ser empregados apenas quando necessários e compatíveis com a interpretação da variável e com as propriedades do modelo (Lovell & Pastor, 1995; Scheel, 2001; Zanella *et al.*, 2015).

1.1.6.1 Outputs indesejáveis

Um *output* indesejável é definido pela direção de preferência, e não pelo sinal da variável ($\pm$). Nos *outputs* desejáveis, valores mais altos são preferidos, enquanto, nos indesejáveis, valores mais baixos representam o resultado desejado. Assim, emissões, resíduos, acidentes, mortes evitáveis ou abandono escolar podem assumir valores positivos e, ainda assim, serem classificados como indesejáveis. Nesses casos, podem ser empregados tratamentos indiretos que modificam a representação ou a classificação da variável antes da estimação (Scheel, 2001; Seiford & Zhu, 2002; Zanella *et al.*, 2015).

I. Subtração

A transformação linear decrescente pode ser utilizada para representar fatores indesejáveis ao inverter a direção de preferência da variável. Dessa forma, valores menores na variável original passam a corresponder a valores maiores após a transformação. Esse procedimento é classificado como uma abordagem indireta, pois a variável indesejável é modificada antes da estimação para que sua direção se torne compatível com a dos indicadores desejáveis. Como consequência, a transformação altera a escala original da variável, aspecto que deve ser considerado na escolha entre esse procedimento e modelos que incorporam os indicado-

res indesejáveis sem transformação prévia. Essa transformação pode ser expressa pela relação apresentada a seguir (Seiford & Zhu, 2002; Zanella *et al.*, 2015).

$$x_k^* = \alpha - x_k, \quad \alpha \geq \max_k \{x_k\} \quad (1.86)$$

Quando α corresponde ao maior valor observado, a maior observação de x_k é transformada em zero. Por exemplo, para $x = \{10, 20, 30\}$ e $\alpha = 30$, obtém-se $x^* = \{20, 10, 0\}$. Dessa forma, o menor valor indesejável passa a apresentar o maior valor transformado. Quando a formulação exige valores estritamente positivos, pode-se adotar $\alpha > \max(x)$. Com $\alpha = 31$, o mesmo exemplo resulta em $x^* = \{21, 11, 1\}$. A transformação preserva a linearidade e inverte a ordenação dos valores. No modelo BCC, sua aplicação pode explorar propriedades de invariância associadas à translação e à classificação das variáveis. Essa propriedade, contudo, não se estende a todas as formulações DEA, pois os efeitos da adição ou subtração de constantes dependem do modelo e da estrutura utilizada para representar a tecnologia (Lovell & Pastor, 1995; Seiford & Zhu, 2002; Zanella *et al.*, 2015).

II. Complemento

Quando a variável possui limites definidos pela própria escala, a inversão da direção de preferência pode ser realizada a partir de uma constante fixa. Para variáveis expressas em percentual, utiliza-se o limite superior igual a 100, enquanto, para variáveis expressas como proporções no intervalo $[0, 1]$, utiliza-se o limite igual a 1. As duas expressões representam a mesma transformação, diferenciando-se apenas pela escala utilizada para representar a variável (Seiford & Zhu, 2002; Zanella *et al.*, 2015).

$$p_k^* = 100 - p_k \quad \text{ou} \quad p_k^* = 1 - p_k \quad (1.87)$$

Assim, uma taxa indesejável de 25% resulta em 75% após a transformação. Se a mesma variável for expressa como proporção, 0,25 é transformado em 0,75, sem alteração da relação representada. Quando as duas medidas correspondem a categorias complementares, o valor transformado também pode receber uma interpretação direta. Uma taxa de abandono escolar de 25%, por exemplo, corresponde a uma taxa de não abandono de 75%, desde que ambas sejam definidas sobre a mesma população e o mesmo período.

A diferença em relação à transformação baseada em $\alpha = \max(x)$ está na origem da constante utilizada. No complemento, os limites 100 ou 1 pertencem à própria definição da escala e não dependem das DMUs observadas. Quando α corresponde ao maior valor da amostra, a constante depende das observações incluídas e pode mudar com a inclusão ou retirada de DMUs (Seiford & Zhu, 2002; Zanella *et al.*, 2015).

III. Inversão

A inversão consiste na transformação recíproca de uma variável estritamente positiva. O procedimento converte valores menores da variável original em valores maiores após a transformação e, por isso, pode ser utilizado como abordagem indireta para inverter a direção de preferência de fatores indesejáveis, conforme representado abaixo (Golany & Roll, 1989; Scheel, 2001; Zanella *et al.*, 2015).

$$x_k^* = \frac{1}{x_k}, \quad x_k > 0 \quad (1.88)$$

Por exemplo, para uma variável indesejável com valores $x = \{2, 5, 10\}$, a transformação recíproca resulta, respectivamente, em $x^* = \{0.5, 0.2, 0.1\}$. Nesse caso, o menor valor indesejável, $x = 2$, passa a apresentar o maior valor transformado, $x^* = 0.5$. Diferentemente da subtração, a inversão é não linear e altera não apenas a ordenação, mas também as distâncias e proporções entre as observações. Valores próximos de zero produzem valores transformados maiores, enquanto diferenças entre valores originalmente maiores são comprimidas. Além disso, a transformação não pode ser aplicada diretamente a valores iguais a zero e pode modificar a representação do conjunto de possibilidades de produção, o que exige atenção à interpretação dos resultados (Scheel, 2001; Michali *et al.*, 2026).

IV. Reclassificação como *input*

Um *output* indesejável pode ser reclassificado como *input*, fazendo com que valores menores sejam tratados como menor utilização de um recurso. Embora essa alternativa permita incorporar a direção indesejável sem transformar numericamente a variável, ela altera sua função no modelo, pois uma medida originalmente gerada pelo processo passa a ser representada como recurso utilizado pela DMU (Seiford & Zhu, 2002; Zanella *et al.*, 2015).

Um exemplo pode ser construído a partir de três fábricas que produzem bens e resíduos. Ao reclassificar os resíduos como *input*, a fábrica que gera menor quantidade passa a ser representada como aquela que utiliza menos desse fator. Essa interpretação não é equivalente à estrutura produtiva original quando o resíduo é gerado conjuntamente com os produtos desejáveis, pois o fator indesejável deixa de ser tratado como resultado do processo e passa a integrar o conjunto de recursos utilizados (Seiford & Zhu, 2002; Zanella *et al.*, 2015).

1.1.6.2 Transformação das Variáveis

Em DEA, as variáveis não precisam estar expressas na mesma escala numérica, pois os pesos endógenos se ajustam às unidades utilizadas. Ainda assim, é importante distinguir mudança de unidade, reescala multiplicativa e padronização estatística. A mudança de unidade e a reescala por uma constante positiva preservam a proporcionalidade dos dados, enquanto a padronização pelo escore z também altera a origem da variável e pode gerar valores negativos

(Lovell & Pastor, 1995; Sarkis, 2007).

Esses procedimentos não são equivalentes e seus efeitos dependem da formulação utilizada. Quando o objetivo é apenas alterar a unidade ou reduzir diferenças de magnitude, uma reescala multiplicativa positiva pode ser suficiente. Já transformações que modificam a origem ou a proporcionalidade da variável podem alterar a representação do problema e, no BoD, afetar a construção do indicador composto (Lovell & Pastor, 1995; Cherchye *et al.*, 2007; Van Puyenbroeck, 2018).

I. Reescala multiplicativa

A reescala por multiplicação envolve multiplicar ou dividir *todos* os valores de uma mesma variável por uma constante positiva. Se uma despesa está registrada em reais, por exemplo, ela pode ser convertida para milhões de reais por

$$x'_{ik} = \frac{x_{ik}}{1.000.000} \quad (1.89)$$

Uma mudança de unidade altera apenas a forma de expressar a variável, sem modificar seu conteúdo. Uma despesa de R\$ 2.000.000, por exemplo, pode ser registrada como 2 quando a unidade passa de reais para milhões de reais. Esse tipo de transformação corresponde à multiplicação da variável por uma constante positiva (Lovell & Pastor, 1995; Cooper *et al.*, 2007).

Nos modelos DEA invariantes às unidades de medida, essa alteração não modifica os escores de eficiência, pois a mudança de escala é compensada pelos pesos do modelo. Por essa razão, variáveis expressas em unidades ou escalas numéricas diferentes podem ser utilizadas conjuntamente sem exigir uma reescala prévia apenas para igualar seus valores numéricos (Lovell & Pastor, 1995; Cooper *et al.*, 2007).

II. Normalização pelo valor máximo

A normalização pelo valor máximo consiste em dividir todas as observações de uma variável pelo maior valor registrado. Quando a variável é não negativa e seu valor máximo é positivo, o procedimento corresponde a uma reescala multiplicativa por uma constante positiva (Lovell & Pastor, 1995; Cooper *et al.*, 2007).

$$x_k^* = \frac{x_k}{\max_k(x_k)} \quad (1.90)$$

Para $x = \{20, 50, 100\}$, por exemplo, obtém-se $x^* = \{0.20, 0.50, 1\}$. Como todos os valores são multiplicados pela mesma constante $1/\max(x)$, a proporcionalidade entre as observações é preservada. Nos modelos DEA invariantes às unidades de medida, essa reescala não altera os escores de eficiência (Lovell & Pastor, 1995; Cooper *et al.*, 2007).

III. Normalização pela média

A normalização pela média consiste em dividir todas as observações de uma variável por sua própria média. O procedimento expressa cada valor em relação à média original da variável e, quando $\bar{x} > 0$, corresponde a uma reescala multiplicativa por uma constante positiva (Sarkis, 2007; Lovell & Pastor, 1995).

$$x_k^* = \frac{x_k}{\bar{x}} \quad (1.91)$$

Após a transformação, $x_k^* = 1$ representa um valor igual à média, enquanto $x_k^* = 1,20$ e $x_k^* = 0,80$ correspondem, respectivamente, a 120% e 80% da média. Diferentemente da padronização pelo escore z , não ocorre subtração da média e, portanto, a origem da variável não é deslocada. Nos modelos DEA invariantes às unidades de medida, a divisão por uma média positiva preserva os escores de eficiência por corresponder à multiplicação de toda a variável pela mesma constante positiva (Sarkis, 2007; Lovell & Pastor, 1995; Cooper *et al.*, 2007).

A condição $\bar{x} > 0$ é necessária para essa interpretação. Quando $\bar{x} = 0$, a transformação não é definida, enquanto uma média negativa produz um fator de reescala negativo e deixa de atender à condição de multiplicação por constante positiva. Por isso, o procedimento deve ser compatível com o domínio da variável e não deve ser confundido com a padronização pelo escore z (Sarkis, 2007; Lovell & Pastor, 1995).

IV. Escore z

A padronização pelo escore z expressa cada observação em termos de sua distância em relação à média, medida em desvios-padrão. Para uma variável original x , o escore padronizado é obtido pela expressão a seguir.

$$z_k = \frac{x_k - \bar{x}}{s_x} \quad (1.92)$$

Nessa transformação, $\bar{x}$ representa a média e s_x o desvio-padrão da variável original. O valor $z_k = 0$ corresponde à média. Diferentemente de uma reescala multiplicativa simples, o escore z altera a origem e a escala da variável, pois subtrai a média e, em seguida, divide pelo desvio-padrão. Como a translação modifica as relações entre as observações, a invariância do modelo a mudanças de unidade não garante a preservação dos escores de eficiência.

A padronização também gera valores negativos para observações abaixo da média, mesmo quando todos os dados originais são positivos. Como as formulações DEA clássicas são usualmente definidas para dados não negativos, a aplicação direta do escore z pode introduzir valores incompatíveis com essa condição de não negatividade. Formulações específicas foram desenvolvidas para situações em que valores negativos precisam ser incorporados (Silva Portela *et al.*, 2004; Tone *et al.*, 2020).

1.2 Clusterização

Também conhecida como análise de conglomerados ou clusterização, a análise de agrupamento é uma técnica de aprendizado de máquina não supervisionado. Seu objetivo é agrupar observações semelhantes em conjuntos internamente homogêneos e, ao mesmo tempo, distintos entre si. Os requisitos iniciais consistem em escolher as variáveis quantitativas, a medida de dissimilaridade e o método de agrupamento (Han *et al.*, 2011). A Tabela 1.7 mostra algumas medidas de dissimilaridade para variáveis quantitativas métricas.

Tabela 1.7: Expressões das medidas de distância

Medida de Distância	Expressão
Euclidiana	$d_{pq} = \sqrt{\sum_{j=1}^k (X_{jp} - X_{jq})^2}$
Quadrática euclidiana	$d_{pq} = \sum_{j=1}^k (X_{jp} - X_{jq})^2$
Minkowski	$d_{pq} = \left[\sum_{j=1}^k X_{jp} - X_{jq} ^m \right]^{\frac{1}{m}}$
Manhattan	$d_{pq} = \sum_{j=1}^k X_{jp} - X_{jq} $
Chebychev	$d_{pq} = \max X_{jp} - X_{jq} $
Canberra	$d_{pq} = \sum_{j=1}^k \frac{ X_{jp} - X_{jq} }{ X_{jp} + X_{jq} }$

Fonte: Adaptado de Fávero e Belfiore (2022).

A primeira distância que aparece na Tabela 1.7 é a Euclidiana, a qual é um conceito fundamental da geometria e a forma mais intuitiva de medir a distância entre dois pontos de coordenadas X_p e X_q presentes em um espaço n -dimensional, considerando as j variáveis, ou seja, é uma linha reta, também conhecida como Norma L^2 , entre os dois pontos, que são as linhas p e q do banco de dados mencionadas (Mussabayev, 2024).

A única diferença entre a distância euclidiana e a distância euclidiana quadrática é a raiz quadrada. Uma vez que essa operação não muda a ordem dos valores não negativos, ambas preservam a mesma ordem nas distâncias entre as observações. Contudo, o cálculo da distância quadrática pode ter um custo computacional menor por não precisar realizar essa operação (Mussabayev, 2024).

A distância Euclidiana é uma derivação da distância de Minkowski para $m=2$, tendo em vista que a Minkowski é a generalização que serve para outras, como a distância de Manhattan, ou *City Block*, para $m=1$, cuja principal característica é sua movimentação similar a de


quarteirões de uma cidade, enquanto a distância de Chebyshev, também conhecida como distância máxima, L_{max} ou L_{∞} é outra generalização de Minkowski, adotando $m \rightarrow \infty$, diferindo das demais medidas por apenas considerar a maior distância entre todas as variáveis j em estudo (Han *et al.*, 2011).

A distância de Canberra, por sua vez, é calculada pela soma das diferenças absolutas normalizadas entre os componentes dos vetores. Cada diferença é dividida pela soma dos valores absolutos correspondentes, reduzindo a influência da magnitude das variáveis. Quando as variáveis são expressas em unidades de medida diferentes, pode-se realizar previamente sua padronização, por exemplo, por meio do escore z (Blanco-Mallo *et al.*, 2023; Fávero & Belfiore, 2022).

Definidas as variáveis e a medida de distância, os métodos de agrupamento podem ser classificados em hierárquicos e não hierárquicos.

1.2.1 Clusters Hierárquicos




A característica dos métodos hierárquicos é que os agrupamentos são definidos de forma progressiva à medida que o processo avança. Eles podem ser considerados aglomerativos ou divisivos. Nos métodos aglomerativos, cada observação começa como um grupo individual, e os grupos que estão mais próximos uns dos outros são combinados até que reste um único grupo. Em procedimentos de divisão, inicia-se com um grupo que inclui todas as observações e, em seguida, esse grupo é subdividido em grupos menores (Figura 1.3) (Fávero & Belfiore, 2022).



Fonte: Kaufman e Rousseeuw (2009).

Nos métodos hierárquicos, a definição do esquema de aglomeração é seguida pela escolha do método de encadeamento (linkage), que estabelece como será calculada a distância entre os clusters a cada iteração, além da medida de distância escolhida. Alguns dos métodos mais utilizados são o *Single Linkage*, *Complete Linkage* e o *Average Linkage*, os quais estão representados na Tabela 1.8.

Tabela 1.8: Métodos de Encadeamento.


Método de Encadeamento	Ilustração	Distância	Generalização
Único		d_{23}	$\min\{d_{MW}, d_{NW}\}$
Completo		d_{15}	$\max\{d_{MW}, d_{NW}\}$
Médio		$\frac{d_{13} + \dots + d_{25}}{6}$	$\frac{\sum_{p=1}^M \sum_{q=1}^N d_{pq}}{ M \cdot N }$

Fonte: Adaptado de Fávero e Belfiore (2022) e Emmendorfer e Paula Canuto (2021).

O método de encadeamento único, ou *Single Linkage*, também chamado de vizinho mais próximo, leva em conta a menor distância entre os membros dos clusters M e N. No exemplo da Tabela 1.8, essa distância é representada por d_{23} . O *Complete Linkage*, denominado método de encadeamento completo ou *furthest neighbor* (vizinho mais distante), considera a maior distância entre os elementos dos dois conjuntos, representada por d_{15} . Finalmente, o *Average Linkage*, conhecido como método de encadeamento médio ou entre grupos (*between groups*), calcula a distância média entre todos os pares possíveis de elementos de M e N (Fávero & Belfiore, 2022).

Os métodos de agrupamento hierárquico podem ser ilustrados por um diagrama em forma de árvore chamado dendrograma. Essa representação permite realizar um “corte” vertical em seu eixo de distância, de modo que a quantidade de ramos interceptados indique o número de clusters formados naquele ponto, conforme ilustra a Figura 1.4 (Albert & Tullis, 2022).

Figura 1.4: Dendrograma.



Fonte: Albert e Tullis (2022).

Na Figura 1.4, o corte vertical realizado próximo ao valor 11 do eixo de distância intercepta quatro ramos do diagrama, formando quatro clusters, diferenciados por cores por Albert e Tullis (2022). O primeiro contém apenas bananas, o segundo, tomates, o terceiro, ameixas, cerejas, uvas e morangos e o quarto, peras, pêssegos, laranjas e maçãs. Caso o corte fosse realizado em uma distância igual a 1, o número de clusters seria igual ao número de observações ($K = n$), não ocorrendo agrupamento entre elas. Outra maneira de agrupar observações semelhantes consiste na utilização de técnicas não hierárquicas.

1.2.2 Clusters Não-Hierárquicos

Diferentemente dos métodos hierárquicos, que produzem uma estrutura de agrupamentos aninhados, os métodos particionais geralmente requerem que o número de clusters (K) seja definido *a priori* e realizam uma partição direta dos dados. No processo, os elementos são movidos de um grupo para outro, um de cada vez, até que no grupo de origem não haja mais elementos cuja realocação leve a uma melhoria na função objetivo ou até que a melhoria se torne insignificante (Jain & Dubes, 1988; Jain *et al.*, 1999). Dentre os algoritmos dessa classe, o *k-means* se destaca, sendo o mais utilizado devido à sua simplicidade conceitual e eficiência computacional, especialmente com dados que possuem variáveis numéricas (Jain, 2010; Kaufman & Rousseeuw, 2009).

Jain *et al.* (1999) apresentam o *k-means* como um algoritmo de agrupamento baseado na minimização do erro quadrático. Nesse sentido, o que chamamos de “erro” não é uma imperfeição na obtenção ou na aferição dos dados, mas sim o desvio de cada ponto em relação

ao centro do cluster ao qual foi atribuído, calculado pela distância ao quadrado. Esse ponto, chamado de centroide, que é a média dos elementos que pertencem ao cluster, atua como um ponto representativo do grupo.

O método busca, portanto, particionar os dados em K clusters, minimizando a soma das distâncias quadráticas entre cada elemento e o centroide do grupo ao qual pertence (MacQueen, 1967; Hartigan & Wong, 1979; Jain *et al.*, 1999). Quanto menor for essa soma, menor será a dispersão interna e mais compactos serão os clusters formados (Jain *et al.*, 1999).

Considera-se um conjunto de dados $X = \{x_i, i = 1, \dots, n\}$, particionado em K clusters, $C = \{C_k, k = 1, \dots, K\}$, em que $\bar{x}_k$ representa o centroide do cluster C_k . A função objetivo do método é expressa por:


$$J(C) = \sum_{k=1}^K \sum_{x_i \in C_k} \|x_i - \bar{x}_k\|^2 \quad (1.93)$$

Na Equação 1.93, $\|x_i - \bar{x}_k\|^2$ representa a distância quadrática entre o elemento x_i e o centroide $\bar{x}_k$. O somatório interno calcula a dispersão dos elementos de cada cluster, enquanto o somatório externo agrega os resultados dos K clusters que compõem a partição (Hartigan & Wong, 1979; Jain *et al.*, 1999).

O procedimento de clusterização pelo *k-means*, ilustrado na Figura 1.5, pode ser resumido em quatro etapas, de acordo com Fachieri e Suaide (2025):

1. Definir previamente o número de clusters (K), com base em um critério de seleção adequado;
2. Atribuir a cada ponto o cluster com o centro mais próximo;
3. Atualizar os centros dos clusters como a média dos pontos pertencentes a cada cluster;
4. Repetir as etapas 2 e 3 até que os centros dos clusters não apresentem alterações significativas ou até atingir um critério de convergência.

Figura 1.5: Clusterização: *k-means*.



Fonte: Jain (2010).

Na fase *a*, os dados são posicionados no plano. No estágio *b*, começam a surgir os primeiros grupos em torno dos centroides iniciais (*seed points*), destacados pelos círculos. Em seguida, as etapas de atribuição das observações e atualização dos centroides são repetidas até que a configuração final da etapa *e* seja alcançada.


Conforme mencionado na primeira etapa, o número de clusters (K) pode ser definido com base em diferentes critérios. Conforme Marutho *et al.* (2018) e Rousseeuw (1987), o método do cotovelo e o coeficiente de silhueta são duas técnicas para determinar o número de clusters. Tibshirani *et al.* (2001) apresentam o *gap statistic* e Fávero e Belfiore (2022) indicam que é viável usar métodos hierárquicos antes de aplicar os não hierárquicos para ter uma estimativa do número de grupos.

1.2.3 Método do Cotovelo (Elbow)

O método do cotovelo é uma técnica visual empregada para estimar o número de agrupamentos (K) em algoritmos de clusterização, como o *k-means* (Umargono *et al.*, 2020). Sua premissa consiste na utilização da Soma dos Erros Quadráticos (*Sum of Squared Errors* – SSE) como métrica, calculada a partir das distâncias quadráticas entre as observações de cada cluster e seu respectivo centroide (Yuan & Yang, 2019).

Conforme ilustrado na Figura 1.6, à medida que o número de clusters (K) se aproxima da quantidade de partições subjacentes ao conjunto de dados, o valor da SSE apresenta redução acentuada. Quando o valor de K ultrapassa esse ponto, a SSE continua diminuindo, porém em ritmo mais lento (Yuan & Yang, 2019).

Figura 1.6: Método do Cotovelo.



Fonte: Yuan e Yang (2019).

No gráfico, a diminuição da SSE é mais acentuada até que se torna um ponto de inflexão semelhante a um “cotovelo”. Este aspecto se refere à quantidade de clusters que devem

ser considerados no modelo (Umargono *et al.*, 2020; Yuan & Yang, 2019).

A análise visual é uma limitação teórica central desse método, pois se o ponto de inflexão não for claro na relação entre o valor de K e a diminuição da distância, não será possível determinar com precisão o número de clusters (Yuan & Yang, 2019).

1.3 Mapeamento de Trabalhos Relacionados

Foram conduzidos dois levantamentos para identificar trabalhos que conectam o DEA aos Objetivos de Desenvolvimento Sustentável. O primeiro, focado na produção acadêmica, foi realizado através de uma Revisão Bibliográfica Sistemática (RBS) de artigos científicos. O segundo, de natureza governamental, foi um levantamento quantitativo de documentos políticos disponíveis na plataforma Overton ¹.

1.3.1 Perspectiva Acadêmica: Artigos Científicos

1.3.1.1 Revisão Bibliográfica Sistemática (RBS)

Para identificar quais modelos de Análise Envoltória de Dados são mais frequentemente empregados em pesquisas sobre sustentabilidade e os Objetivos de Desenvolvimento Sustentável, foi realizada uma Revisão Bibliográfica Sistemática (RBS) no Portal de Periódicos da CAPES. As investigações ocorreram entre dezembro de 2025 e janeiro de 2026, restritas a artigos científicos publicados em inglês, que passaram por revisão por pares, e que corresponderam exatamente aos termos de pesquisa.

Foram empregadas duas táticas de busca: “DEA AND Sustainability AND SDG” e “DEA AND SDG”, que resultaram, respectivamente, em 56 e 92 registros, somando um total de 148 resultados preliminares. Após uma primeira checagem da conformidade dos registros com os termos pesquisados, 47 artigos da primeira estratégia e 72 da segunda estratégia foram mantidos, resultando em 119 registros nas duas planilhas de busca.

Em seguida, as duas estratégias foram consolidadas. Em comparação aos títulos, foram localizados 40 registros duplicados entre as buscas, contando variações de grafia, pontuação ou abreviação nos títulos. Depois de eliminar as duplicatas, 79 artigos únicos ficaram para a triagem.

A seleção dos estudos foi realizada em duas etapas sucessivas. Primeiro, foram lidos os títulos, eliminando os registros que eram claramente incompatíveis com o propósito da revisão. Em seguida, os resumos dos registros remanescentes foram analisados para identificar a utilização real de modelos de Análise Envoltória de Dados e verificar se havia relação com a sustentabilidade e/ou com os Objetivos de Desenvolvimento Sustentável.

¹<https://app.overton.io/>

Os estudos que não aplicaram DEA, que não tinham uma relação significativa com a sustentabilidade ou os ODS, que estavam apenas citados de forma formal ou que não forneciam informações suficientes para identificar e classificar a metodologia adotada foram excluídos. Foram excluídos editoriais e estudos secundários que não trouxessem conteúdo metodológico relevante para alcançar os objetivos da revisão. Depois de aplicar esses critérios, 25 registros foram excluídos, deixando um total de 54 artigos na base final.

Como os motivos específicos de exclusão não foram documentados durante a busca original, sua categorização foi reconstituída posteriormente com base nos títulos, resumos e metadados disponíveis nas planilhas. Essa reconstrução torna os critérios de elegibilidade mais transparentes, mas não substitui o registro contemporâneo das decisões de exclusão e, por isso, constitui uma limitação de rastreabilidade do processo de revisão.

Para os 54 artigos selecionados, foram coletadas informações sobre o ano de publicação, autores, periódico, contexto de aplicação, tipo de orientação do modelo, tipo de tecnologia de retornos à escala, modelo DEA utilizado, variáveis e palavras-chave. A Tabela 1.9 apresenta uma síntese dos contextos e das principais características metodológicas identificadas.

Tabela 1.9: RBS: Modelos DEA e Sustentabilidade

Trabalho	Contexto	Orientação	CRS	VRS	SBM	Outros
Gan <i>et al.</i> (2022)	Rural	Sem orientação			×	
Gennitsaris e Sofianopoulou (2024)	Energia	Output		×		
Chen <i>et al.</i> (2019)	Transporte	Input		×		
Lozano e Borrego-Marin (2024)	Uso da Água	Sem orientação				NDEA
Xia <i>et al.</i> (2022)	Turismo	Sem orientação			×	
Hatami-Marbini <i>et al.</i> (2024)	Transporte	N/A				Múltiplos
Wang <i>et al.</i> (2024c)	Rural	Output				NDEA
Maia <i>et al.</i> (2022)	Energia	Input	×			
Ning <i>et al.</i> (2018)	Rural	Sem orientação			×	
Issever Grochová e Litzman (2021)	Avaliação SDG	Input		×		
Li <i>et al.</i> (2021)	Energia	Input				VO TFEE
Singpai e Wu (2020)	Avaliação SDG	Output		×		
Rana <i>et al.</i> (2022)	Economia	Output		×		
Li <i>et al.</i> (2024)	Rural	Sem orientação				Super-SBM
Łacka e Brzezicki (2022)	Eco-eficiência	Output				DNSBM
Mohammadi <i>et al.</i> (2022)	Eco-eficiência	Sem orientação			×	

Continua na próxima página...

Tabela 1.9 – RBS: Modelos DEA e Sustentabilidade

Trabalho	Contexto	Orientação	CRS	VRS	SBM	Outros
Campoli <i>et al.</i> (2024)	Energia	Sem orientação			×	
Xue (2022)	Energia	N/A				Malmquist
Yang <i>et al.</i> (2024)	Eco-eficiência	N/A				DDF
Rodríguez-Cornejo <i>et al.</i> (2024)	Clima	Output				DNSBM
Jiakui <i>et al.</i> (2023)	Economia Verde	Sem orientação				DEA-DDF
Lin <i>et al.</i> (2025)	Avaliação SDG	Sem orientação			×	
Zhang <i>et al.</i> (2024)	Clima	Sem orientação				Super-SBM
Malešević Perović <i>et al.</i> (2025)	Avaliação SDG	Output	×			
Kourtiti <i>et al.</i> (2021)	Cidades	N/A				SE-DEA
Priyadarshini e Abhilash (2023)	Alimentar	Input	×			
Lin e Lu (2024)	Ressuprimento	Sem orientação				IDEA
Liu <i>et al.</i> (2023)	Energia	N/A				RAM-DEA
Suárez-Fernández <i>et al.</i> (2024)	Energia	Output		×		
Wang <i>et al.</i> (2024b)	Rural	N/A				DSBM
Ahmadabadi <i>et al.</i> (2024)	Sustentabilidade	Múltiplos				DFM
Özdemir <i>et al.</i> (2021)	Saúde	Output		×		
Feng <i>et al.</i> (2022)	Industrial	Sem orientação				DDF
Maricuț <i>et al.</i> (2023)	Cidades	Input		×		
Malešević Perović e Mihaljević Kosor (2020)	Avaliação de SDGs	Output				N/A
Koçak <i>et al.</i> (2019)	Educação	Output				NDEA
Li <i>et al.</i> (2023a)	Cidades	Sem orientação			×	
Georgiadis <i>et al.</i> (2024)	Transporte	Output	×			
Wang <i>et al.</i> (2024d)	Energia	Sem orientação				SBM-UN
Rusydiana <i>et al.</i> (2021)	Energia	Output		×		
Wang <i>et al.</i> (2024a)	Cidades	Sem orientação			×	
Osman e Zabliith (2021)	Governo	Múltiplos				Múltiplos
Fumbwe <i>et al.</i> (2021)	Saúde	Input		×		
Thore (2022)	Saúde	N/A		×		
Yang <i>et al.</i> (2025)	Energia	N/A				DEA-DDF

Continua na próxima página...

Tabela 1.9 – RBS: Modelos DEA e Sustentabilidade

Trabalho	Contexto	Orientação	CRS	VRS	SBM	Outros
Arhin e Asante-Darko (2023)	Saúde	Output		×		
Er-Rays e M'dioud (2025)	Saúde	Input				Múltiplos
Liu <i>et al.</i> (2024)	Industrial	N/A				Múltiplos
Huong <i>et al.</i> (2021)	Industrial	Input				Malmquist
Sakr <i>et al.</i> (2024)	Foreign Aid	Múltiplos				Múltiplos
Matulová (2023)	Educação	Múltiplos				Múltiplos
Li <i>et al.</i> (2023b)	Rural	Sem orientação				Super-SBM
Aldieri <i>et al.</i> (2024)	Energia	N/A				DEA-Tobit
Dai <i>et al.</i> (2024)	Cidades	Sem orientação				DTDEA


Fonte: Elaboração própria.

Entre as tecnologias de produção registradas na Tabela 1.9, a coluna VRS ou BCC apresentou 12 ocorrências, enquanto a coluna CRS ou CCR apresentou quatro. A coluna SBM foi assinalada em oito estudos. Além dessas ocorrências, a coluna “Outros” reúne extensões relacionadas à família SBM, como Super-SBM, DNSBM, DSBM e SBM-UN. Como um mesmo artigo pode utilizar mais de um modelo, tecnologia ou orientação, essas contagens não constituem categorias mutuamente excludentes. Em tais situações, a classificação “Múltiplos” foi empregada. Quando o artigo não trouxe informações suficientes para determinar a orientação ou o modelo utilizado, foi usada a designação *Not Available* (N/A).

A Tabela 1.9 apresenta uma síntese dos modelos identificados e de seus respectivos contextos de aplicação. As palavras-chave dos artigos também foram coletadas, além dessas informações. Após a padronização de termos equivalentes e a retirada de expressões com baixa frequência ou pouca contribuição temática, foram selecionadas 24 palavras-chave para a formação dos agrupamentos representados na Figura 1.7.

Os contextos que mais apareceram foram Energia, com 11 pesquisas, Rural, com seis, e Cidades, com cinco. Duas pesquisas foram categorizadas diretamente no âmbito da Educação. Isso evidencia a escassa presença de aplicações educacionais no conjunto analisado e ressalta a relevância de investigar a utilização da DEA e de indicadores compostos na avaliação do ODS 4.

Figura 1.7: Clusters RBS.



Fonte: Elaboração própria.

A Figura 1.7 apresenta outra organização visual dos resultados da RBS, evidenciando relações de proximidade entre os agrupamentos temáticos. Em particular, os termos que mais se destacam são sustentabilidade, DEA, indicadores compostos, segurança e eficiência energética. A Tabela 1.10 sintetiza os seis principais clusters e seus respectivos contextos, com apoio de inteligência artificial (IA).

Tabela 1.10: Clusters Temáticos e Contextos

Cluster	Tema Central	Contexto
1	Ecoeficiência energética baseada em LCA	Estudos focados na avaliação de ecoeficiência e emissões de carbono ao longo do ciclo de vida, com aplicações em sistemas energéticos, cadeias globais de suprimentos e alternativas tecnológicas.
2	Eficiência de serviços públicos orientada aos ODS	Desempenho sustentável em serviços públicos, como saúde, educação, transporte e agricultura, alinhadas aos ODS 2030. Utilizam DEA combinado com regressão Tobit, índices compostos e análises institucionais para apoiar políticas públicas.
3	Desempenho urbano baseado em inovação	Foco no desempenho de cidades e países sob a ótica da inovação, <i>smart cities</i> e segurança urbana. Empregam modelos avançados de DEA (super-eficiência, DNSBM, divisional Malmquist) para capturar dinâmicas sistêmicas e estratégias operacionais.
4	Ecoeficiência universitária e ODS ambientais	Estudos voltados à avaliação da eficiência ambiental de instituições de ensino superior e setores intensivos em energia, alinhados especialmente aos ODS 12 e 13. Aplicam DEA-Tobit, indicadores compostos e análises temporais para mensurar eco-inovação e desempenho ambiental.
5	Eficiência verde agroindustrial	Pesquisas que mensuram eficiência no uso de energia, água e recursos naturais em sistemas agroalimentares e industriais. Utilizam modelos como DDF-DEA para lidar com outputs indesejáveis, integrando economia circular, inovação verde, inteligência artificial e financiamento verde.
6	Eficiência do transporte urbano equitativo	Estudos focados na avaliação de desempenho de sistemas de transporte urbano, com ênfase em acessibilidade, equidade social e uso do solo. Aplicam DEA e benchmarking para apoiar o planejamento urbano e a formulação de políticas públicas locais.

Fonte: Elaborado com o auxílio de IA.

Embora os clusters apresentem proximidade temática, cada um possui uma ênfase específica. O Cluster 1 foca na ecoeficiência energética, especialmente em estudos que utilizam a *life cycle assessment* (LCA) para avaliar as emissões de carbono nos sistemas de energia. O Cluster 2 compila pesquisas que tratam de serviços públicos em consonância com a Agenda 2030, abarcando desde aplicações de aprendizado de máquina até o uso de indicadores compostos. O Cluster 3 foca no desempenho das cidades e no conceito de cidades inteligentes, ao passo que o Cluster 6 dá ênfase à mobilidade urbana, acessibilidade e equidade social. O Cluster 4 agrupa pesquisas que envolvem universidades e sistemas de avaliação, principalmente em relação aos ODS 12 e 13, que tratam do consumo e da produção responsáveis e da luta contra as mudanças climáticas. Por último, o Cluster 5 enfoca o uso responsável de recursos naturais na indústria e na agroindústria.

Para concluir a RBS, também foram levantadas as variáveis utilizadas em cada ar-

tigo, classificadas em *inputs*, *outputs* desejados e *outputs* indesejados, conforme apresentado na Tabela 1.11. Foram encontradas quatro categorias entre os *inputs*: Capital Humano, Recursos Econômicos, Recursos Naturais/Energia e Infraestrutura, com 26, 24, 24 e 12 ocorrências, respectivamente. Aqueles *outputs* que, ao aumentarem, favorecem o modelo, foram reunidos sob os rótulos Desempenho Econômico, Bem-estar Social e Inovação e Conhecimento, com 28, 12 e 4 ocorrências, respectivamente.

Os *outputs* indesejados correspondem a resultados cujo aumento representa uma condição desfavorável e que, portanto, devem ser reduzidos. As categorias identificadas foram: Emissões Atmosféricas (20 ocorrências), Resíduos e Efluentes (8), Ineficiência de Recursos (7) e Impactos Socioeconômicos (4). A primeira reúne variáveis como gases de efeito estufa, poluição do ar e emissões de CO_2 . A última inclui pobreza e desemprego. A escassez dos impactos socioeconômicos indica que essas dimensões foram menos contempladas entre os estudos selecionados pela RBS.

Tabela 1.11: Classificação de variáveis: inputs e outputs

Classificação	Categoria conceitual	Freq.	Exemplos de variáveis comuns
Input	Capital humano	26	Número de empregados, mão de obra, população ativa
	Recursos econômicos	24	Capital fixo, investimento em P&D, custos operacionais
	Recursos naturais/energia	24	Consumo de energia, água captada, uso da terra
	Infraestrutura	12	Transporte, áreas urbanas
Output desejado	Desempenho econômico	28	PIB, valor adicionado bruto (VAB), receita
	Bem-estar social	12	Saúde pública, saneamento, equidade
	Inovação e conhecimento	4	Patentes, citações acadêmicas, documentos
Output indesejado	Emissões atmosféricas	20	CO_2 , gases de efeito estufa (GEE), poluição do ar
	Resíduos e efluentes	8	Esgoto sanitário, resíduos sólidos, águas residuais
	Ineficiência de recursos	7	Intensidade energética, perdas no sistema
	Impactos socioeconômicos	4	Desemprego, pobreza

Fonte: Elaboração própria.


1.3.2 Perspectiva Governamental: Documentos Políticos

Como complemento à RBS, realizou-se um levantamento de documentos políticos na plataforma Overton que citam pesquisas relacionadas à DEA. A Overton é um banco de dados sobre políticas públicas e literatura cinzenta, criado para ajudar a avaliar o impacto da pesquisa nas políticas. Os dados que vinculam os artigos acadêmicos às instituições são provenientes da plataforma OpenAlex, que não informa a afiliação de todos os registros. De acordo com a própria plataforma, buscas por afiliação podem parar de recuperar até 20% da produção de uma instituição.

Foi utilizada a expressão "*Data Envelopment Analysis*" como palavra-chave, com um filtro para que os resultados fossem restritos a documentos governamentais, o que gerou 884 ocorrências. Após aplicar os critérios de publicação a partir de 2015, origem no setor público e associação a pelo menos um ODS, 545 documentos permaneceram.

Após a verificação manual de duplicatas e de títulos com pequenas variações de grafia ou capitalização, permaneceram 399 documentos governamentais, cuja distribuição geográfica é apresentada na Figura 1.8.


Figura 1.8: Overton: Políticas Governamentais em DEA



Fonte: Elaboração própria.

A maior concentração de documentos ocorre na Europa, com 223 registros, seguida pelas Américas com 78; Ásia, com 65; Oceania, com 19; e África, com 14. A plataforma Overton indica quais ODS estão relacionados a cada documento. Essas ocorrências foram contabilizadas para identificar os objetivos mais frequentes no conjunto analisado, conforme ilustra a Figura 1.9.

Figura 1.9: Overton: Aplicações de DEA nas políticas governamentais




Fonte: Elaboração própria.

Foram encontradas 494 ligações entre os documentos pesquisados e os ODS. Conforme apresentado na Figura 1.9, os objetivos mais frequentes foram o ODS 8 – Trabalho Decente e Crescimento Econômico –, o ODS 9 – Indústria, Inovação e Infraestrutura – e o ODS 3 – Saúde e Bem-estar –, com 94, 85 e 62 menções, respectivamente. Os ODS que apareceram com menor frequência foram o ODS 5 – Igualdade de Gênero –, que teve 2 menções, o ODS 14 – Vida na Água – com 3, e o ODS 15 – Vida Terrestre –, que teve 5.

A distribuição dos ODS também pode ser examinada separadamente para cada continente, conforme apresentado na Figura 1.10.

Figura 1.10: Overton: distribuição dos ODS por continente



Fonte: Elaboração própria.

A Figura 1.10 apresenta a distribuição percentual das associações entre os documentos governamentais relacionados à DEA e os ODS em cada continente. Cada percentual indica a participação de determinado ODS no total de associações com os ODS registradas naquele continente, permitindo comparar a composição relativa dessas ocorrências entre os continentes.

Em África, observa-se maior concentração de associações no ODS 3 (43%), relacionado à Saúde e Bem-estar, enquanto a Europa apresenta, em números absolutos, 24 associações com esse objetivo. O ODS 9 representa 21% das associações africanas, e o ODS 8 corresponde a 14%.

Na América, a distribuição entre o ODS 3 (13%), o ODS 4 (10%), o ODS 7 (12%), o ODS 8 (13%) e o ODS 9 (14%) é mais equilibrada. Em comparação com a África, não há concentração equivalente em um único objetivo, e também aparecem associações com educação de qualidade e energia limpa.

Na Ásia, 31% das associações registradas correspondem ao ODS 8. Na sequência aparecem o ODS 3, com 19%, e o ODS 2, relacionado ao combate à fome e à promoção de uma agricultura sustentável.

A Europa apresenta os maiores números absolutos de associações com o ODS 8 (54) e o ODS 9 (61), que, em conjunto, correspondem a 39% das associações com os ODS registradas no continente. O ODS 13 representa 10% do total europeu e concentra a maior parte das 36 associações identificadas para esse objetivo. A Europa também se destaca, em números absolutos, nas associações ligadas à maior parte dos ODS. Nos ODS 5 e 15, possui a

mesma quantidade que as Américas, e é o único continente com associação ao ODS 14 entre os registros analisados.

Por fim, na Oceania, 26% das associações correspondem ao ODS 3 e 17% ao ODS 16. Os ODS 2 e 8 representam 13% cada um do total de associações do continente.

Considerando o conjunto dos resultados, os ODS 3, 7, 8, 9 e 16 apresentam as maiores diferenças percentuais entre os continentes. Para os demais objetivos com valores diferentes de zero, as proporções tendem a ficar mais próximas. No ODS 1, por exemplo, a África não registra associação, enquanto os demais continentes apresentam percentuais entre 2% e 4%.

Foram localizados outros trabalhos após a RBS, porém eles não foram contabilizados por não se adequarem às chaves de busca aplicadas. Entretanto, ambos se mostram relevantes para a discussão sobre equidade e comparabilidade contextual que sustenta esta pesquisa.

O primeiro deles é o trabalho de Radovanović *et al.* (2022), que propõe uma variação do modelo DEA denominada *Fairness DEA*. A abordagem divide inicialmente as unidades em dois grupos com base em uma característica sensível: o grupo privilegiado ($q = 1$) e o grupo não privilegiado ($q = 0$). Depois, acrescenta uma restrição de paridade estatística que visa diminuir as disparidades de tratamento entre os grupos.

O segundo estudo que aborda a inclusão do contexto na avaliação por DEA é o de Durães *et al.* (2026). A abordagem incorpora variáveis contextuais no processo de estimação e utiliza o método *Benefit-of-the-Doubt* para construir indicadores compostos. Conforme foi possível verificar, no modelo não condicionado, a Alemanha se espelha em países nórdicos, enquanto, após a adição do contexto sobre a inclusão de imigrantes, o Reino Unido passa a fazer parte do conjunto de referências. Por essa razão, foi escolhido o trabalho de Durães *et al.* (2026), que une avaliação de desempenho educacional, indicadores compostos e leva em conta as condições socioeconômicas das unidades analisadas.

CAPÍTULO 2

METODOLOGIA

Este capítulo apresenta os procedimentos metodológicos adotados na pesquisa. Inicialmente, são descritas a base de dados, a seleção das regiões e das variáveis, bem como a formação dos agrupamentos contextuais. Em seguida, apresenta-se a formulação do método *Benefit-of-the-Doubt* utilizada para construir os indicadores compostos associados aos ODS 4 e 8 e o protocolo empregado para avaliar a sensibilidade dos resultados do ODS 8 à escolha da margem positiva ϵ .

2.1 Abordagem Geral

A abordagem metodológica deste trabalho é classificada como quantitativa, pois utiliza dados numéricos, técnicas de estatística descritiva, procedimentos de clusterização e modelagem DEA-BoD. Quanto aos objetivos, a pesquisa caracteriza-se como descritiva, uma vez que os fatos são observados, registrados, analisados, classificados e interpretados sem a interferência do pesquisador (Prodanov & De Freitas, 2013).

A presente pesquisa caracteriza-se como uma extensão analítica baseada em análise secundária de dados, conforme Vartanian (2010). A base de partida utilizada para as variáveis contextuais e para a aplicação do ODS 4 foi construída a partir da base empregada por Durães *et al.* (2026), oriunda da plataforma *Eurostat*¹. Para a aplicação do ODS 8, esse conjunto foi complementado com séries regionais obtidas no *Eurostat* e na base ARDECO², conforme as fontes individualizadas na Tabela 2.10. Dessa forma, este trabalho propõe uma aplicação do modelo DEA-BoD sobre esse conjunto ampliado de dados, precedida pela formação de agrupamentos destinados a reduzir a heterogeneidade contextual entre as regiões comparadas.

Diferentemente de Durães *et al.* (2026), este estudo não estima o modelo robusto condicional. As condições contextuais são consideradas por meio de uma etapa prévia de clusterização, seguida da aplicação do modelo BoD convencional separadamente em cada agrupamento.

2.2 Metodologia baseada em Indicadores Compostos

Conforme mencionado anteriormente, a RBS identificou diversas aplicações em contextos energéticos, agrícolas e urbanos. Entretanto, o primeiro eixo aplicado deste estudo

¹*Eurostat - European Statistical Office*

²ARDECO – *Annual Regional Database of the European Commission*

está associado à educação. Embora o estudo de Koçak *et al.* (2019) contemple essa temática ao abordar o ODS 4, ele não considera explicitamente as diferenças contextuais entre as unidades avaliadas. Para incorporar à aplicação educacional uma estrutura capaz de considerar diferenças contextuais entre as unidades avaliadas, adotou-se como referência metodológica complementar a proposta de Durães *et al.* (2026), que utiliza indicadores compostos baseados no modelo DEA *Benefit-of-the-Doubt* (BoD).

O modelo BoD é uma aplicação específica de DEA projetada para condensar múltiplas dimensões complexas em uma única métrica interpretável, facilitando o *benchmarking* e a análise de políticas. Diferentemente das aplicações tradicionais de eficiência técnica, a estrutura de *inputs* e *outputs* no contexto do BoD é adaptada para a agregação de indicadores:

- **Inputs:** O modelo utiliza uma única variável *dummy* (fictícia) igual a um para todas as unidades de tomada de decisão (DMUs). Isso ocorre porque o foco não é a relação recurso-produto, mas a síntese de *outputs* em um índice.
- **Outputs:** Os *outputs* são os próprios indicadores individuais monitorados.

Para os indicadores considerados indesejáveis, realiza-se inicialmente um ajuste de direção por meio da subtração de seus valores originais de 100%. Na aplicação do ODS 4, esse procedimento foi aplicado a Y2 e ao indicador original de Y5. Na aplicação do ODS 8, foi aplicado a Y2. Em ambos os casos, a transformação alinha a direção dos indicadores à lógica do BoD, na qual valores mais elevados representam melhor desempenho.

Após o ajuste de direção e antes da estimação do BoD, a translação foi aplicada, no ODS 8, apenas aos indicadores que apresentaram valores negativos no respectivo ano. Como as fronteiras são estimadas separadamente por *cluster* e ano, o procedimento foi realizado no conjunto de DMUs de cada estimação. Para cada indicador r e ano t nessa condição, identificou-se o menor valor observado e adicionou-se a todas as observações a constante correspondente ao módulo desse mínimo acrescido de uma margem positiva ϵ_{rt} . Na especificação principal, adotou-se

$$\epsilon_{rt} = 0,01 m_{rt}^+, \quad m_{rt}^+ = \min_{\ell: y_{r\ell t} > 0} \{y_{r\ell t}\},$$

de modo que ϵ_{rt} corresponde a 1% do menor valor estritamente positivo do mesmo indicador no respectivo conjunto de estimação, antes do deslocamento. Portanto, a margem não é uma constante fixa para Y1 ou Y4, pois seu valor varia conforme o indicador, o ano e o *cluster*. Para manter a notação enxuta, o índice do *cluster* foi omitido de y_{rjt} , m_{rt}^+ e ϵ_{rt} . Indicadores que não apresentaram valores negativos no ano permaneceram inalterados. Representando por y_{rjt} o valor antes da translação e por y_{rjt}^+ o valor utilizado no BoD, o procedimento é dado por:

$$y_{rjt}^+ = \begin{cases} y_{rjt} + |\min_{\ell} \{y_{r\ell t}\}| + \epsilon_{rt}, & \text{se } \min_{\ell} \{y_{r\ell t}\} < 0, \\ y_{rjt}, & \text{caso contrário.} \end{cases} \quad (2.1)$$

Na Equação 2.1, ℓ percorre as observações da variável r no ano t , utilizadas para identificar o menor valor do respectivo conjunto de estimação, e $\epsilon_{rt} > 0$ representa a margem adicionada após o deslocamento pelo módulo do mínimo. Quando a translação é necessária, a menor observação transformada assume o valor ϵ_{rt} , garantindo positividade estrita. Nos demais casos, nenhuma translação é realizada. (Adler & Berechman, 2001; Guimaraes *et al.*, 2019; Lovell & Pastor, 1995; Silva Portela *et al.*, 2004).

Na análise de sensibilidade, a margem positiva foi redefinida, para cada indicador, ano e *cluster* submetido à translação, como uma proporção do menor valor positivo observado antes do deslocamento. Foram examinados os níveis de 0,1%, 0,5%, 1%, 5% e 10%, tendo-se 1% como especificação de referência. Em todos os cenários, foram mantidos inalterados os dados, a composição dos *clusters*, a formulação do modelo e o limite de contribuição mínima $\phi_r = 0,05$, descrito na Seção 2.6.

2.3 Seleção de DMUs

O artigo de Durães *et al.* (2026) orientou a seleção das DMUs com base em três critérios. O primeiro corresponde ao aspecto temporal e considera a disponibilidade dos dados no período de 2014 a 2019. Os autores optaram por conduzir o estudo com dados de 2019, por se tratar do ano mais recente com quantidade suficiente de informações para a avaliação.

Diferentemente do artigo de Durães *et al.* (2026), este estudo realiza estimações separadas para cada ano do período de 2014 a 2019. Essa escolha permite avaliar a posição relativa das DMUs em cada execução anual e descrever o comportamento de seus escores ao longo do período.

O segundo critério de seleção utilizado por Durães *et al.* (2026) corresponde à dimensão geográfica e territorial, com a adoção da Nomenclatura das Unidades Territoriais para Fins Estatísticos (NUTS). O estudo original contempla países e regiões NUTS-I. No presente trabalho, entretanto, são consideradas exclusivamente as regiões classificadas no nível NUTS-I. Essa escala permite observar a heterogeneidade existente no interior dos países e identificar disparidades que avaliações agregadas em nível nacional podem ocultar.

O terceiro critério corresponde à completude dos dados. Para o ODS 4, foram mantidas apenas as regiões que apresentavam informações para os cinco indicadores de desempenho alinhados ao quadro ET2030 e para as duas variáveis contextuais em todos os anos analisados. A ampliação do período para 2014–2019 reduziu a amostra de 121 para 86 regiões. Para o ODS 8, dessas 86 regiões, 59 delas apresentaram dados completos para os quatro indicadores selecionados. Não foi realizada uma nova clusterização com as 59 DMUs, mantendo a classificação de cluster obtida na partição contextual definida com as 86 regiões. Dessa forma, o ODS 8 preserva o mesmo recorte contextual do ODS 4, mas trabalha com conjuntos de referência menores, compostos por 23 regiões no Cluster 1, 31 no Cluster 2 e apenas 5 no Cluster 3. Essa diferença de composição impede que os valores dos escores dos dois ODS sejam interpretados

como diretamente comparáveis entre si.

2.4 Variáveis Seleccionadas

A seleção das variáveis é organizada em três conjuntos: variáveis contextuais, variáveis de estudo do ODS 4 e variáveis de estudo do ODS 8. As variáveis contextuais são apresentadas primeiro, pois definem os agrupamentos de comparação utilizados nas duas aplicações temáticas.

2.4.1 Variáveis Contextuais

As mesmas variáveis Z1 e Z2 são mantidas na etapa de clusterização que antecede as aplicações dos ODS 4 e 8.

Tabela 2.1: Descrição das Variáveis Contextuais

Z	Variável contextual	Descrição	Código / fonte
Z1	Desemprego	Percentual da população com 15 anos ou mais desempregada.	lfst_r_lfu3rt
Z2	Cidadania	Percentual da população com 15 anos ou mais com cidadania do país reportado.	lfst_r_lfsd2pwn

Fonte: Durães *et al.* (2026).

A variável Z2 foi seleccionada para representar uma dimensão sociodemográfica relacionada à composição da população por cidadania. A literatura europeia associa a condição migratória a diferenças de desempenho educacional, considerando desafios relacionados à adaptação cultural, à aquisição da língua e ao desenvolvimento da carreira. Neste estudo, entretanto, Z2 corresponde especificamente ao percentual da população com 15 anos ou mais que possui cidadania do país reportado. Essa variável foi escolhida por apresentar menor número de valores ausentes (*missing values*) nas bases de dados (Durães *et al.*, 2026). Assim, Z2 não deve ser interpretada como medida direta de imigração, percentual da população nascida no exterior, fluxos migratórios ou composição da força de trabalho estrangeira, mas exclusivamente como o percentual de residentes com cidadania do país reportado.

Portanto, são adotadas duas variáveis de contexto (Z) para agrupar as observações em conjuntos internamente homogêneos e, simultaneamente, heterogêneos em relação aos demais grupos. Essas variáveis estão descritas na Tabela 2.1.

Estatísticas Descritivas

As estatísticas descritivas de Z1 e Z2 são apresentadas antes das aplicações temáticas porque essas variáveis determinam a composição dos grupos de comparação, mas não

entram como *outputs* no indicador composto.

Tabela 2.2: Estatísticas descritivas para a variável Z1 (2014-2019)

Z1	2014	2015	2016	2017	2018	2019
Média	9,90	9,11	8,30	7,39	6,60	6,16
Desvio Padrão	5,90	5,37	4,96	4,56	4,14	3,95
Min	2,90	2,90	2,50	2,30	2,20	2,00
Q1 (25%)	6,12	5,62	4,80	4,20	3,80	3,52
Q2 (50%)	8,55	7,80	7,00	6,25	5,20	4,85
Q3 (75%)	10,77	10,60	9,85	8,95	8,37	7,47
Max	33,50	30,50	27,50	24,40	22,10	20,50

Fonte: Elaboração própria.

Z1 apresenta deslocamento da distribuição para taxas de desemprego menores ao longo do período. Esse movimento aparece na média, na mediana e nos dois quartis, e também alcança os extremos da distribuição. A redução do desvio padrão e do intervalo interquartil indica que o recuo do desemprego foi acompanhado por diminuição da dispersão entre as regiões. Ainda assim, os valores máximos permanecem acima das medidas centrais, preservando diferenças entre regiões com condições distintas de mercado de trabalho.

Tabela 2.3: Estatísticas descritivas para a variável Z2 (2014-2019)

Z2	2014	2015	2016	2017	2018	2019
Média	92,59	92,25	91,86	91,58	91,35	91,09
Desvio Padrão	6,49	6,62	6,72	6,92	6,96	7,06
Min	64,05	63,09	64,61	63,68	64,25	63,86
Q1 (25%)	88,45	87,68	87,23	87,42	87,06	86,85
Q2 (50%)	94,01	93,18	92,56	92,45	92,32	92,11
Q3 (75%)	97,23	96,71	96,05	96,26	95,95	96,06
Max	100,00	99,97	99,97	99,97	99,95	99,97

Fonte: Elaboração própria.

Z2 apresenta comportamento distinto de Z1. As medidas centrais de cidadania se deslocam para valores menores ao longo do período, enquanto a dispersão aumenta. O mínimo permanece entre 63,09% e 64,61%, e o máximo entre 99,95% e 100%, indicando que a mudança se concentra nas medidas centrais e na dispersão, e não nos limites observados. Como Z2 representa a parcela da população com cidadania do país reportado, sua redução corresponde a uma participação maior de residentes sem essa cidadania no conjunto analisado. Esse comportamento preserva uma dimensão sociodemográfica de diferenciação entre as regiões para a

etapa de clusterização.

A diferença de comportamento entre Z1 e Z2 reforça o papel complementar das duas variáveis na formação dos grupos: uma representa condições do mercado de trabalho e a outra, composição sociodemográfica.

2.4.2 Variáveis de Estudo - ODS 4

O critério primário para a seleção dessas variáveis foi sua correspondência direta às cinco prioridades estratégicas de referência definidas pela União Europeia no Quadro Estratégico para a Educação e Formação 2030 (ET2030). Contudo, como o estudo se concentra na escala regional (NUTS-I), e não apenas na nacional, foi necessário adotar variáveis aproximadas (*proxies*) devido à indisponibilidade de determinados dados (Durães *et al.*, 2026).

Tabela 2.4: Indicadores de Educação e Competências Digitais

Y	Indicador	Descrição	Código / fonte
Y1	Educação na primeira infância	Percentual da população da UE com idade entre 3 anos e a idade de início da educação primária obrigatória que participa da educação infantil.	educ_uoe_enra22
Y2	Abandono precoce da educação e formação	Percentual da população da UE com idade entre 18 e 24 anos com, no máximo, ensino secundário e que não está mais em educação ou formação.	edat_lfse_16
Y3	Conclusão do ensino superior	Percentual da população da UE com idade entre 25 e 34 anos que concluiu com sucesso o ensino superior.	edat_lfse_04
Y4	Participação de adultos em aprendizagem ao longo da vida	Percentual da população da UE com idade entre 25 e 64 anos que participou de educação e formação nas últimas 4 semanas.	trng_lfse_04
Y5	Acesso domiciliar à internet	Percentual de domicílios com acesso à internet em casa, obtido pelo complemento do indicador original de domicílios sem acesso.	isoc_r_iacc_h

Fonte: Durães *et al.* (2026).

O indicador originalmente previsto correspondia ao percentual de estudantes do oitavo ano de escolaridade com baixo desempenho em literacia computacional e da informação. Entretanto, esses dados estavam disponíveis apenas em nível nacional. Como alternativa, Durães *et al.* (2026) adotaram como *proxy* regional o percentual de domicílios sem acesso à internet em casa, uma vez que a ausência de conectividade limita o desenvolvimento de competências digitais fora da escola e pode contribuir para a exclusão digital. Por se tratar de um indicador indesejável, seus valores foram transformados por meio do complemento em relação a 100%. Assim, a variável Y5 utilizada neste estudo representa o percentual de domicílios com acesso à internet em casa, de modo que valores mais elevados indiquem melhor desempenho.

Estatísticas Descritivas

As estatísticas descritivas dos cinco indicadores são apresentadas por ano para o período de 2014 a 2019. A leitura conjunta de média, desvio padrão, quartis e extremos permite descrever mudanças de posição e dispersão sem atribuir significância estatística às diferenças observadas.

Tabela 2.5: Estatísticas descritivas para a variável Y1 (2014-2019)

Y1	2014	2015	2016	2017	2018	2019
Média	91,75	92,51	93,12	93,52	93,49	93,73
Desvio Padrão	7,69	7,49	6,54	6,45	6,55	6,42
Min	67,60	69,50	70,50	74,90	76,30	74,20
Q1 (25%)	87,67	88,02	88,72	90,07	90,02	91,75
Q2 (50%)	94,90	95,55	94,65	95,10	94,65	95,00
Q3 (75%)	97,27	98,37	98,50	98,97	99,60	100,00
Max	100,00	100,00	100,00	100,00	100,00	100,00

Fonte: Elaboração própria.

Em Y1, a distribuição se desloca para níveis maiores de participação na educação infantil e apresenta redução da dispersão ao longo do período. O movimento não fica restrito à média: o primeiro quartil e o valor mínimo também avançam, indicando que regiões situadas na parte inferior da distribuição acompanham essa mudança. Na parte superior, o indicador se aproxima do limite da própria escala; em 2019, Q3 atinge 100%, o que significa que pelo menos um quarto das regiões se encontra no valor máximo. Esse efeito de teto reduz a capacidade do indicador de distinguir as regiões que já apresentam participação próxima da universalização.

Tabela 2.6: Estatísticas descritivas para a variável Y2 (2014-2019)

Y2	2014	2015	2016	2017	2018	2019
Média	11,28	11,27	11,03	10,81	10,72	10,69
Desvio Padrão	5,51	5,01	4,68	4,54	4,57	4,44
Min	2,80	2,80	2,80	3,10	2,80	3,00
Q1 (25%)	7,12	7,32	7,72	7,87	7,72	7,52
Q2 (50%)	10,50	10,60	10,40	10,20	10,00	10,55
Q3 (75%)	13,37	13,05	12,85	12,70	12,30	12,35
Max	32,80	28,80	26,90	27,80	28,30	27,00

Fonte: Elaboração própria.

Na escala original apresentada na tabela, Y2 é um indicador indesejável: valores

menores representam menor abandono precoce da educação e formação. A distribuição se desloca nessa direção ao longo do período e, ao mesmo tempo, apresenta redução da dispersão entre as regiões. A queda do limite superior também mostra que a mudança alcança as regiões com maiores taxas de abandono, embora permaneça uma cauda superior em relação às medidas centrais. Para a estimação BoD, essa direção é invertida por meio do complemento em relação a 100%, conforme descrito anteriormente.

Tabela 2.7: Estatísticas descritivas para a variável Y3 (2014-2019)

Y3	2014	2015	2016	2017	2018	2019
Média	36,32	36,82	37,18	37,77	38,80	39,45
Desvio Padrão	10,33	10,19	10,09	10,18	10,40	10,74
Min	16,40	17,60	17,10	17,10	17,50	17,00
Q1 (25%)	28,37	29,52	28,57	30,42	32,05	32,07
Q2 (50%)	37,00	38,40	37,85	38,20	39,70	39,90
Q3 (75%)	42,72	43,42	42,82	44,25	45,75	46,22
Max	61,50	65,20	66,50	66,60	66,90	67,90

Fonte: Elaboração própria.

Y3 apresenta deslocamento das medidas de posição para níveis maiores de conclusão do ensino superior. O avanço ocorre no primeiro quartil, na mediana e no terceiro quartil, de modo que não se limita às regiões situadas no topo da distribuição. Entre 2014 e 2019, o intervalo interquartil passa de 14,35 para 14,15 pontos percentuais e o desvio padrão de 10,33% para 10,74%. Assim, o aumento das medidas de posição não é acompanhado por redução da dispersão que sustente uma leitura de convergência entre as regiões.

Tabela 2.8: Estatísticas descritivas para a variável Y4 (2014-2019)

Y4	2014	2015	2016	2017	2018	2019
Média	11,08	11,12	11,15	11,3	11,51	11,71
Desvio Padrão	6,63	6,59	6,55	6,63	6,69	7,69
Min	0,80	0,90	0,90	0,90	0,70	0,80
Q1 (25%)	6,42	6,42	6,92	7,27	7,20	7,00
Q2 (50%)	9,45	9,30	9,55	10,05	10,05	10,20
Q3 (75%)	16,27	16,05	15,27	15,42	15,22	15,77
Max	30,90	30,50	31,00	31,30	32,10	35,20

Fonte: Elaboração própria.

Y4 não apresenta um deslocamento uniforme da distribuição. A média e a mediana terminam o período acima dos valores iniciais, mas o terceiro quartil não acompanha o mesmo

movimento, enquanto o valor máximo aumenta e amplia a faixa total observada em 2019. O resultado indica que a participação de adultos em aprendizagem ao longo da vida evolui de forma distinta entre as regiões e entre partes da distribuição. Por isso, a mudança das medidas centrais não deve ser interpretada como convergência regional.

Tabela 2.9: Estatísticas descritivas para a variável Y5 (2014-2019)

Y5	2014	2015	2016	2017	2018	2019
Média	82,95	84,41	86,33	87,66	89,24	90,98
Desvio Padrão	10,21	9,08	8,71	7,68	6,73	5,96
Min	58,79	60,63	63,37	67,48	70,68	74,00
Q1 (25%)	74,61	77,27	79,09	82,24	84,33	87,12
Q2 (50%)	85,47	86,96	88,80	89,66	91,59	92,32
Q3 (75%)	91,10	90,94	92,94	93,63	94,50	95,42
Max	97,31	98,54	99,21	98,96	98,83	99,18

Fonte: Elaboração própria.

Y5 apresenta um movimento conjunto de expansão do acesso domiciliar à internet e redução da dispersão regional. O mínimo e o primeiro quartil aumentam mais do que o terceiro quartil, enquanto o limite superior permanece próximo de 100%. Esse padrão mostra que parte da redução da dispersão ocorre pelo deslocamento das regiões que estavam na porção inferior da distribuição. Como a variável utilizada no modelo é o complemento do indicador original de domicílios sem internet, o movimento representa redução da exclusão de acesso entre as regiões analisadas.

Os cinco indicadores do ODS 4 não seguem a mesma dinâmica ao longo do período. A combinação dessas trajetórias reforça a necessidade de preservar o caráter multidimensional da avaliação, em vez de interpretar o desempenho educacional a partir de um único indicador.

2.4.3 Variáveis de Estudo - ODS 8

A seleção das variáveis do ODS 8 partiu da necessidade de representar trabalho decente e crescimento econômico sem reproduzir, dentro do indicador composto, a mesma dimensão utilizada na formação dos grupos contextuais. Como a taxa de desemprego (Z1) já integra a etapa de clusterização, indicadores gerais de emprego, participação na força de trabalho, subutilização da mão de obra e desemprego de longa duração não foram incorporados como variáveis de desempenho. A inclusão dessas medidas faria com que uma dimensão do mercado de trabalho participasse da definição dos grupos de comparação e voltasse a influenciar o escore BoD. A separação adotada mantém o desemprego como condição contextual e reserva as variáveis Y para dimensões do ODS 8 que acrescentam informação ao desempenho avaliado.

A vinculação das variáveis às dimensões do ODS 8 também considerou o quadro

oficial de metas e indicadores da Agenda 2030. Y1 corresponde à dimensão de produtividade da Meta 8.2 e acompanha a lógica do Indicador 8.2.1, definido como a taxa anual de crescimento do PIB real por pessoa empregada. Y4 se vincula à Meta 8.1 e ao Indicador 8.1.1, referente à taxa anual de crescimento do PIB real por habitante. Y2 representa a dimensão da Meta 8.6 associada aos jovens fora do emprego, da educação ou da formação; contudo, a série regional utilizada abrange a população de 15 a 29 anos, enquanto o Indicador 8.6.1 do quadro global considera a faixa de 15 a 24 anos, razão pela qual Y2 é utilizada como aproximação regional dessa dimensão. Y3 não reproduz diretamente um indicador global do ODS 8, sendo utilizada como medida complementar da dimensão de modernização tecnológica e inovação prevista na Meta 8.2, com base na série regional de emprego em setores de alta tecnologia e intensivos em conhecimento do *Eurostat* (United Nations Statistics Division, 2026; Eurostat, 2024a).

Essa decisão não elimina a dimensão laboral do ODS 8. Y2 foi mantida porque a taxa NEET não equivale à taxa geral de desemprego utilizada em Z1. O indicador identifica jovens de 15 a 29 anos que se encontram fora do emprego, da educação e da formação e, portanto, combina inserção laboral e continuidade educacional em uma população específica. Para adequar a direção de preferência ao BoD, utiliza-se seu complemento em relação a 100%, de modo que valores maiores representem maior proporção de jovens em emprego, educação ou formação.

Y3 complementa essa dimensão ao observar a composição do emprego, e não sua quantidade. A variável corresponde à participação dos trabalhadores empregados em setores de alta tecnologia e intensivos em conhecimento no emprego regional. Dessa forma, duas regiões com taxas de desemprego semelhantes podem apresentar valores distintos de Y3 caso sua estrutura produtiva absorva parcelas diferentes da força de trabalho em atividades associadas a tecnologia e conhecimento. A variável acrescenta, assim, uma dimensão relacionada à estrutura produtiva, à inovação e ao trabalho qualificado sem repetir a medida contextual de desemprego.

Y1 e Y4 foram mantidas apesar de ambas serem expressas como taxas de crescimento porque representam grandezas distintas. Y1 mede a variação anual da produtividade real do trabalho por pessoa empregada e está associada à Meta 8.2; seu denominador é a população empregada e sua interpretação está ligada à variação do produto real gerado por trabalhador. Y4 mede a variação anual do PIB real por habitante e está associada à Meta 8.1; seu denominador é a população residente e sua interpretação corresponde ao crescimento do produto real por pessoa na região. A coincidência na forma de taxa de crescimento não torna as duas medidas equivalentes, pois produtividade por trabalhador e produto por habitante podem seguir trajetórias diferentes conforme variem emprego, população e produção.

A seleção não procura reproduzir todas as metas do ODS 8 em um único indicador. O recorte considera as dimensões para as quais foi possível manter séries regionais compatíveis com o nível NUTS-I, o período de 2014 a 2019 e a separação entre contexto e desempenho adotada no estudo. Com essa composição, as quatro variáveis cobrem crescimento da produtividade do trabalho (Y1), inserção dos jovens no trabalho ou na formação (Y2), estrutura ocupacional

associada a tecnologia e conhecimento (Y3) e crescimento econômico real por habitante (Y4). A Tabela 2.10 apresenta as variáveis utilizadas.

Tabela 2.10: Indicadores de Trabalho Decente e Crescimento Econômico

Y	Indicador	Descrição	Código / fonte
Y1	Crescimento da produtividade real do trabalho	Taxa anual de crescimento da produtividade real do trabalho por pessoa empregada.	nama_10r_2rlp
Y2	População jovem estudando ou trabalhando (15–29 anos)	Complemento da taxa NEET, obtido por 100 – taxa NEET, de modo que valores maiores representem maior participação dos jovens no trabalho, educação ou formação.	edat_lfse_22
Y3	Emprego de alta tecnologia	Participação do emprego em setores de alta tecnologia e intensivos em conhecimento no emprego regional.	htec_emp_risco2
Y4	Crescimento do PIB real por habitante	Taxa anual de crescimento do PIB real por habitante, calculada a partir da série SOVGDP a preços constantes.	ARDECO – SOVGDP

Fonte: Elaboração própria com base em Eurostat e ARDECO.

Para a construção de Y4, foram utilizados os valores da série SOVGDP do ARDECO, correspondente ao PIB Real (PIBr), na unidade EUR2015 e no nível territorial NUTS-I, conforme a classificação NUTS 2024 utilizada na extração. Para cada região i e ano t , a taxa anual foi calculada por:

$$Y4_{i,t} = \frac{(PIBr_{i,t} - PIBr_{i,t-1})}{PIBr_{i,t-1}} \times 100 \quad (2.2)$$

Para obter a taxa de 2014, o valor de 2013 foi utilizado exclusivamente como base de comparação do ano anterior, mantendo-se 2014–2019 como período analisado. A base ARDECO reúne séries regionais da Comissão Europeia em diferentes níveis NUTS e utiliza o *Eurostat* como sua principal fonte de dados (European Commission, 2024; Eurostat, 2024b).

Por Y1 e Y4 assumir valores negativos quando a produtividade real por pessoa empregada ou o PIB real por habitante diminuem em relação ao ano anterior. O sinal, nesses casos, constitui parte da informação econômica da variável e não é tratado como erro de registro. Os valores originais são preservados nas estatísticas descritivas; para a estimação BoD, Y1 e Y4 passam, em cada ano, pelo procedimento de translação descrito na Equação 2.1, pois apresentam valores negativos ao longo de todo o período analisado. Y2 e Y3 permanecem inalterados quanto a esse tratamento. Na aplicação do ODS 8, 59 DMUs apresentaram os dados completos para os quatro indicadores utilizados nas estimações.

Estatísticas Descritivas

As estatísticas descritivas dos quatro indicadores são apresentadas na escala original das variáveis. A análise prioriza o comportamento do conjunto ao longo do período, enquanto os valores completos permanecem disponíveis nas tabelas.

Tabela 2.11: Estatísticas descritivas para a variável Y1 do ODS 8 (2014-2019)

Y1	2014	2015	2016	2017	2018	2019
Média	1,03	1,21	0,61	2,15	1,12	1,31
Desvio Padrão	1,57	2,43	1,61	2,02	2,05	1,85
Min	-2,70	-3,30	-2,30	-0,50	-1,60	-2,70
Q1 (25%)	0,05	0,05	-0,45	0,90	-0,30	0,40
Q2 (50%)	0,90	0,70	0,40	1,70	0,60	1,00
Q3 (75%)	1,90	2,05	1,50	2,70	1,45	1,95
Max	5,80	14,50	5,20	9,70	7,30	8,80

Fonte: Elaboração própria.

Y1 não apresenta uma trajetória contínua de aceleração ou desaceleração. A taxa média de crescimento da produtividade permaneceu positiva nos seis anos, mas os valores mínimos foram negativos em todos eles, mostrando que o crescimento médio coexistiu com contrações em parte das regiões. Em 2015, a distribuição apresentou a maior amplitude do período devido ao limite superior observado; as demais medidas de posição não indicam, por si só, que esse valor deva ser tratado como erro ou excluído. As medidas de dispersão também não se deslocam na mesma direção entre o início e o fim do período, de modo que os dados não sustentam uma leitura de convergência ou afastamento generalizado entre as regiões.

Tabela 2.12: Estatísticas descritivas para a variável Y2 do ODS 8 (2014-2019)

Y2	2014	2015	2016	2017	2018	2019
Média	85,15	85,49	85,91	86,72	87,44	87,82
Desvio Padrão	6,63	6,49	6,10	5,83	5,79	5,70
Min	61,00	62,30	63,50	64,20	63,90	64,20
Q1 (25%)	81,20	81,55	81,95	83,30	84,65	85,30
Q2 (50%)	87,10	87,40	87,70	87,70	88,90	89,40
Q3 (75%)	89,80	90,25	90,30	90,85	91,30	91,50
Max	94,40	94,30	93,70	93,90	94,20	94,90

Fonte: Elaboração própria.

Em Y2, as medidas de posição terminam o período acima dos valores de 2014,

enquanto o desvio padrão e o intervalo interquartil diminuem. Como a variável corresponde ao complemento da taxa NEET, esse movimento representa uma redução da proporção de jovens fora do emprego, da educação ou da formação no conjunto analisado. O quartil inferior avançou mais do que o quartil superior, reduzindo a distância entre essas duas partes da distribuição. O padrão descreve o conjunto regional e não implica que todas as regiões tenham seguido a mesma trajetória.

Tabela 2.13: Estatísticas descritivas para a variável Y3 do ODS 8 (2014-2019)

Y3	2014	2015	2016	2017	2018	2019
Média	3,75	3,81	3,83	3,88	4,00	4,07
Desvio Padrão	1,58	1,64	1,64	1,64	1,71	1,75
Min	0,92	1,17	1,21	1,05	1,07	1,19
Q1 (25%)	2,77	2,79	2,83	2,70	2,84	2,75
Q2 (50%)	3,37	3,31	3,48	3,54	3,57	3,57
Q3 (75%)	4,75	4,76	4,81	4,99	4,98	4,96
Max	8,20	8,70	8,59	8,75	8,77	9,23

Fonte: Elaboração própria.

Y3 apresenta aumento da média ao longo dos seis anos, acompanhado por deslocamento da mediana e do quartil superior ao comparar 2014 e 2019. O primeiro quartil, porém, termina praticamente no mesmo nível de 2014, com diferença de apenas 0,02 ponto percentual. Esse contraste indica que a mudança na participação do emprego em setores de alta tecnologia e intensivos em conhecimento não ocorreu da mesma forma ao longo da distribuição. As medidas de dispersão terminam acima das observadas em 2014, não sustentando uma interpretação de convergência entre as regiões.

Tabela 2.14: Estatísticas descritivas para a variável Y4 do ODS 8 (2014-2019)

Y4	2014	2015	2016	2017	2018	2019
Média	1,62	1,81	1,83	2,90	2,10	2,00
Desvio Padrão	1,81	1,92	1,67	2,15	2,27	1,86
Min	-2,20	-1,46	-1,21	-0,37	-1,87	-1,70
Q1 (25%)	0,46	0,38	0,76	1,37	0,37	1,13
Q2 (50%)	1,44	1,32	1,40	2,32	1,42	1,47
Q3 (75%)	2,55	2,90	2,64	4,31	3,36	2,68
Max	6,60	6,49	6,25	10,39	8,86	8,04

Fonte: Elaboração própria.

Y4 combina crescimento médio positivo com a presença de valores negativos em

todos os anos, indicando que a expansão do PIB real por habitante no conjunto coexistiu com contrações regionais. Em 2017, média, mediana e quartis se deslocam para cima em relação aos demais anos, mas esse movimento não se mantém em 2018 e 2019. O comportamento é coerente com uma variável de crescimento anual, na qual acelerações e desacelerações podem alternar entre períodos. Como as medidas de dispersão não apresentam uma direção comum entre 2014 e 2019, os dados não sustentam conclusão de convergência ou aumento generalizado da heterogeneidade.

Os quatro indicadores do ODS 8 seguem trajetórias distintas, como mudanças na inserção juvenil e na estrutura ocupacional convivem com oscilações nos indicadores de crescimento. Assim, o período combina mudanças na inserção juvenil e na estrutura ocupacional com oscilações nos indicadores de crescimento. As estatísticas descritivas, isoladamente, não permitem resumir o ODS 8 em uma única trajetória temporal.

2.5 Procedimento de Clusterização

A clusterização foi realizada pelo método *k-means* a partir das variáveis contextuais Z1 e Z2. A solução principal considerou as 86 regiões que compõem a aplicação do ODS 4, de modo que a formação dos agrupamentos antecedeu a estimação dos indicadores compostos e não utilizou as variáveis Y para definir a pertença das DMUs aos *clusters*. Para representar cada região, foram calculadas as médias aritméticas de Z1 e Z2 no período de 2014 a 2019, formando um par de valores contextuais por DMU. Z2, originalmente armazenada como proporção decimal, foi convertida para escala percentual durante a preparação dos dados. Antes da aplicação do *k-means*, Z1 e Z2 foram padronizadas pelo escore *z*. O procedimento foi implementado em Python com a biblioteca *scikit-learn*, utilizando `random_state = 42` e `n_init = 10`.

Como a pertença aos *clusters* foi definida a partir das médias de Z1 e Z2 calculadas para o período completo de 2014 a 2019, a classificação contextual utilizada na aplicação principal é fixa e retrospectiva. Assim, uma DMU observada em determinado ano é avaliada no BoD dentro do agrupamento definido por seu perfil contextual médio no período, e não por uma classificação recalculada apenas com as informações daquele ano. Essa definição mantém a composição dos grupos entre as estimações anuais, enquanto as fronteiras BoD permanecem contemporâneas, pois são estimadas separadamente para cada *cluster* e ano.

O número de agrupamentos foi investigado pelo método do cotovelo para valores de *k* entre 1 e 10. Para cada valor de *k*, foi calculada a inércia, correspondente à soma das distâncias quadráticas das observações aos centroides dos respectivos *clusters*. As partições adjacentes com *k* = 2 e *k* = 4 também foram examinadas como apoio à escolha do número de grupos. A configuração utilizada nas etapas posteriores do estudo foi *k* = 3.

A sensibilidade da classificação à extensão do período utilizado para construir o perfil contextual foi examinada por meio de quatro janelas, todas encerradas em 2019: 2017–2019, 2016–2019, 2015–2019 e 2014–2019. Em cada cenário, as médias de Z1 e Z2 foram

recalculadas apenas com os anos pertencentes à respectiva janela, seguidas pela padronização e por uma nova aplicação do procedimento de clusterização. O método do cotovelo também foi reaplicado em cada janela, e a composição dos agrupamentos foi comparada a partir dos códigos das DMUs e do número de regiões pertencentes a cada grupo.

A janela completa de 2014 a 2019 foi utilizada na aplicação principal por incorporar todo o período analisado à caracterização contextual das regiões e reduzir a dependência da classificação em relação a oscilações observadas em intervalos mais curtos. Os resultados da análise de sensibilidade permitem avaliar em que medida essa escolha afeta a composição dos agrupamentos.

2.6 Modelagem Matemática

Conforme proposto por Durães *et al.* (2026), o modelo utilizado corresponde à forma primal (multiplicadores) de um CCR (CRS) adaptado ao método BoD. Desse modo, a partir da normalização adotada, o modelo está orientado aos *outputs*, conforme ilustra a Equação 2.3.

$$\begin{aligned}
 [IC_k]^{-1} = \min \quad & v \\
 \text{s.t.} \quad & \sum_{r=1}^s u_r y_{rk} = 1 \\
 & \sum_{r=1}^s u_r y_{rj} - v \leq 0 \quad \forall j = 1, \dots, n \\
 & \frac{u_r \bar{y}_r}{\sum_{r=1}^s u_r \bar{y}_r} \geq \phi_r \quad \forall r = 1, \dots, s \\
 & u_r \geq 0 \quad \forall r = 1, \dots, s \\
 & v \geq 0
 \end{aligned} \tag{2.3}$$

Sendo que:

- n : número total de DMUs.
- s : número total de *outputs* avaliados.
- r : índice matemático que identifica cada *output* individualmente.
- k : DMU avaliada.
- j : índice que identifica as DMUs da amostra nas restrições.
- u_r : peso matemático atribuído pelo modelo ao *output* r .
- y_{rk} : valor do *output* r alcançado pela DMU k , após os ajustes de direção e a translação descrita na Equação 2.1.
- y_{rj} : valor do *output* r pertencente à DMU j , após os mesmos procedimentos de preparação.
- $\bar{y}_r$: valor médio do *output* r no conjunto de DMUs que compõe a respectiva estimação.
- ϕ_r : limite inferior para a participação proporcional do *output* r , calculada no vetor de valores médios utilizado na restrição de contribuição.

A primeira restrição do modelo decorre do processo de normalização e estabelece que a soma ponderada dos *outputs* da DMU avaliada seja igual a 1, fixando a escala dos pesos utilizados na estimação. Essa normalização não representa, por si só, um escore de 100%. A segunda restrição estabelece que, sob o mesmo conjunto de pesos, a soma ponderada dos *outputs* de cada DMU não ultrapasse o valor de v . Como a própria DMU avaliada também está sujeita a essa restrição, tem-se $v \geq 1$. Após a otimização, o indicador composto é obtido por $IC_k = 1/v^*$, pertencendo ao intervalo $(0, 1]$. Dessa forma, o escore de 100% ocorre apenas quando $v^* = 1$.

Até esse ponto, o modelo segue, matematicamente, a mesma lógica do modelo CRS proposto por Charnes *et al.* (1978). A terceira restrição, entretanto, impõe que a participação proporcional de cada indicador, avaliada a partir dos valores médios $\bar{y}_r$, seja pelo menos ϕ_r . Como $\phi_r > 0$, a restrição impede contribuição nula do respectivo indicador no vetor de referência utilizado para limitar os pesos. Para o ODS 4, adotou-se $\phi_r = 0,05$, o mesmo parâmetro utilizado por Durães *et al.* (2026) e originalmente empregado por Camanho *et al.* (2023) na elaboração de um indicador composto para a área da educação em países europeus.

Na aplicação do ODS 8, não foi identificado, na literatura consultada, um valor de contribuição mínima especificamente estabelecido para aplicações BoD desse objetivo. Optou-se, portanto, por manter $\phi_r = 0,05$ também no ODS 8, adotando o mesmo limite inferior de participação proporcional por indicador nas duas aplicações e evitando a introdução de um segundo limiar sem referência empírica específica. Essa manutenção constitui uma decisão metodológica do presente estudo e não deve ser interpretada como um valor de referência consolidado na literatura para o ODS 8.

CAPÍTULO 3


RESULTADOS

Este capítulo apresenta os resultados em duas partes sequenciais. A primeira aborda a clusterização das regiões europeias classificadas no nível NUTS-I, descrevendo os agrupamentos formados a partir das variáveis contextuais e examinando a heterogeneidade existente entre regiões de um mesmo país. A segunda parte apresenta os resultados da aplicação da Análise Envoltória de Dados (DEA), por meio do método *Benefit-of-the-Doubt* (BoD), para a construção de indicadores compostos associados aos ODS 4 e 8 e a identificação de referências de desempenho entre regiões contextualmente semelhantes.

3.1 Clusters

Conforme o procedimento descrito na Seção 2.5, o método do cotovelo foi utilizado para auxiliar na definição do número de agrupamentos. O cálculo foi realizado para valores de k entre 1 e 10, conforme apresentado na Figura 3.1.


Figura 3.1: Método do cotovelo: aplicação para valores de k entre 1 e 10



Fonte: Elaboração própria.

A Figura 3.1 evidencia uma redução mais acentuada da inércia até $k = 3$. A partir desse ponto, a inclusão de novos agrupamentos produz reduções progressivamente menores. As partições adjacentes com $k = 2$ e $k = 4$ foram examinadas apenas como apoio à leitura do ponto de inflexão. Com base nesse diagnóstico, manteve-se $k = 3$ como configuração do estudo, sendo essa a partição utilizada nas análises subsequentes.

A solução selecionada resultou em 30 regiões no Cluster 1, 47 regiões no Cluster 2 e 9 regiões no Cluster 3, totalizando as 86 unidades analisadas. A distribuição das regiões em relação às variáveis contextuais pode ser observada na Figura 3.2.



Fonte: Elaboração própria.

Para facilitar a comparação entre os agrupamentos, a Tabela 3.1 apresenta o número de regiões e os valores médios das variáveis contextuais em cada cluster.

Tabela 3.1: Perfil médio das variáveis contextuais por cluster

Cluster	Regiões	Desemprego médio	Cidadania média
Cluster 1	30	6,17%	85,00%
Cluster 2	47	6,91%	96,40%
Cluster 3	9	18,90%	90,00%

Fonte: Elaboração própria.

O Cluster 1 apresenta a menor taxa média de desemprego entre os agrupamentos, equivalente a 6,17%, e a menor proporção média de residentes com cidadania do país reportado, correspondente a 85,0%. O grupo caracteriza-se, portanto, pela combinação entre um nível relativamente baixo de desemprego e uma proporção comparativamente menor de residentes com cidadania nacional.

O Cluster 2, composto pelo maior número de regiões, apresenta uma taxa média de desemprego de 6,91%, valor próximo ao observado no Cluster 1. Sua principal característica distintiva é a proporção média de residentes com cidadania do país reportado, equivalente a

96,4%, a maior entre os três agrupamentos. Assim, embora os Clusters 1 e 2 apresentem níveis semelhantes de desemprego, eles se diferenciam principalmente quanto à variável cidadania.

Por sua vez, o Cluster 3 apresenta a maior taxa média de desemprego, correspondente a 18,9%, valor aproximadamente três vezes superior aos observados nos Clusters 1 e 2. A proporção média de residentes com cidadania do país reportado é de 90,0%, situando-se entre os valores registrados nos outros dois agrupamentos. Dessa maneira, o principal elemento de diferenciação do Cluster 3 é o nível mais elevado de desemprego.

Em termos comparativos, os Clusters 1 e 2 apresentam maior proximidade na dimensão relacionada ao mercado de trabalho, mas ocupam posições distintas quanto à proporção de residentes com cidadania do país reportado. O Cluster 3, em contrapartida, distingue-se sobretudo pelo desemprego mais elevado, enquanto sua posição na variável cidadania permanece intermediária.

Esses resultados permitem identificar três perfis contextuais distintos: o Cluster 1 combina menor desemprego e menor proporção de cidadania do país reportado; o Cluster 2 apresenta baixo desemprego e maior proporção de cidadania; e o Cluster 3 reúne regiões com desemprego mais elevado e proporção intermediária de cidadania.

Da mesma forma, os agrupamentos possuem natureza descritiva e não permitem estabelecer relações causais entre cidadania e desemprego. Os resultados também não permitem atribuir os perfis observados a fatores como dinamismo econômico, rigidez do mercado de trabalho, capacidade institucional, políticas migratórias ou capacidade de absorção da força de trabalho. A investigação dessas relações exigiria a inclusão de variáveis explicativas adicionais e a aplicação de métodos estatísticos específicos.

A finalidade da clusterização neste estudo consiste, portanto, em formar conjuntos de regiões relativamente semelhantes quanto às condições contextuais observadas. Esses agrupamentos serão utilizados posteriormente como ambientes de comparação para a aplicação do método BoD, evitando que regiões com perfis contextuais substancialmente distintos sejam avaliadas diretamente sob uma mesma fronteira de referência.

Outra perspectiva relevante consiste em examinar a distribuição das regiões segundo seus respectivos países. A Tabela 3.2 apresenta a quantidade de regiões de cada país pertencente a cada agrupamento.

Tabela 3.2: Distribuição das regiões por país

Países	Cluster 1	Cluster 2	Cluster 3	Total
Áustria	3			3
Bélgica	2	1		3
Chipre	1			1
Alemanha	10	6		16
Estónia	1			1
França	1	11		12
Irlanda	1			1
Itália	3		2	5
Letónia	1			1
Noruega	1			1
Suécia	1	2		3
Reino Unido	5	6		11
Bulgária		2		2
República Checa		1		1
Finlândia		1		1
Croácia		1		1
Hungria		3		3
Lituânia		1		1
Polónia		4		4
Portugal		2		2
Roménia		4		4
Eslovénia		1		1
Eslováquia		1		1
Espanha			7	7
Total	30	47	9	86

Fonte: Elaboração própria.

A Tabela 3.2 mostra que Áustria, Chipre, Estónia, Irlanda, Letónia e Noruega possuem todas as regiões analisadas concentradas no Cluster 1. Por outro lado, Bulgária, República Checa, Finlândia, Croácia, Hungria, Lituânia, Polónia, Portugal, Roménia, Eslovénia e Eslováquia apresentam suas regiões exclusivamente no Cluster 2. A Espanha é o único país cujas regiões analisadas estão integralmente concentradas no Cluster 3.

Entretanto, a distribuição também evidencia que determinadas fronteiras nacionais abrangem regiões com diferentes perfis contextuais. Bélgica, Alemanha, França, Itália, Suécia e Reino Unido possuem regiões distribuídas entre dois clusters, indicando que a classificação nacional não representa, isoladamente, toda a heterogeneidade observada no nível NUTS-I.

A Alemanha apresenta dez regiões no Cluster 1 e seis no Cluster 2. Dessa forma, 62,5% das regiões alemãs analisadas pertencem ao Cluster 1, enquanto 37,5% pertencem ao Cluster 2. Embora todas apresentem taxas médias de desemprego relativamente baixas em

comparação ao Cluster 3, elas se diferenciam quanto à proporção de residentes com cidadania do país reportado.

A França apresenta onze regiões no Cluster 2 e apenas uma no Cluster 1, enquanto a Suécia apresenta duas regiões no Cluster 2 e uma no Cluster 1. O Reino Unido possui uma distribuição próxima do equilíbrio, com cinco regiões no Cluster 1 e seis no Cluster 2. Esses resultados indicam que regiões pertencentes ao mesmo país podem apresentar diferentes combinações das variáveis contextuais consideradas.


A Itália apresenta uma configuração particular, com três regiões no Cluster 1 e duas no Cluster 3. Trata-se do único país com regiões distribuídas entre esses dois agrupamentos, indicando diferenças internas mais acentuadas principalmente quanto aos níveis de desemprego observados.

A distribuição regional reforça a pertinência de utilizar o nível NUTS-I como unidade de análise. A adoção exclusiva do país como unidade territorial poderia ocultar diferenças contextuais existentes entre suas regiões, reunindo sob uma mesma classificação nacional unidades com posições distintas nas variáveis desemprego e cidadania.

3.1.1 Estabilidade dos Clusters em Diferentes Janelas Temporais

Para avaliar a estabilidade dos resultados da clusterização diante de diferentes extensões temporais, foram comparadas janelas de três a seis anos, todas encerradas em 2019. A janela de três anos corresponde ao período de 2017 a 2019, a janela de quatro anos abrange o período de 2016 a 2019 até a janela de seis anos que corresponde ao período completo de 2014 a 2019, conforme ilustrado na Figura 3.3.

Figura 3.3: Janelas temporais utilizadas na avaliação da estabilidade dos clusters ($k = 3$)



Fonte: Elaboração própria.

O método do cotovelo foi aplicado separadamente para cada janela temporal, indicando uma solução com $k = 3$ em todos os intervalos considerados. Posteriormente, foram

comparadas tanto as quantidades de regiões quanto a composição individual dos agrupamentos. A Tabela 3.3 sintetiza as contagens obtidas em cada janela.

Tabela 3.3: Estabilidade dos clusters em diferentes janelas temporais

Cluster	3 anos	4 anos	5 anos	6 anos
1	30	30	30	30
2	48	48	48	47
3	8	8	8	9

Fonte: Elaboração própria.

Os resultados demonstram estabilidade nas quantidades de regiões pertencentes ao Cluster 1, que permaneceu com 30 unidades em todas as janelas temporais. A comparação dos códigos individuais confirmou que a composição dos grupos também permaneceu inalterada entre as janelas de três, quatro e cinco anos; a única mudança de pertença ocorreu quando o ano de 2014 foi incorporado à janela completa.

Essa alteração corresponde à região ES2, que pertence ao Cluster 2 nas janelas de três, quatro e cinco anos, mas passa a integrar o Cluster 3 quando considerada a janela completa de 2014 a 2019. Consequentemente, o Cluster 2 passa de 48 para 47 regiões, enquanto o Cluster 3 passa de 8 para 9 regiões.

A manutenção do número de agrupamentos e a ocorrência de apenas uma alteração na composição dos clusters indicam que a solução apresenta estabilidade diante das diferentes extensões temporais consideradas. A transição da região ES2 também demonstra que a incorporação de observações de períodos anteriores pode modificar o perfil contextual médio de determinadas unidades posicionadas próximas aos limites entre os agrupamentos.

Optou-se pela utilização da janela completa de seis anos, correspondente ao período de 2014 a 2019. Essa escolha permite considerar um intervalo temporal mais amplo, reduzindo a influência de oscilações anuais isoladas na caracterização contextual das regiões. Além disso, o período inclui o último ano anterior à adoção da Agenda 2030 e os primeiros anos posteriores à sua implementação.

3.1.1.1 Número mínimo de DMUs

Em DEA, o número de unidades avaliadas deve ser considerado em conjunto com a quantidade de *inputs* e *outputs*, pois o aumento do número de variáveis em relação ao número de DMUs reduz a capacidade do modelo de discriminar as unidades eficientes das ineficientes. A partir de considerações relacionadas aos graus de liberdade, Banker *et al.* (1989) recomendam, como regra prática, que o número de DMUs seja superior a três vezes a soma do número de *inputs* e *outputs*. Essa relação constitui uma orientação para a especificação do modelo, e não uma condição necessária para que a estimação DEA possa ser realizada. A relação entre o número de variáveis e a capacidade de discriminação também é discutida por Dyson *et al.*

(2001), que destacam a necessidade de compatibilizar a quantidade de fatores com o número de unidades avaliadas.

Para operacionalizar essa recomendação, adota-se como limiar de referência o critério de Banker *et al.* (1989), em que $n_{\min}$ representa o número mínimo de referência de DMUs, m corresponde ao número de *inputs* e s ao número de *outputs*. E é definido por:

$$n_{\min} = 3(m + s) \quad (3.1)$$

No ODS 4, o modelo utiliza um *input* fictício e cinco *outputs*, resultando em um limiar de 18 DMUs. Para o ODS 8, com um *input* fictício e quatro *outputs*, o valor correspondente é de 15 DMUs. Como as estimações BoD são realizadas separadamente para cada *cluster* e ano, a verificação deve considerar o número de DMUs disponível em cada grupo de comparação. A Tabela 3.4 apresenta essa relação.

Tabela 3.4: Adequação do número de DMUs ao critério de Banker et al. (1989)

ODS	m	s	$n_{\min}$	Cluster 1	Cluster 2	Cluster 3
ODS 4	1	5	$3(1 + 5) = 18$	30 (atende)	47 (atende)	9 (abaixo)
ODS 8	1	4	$3(1 + 4) = 15$	23 (atende)	31 (atende)	5 (abaixo)

Fonte: Elaboração própria.

Os Clusters 1 e 2 atendem ao critério nos dois ODS. O Cluster 3, por outro lado, apresenta número de DMUs inferior ao limiar de referência em ambas as aplicações. Essa condição não impede a estimação do modelo, mas reduz sua capacidade de discriminação, devendo ser considerada na interpretação dos escores obtidos para esse grupo.

Concluída a etapa de clusterização, a análise avança para a construção dos indicadores compostos associados aos ODS 4 e 8 por meio do método *Benefit-of-the-Doubt* (BoD). O modelo é aplicado separadamente em cada cluster e ano, permitindo que as regiões sejam comparadas com unidades inseridas em contextos socioeconômicos semelhantes.

3.2 *Benefit-of-the-Doubt*: Desempenho dos Indicadores Compostos

Para cada ODS, o modelo BoD foi executado separadamente para cada ano e para cada *cluster*, totalizando 18 estimações por ODS. Essa estrutura segue a abordagem de fronteiras contemporâneas apresentada na fundamentação teórica, na qual cada período é avaliado a partir de uma fronteira construída com as observações correspondentes ao próprio período. Neste estudo, a comparação também foi restrita às DMUs pertencentes ao mesmo *cluster*. Assim, cada escore é definido em relação à fronteira formada pelas DMUs do mesmo *cluster* e do mesmo ano. Portanto, o valor de 100% identifica uma unidade posicionada na fronteira de desempenho daquela execução e não representa, necessariamente, o cumprimento absoluto das metas associadas aos indicadores analisados.

As médias dos três *clusters* descrevem suas respectivas distribuições internas e, por serem obtidas a partir de fronteiras distintas, não constituem, isoladamente, uma classificação global entre os grupos.


As variações anuais também devem ser interpretadas como mudanças na posição relativa das DMUs em suas respectivas fronteiras contemporâneas, e não como uma medida direta de evolução temporal absoluta. Alterações nos escores podem decorrer tanto de mudanças nos resultados da própria DMU quanto de mudanças no desempenho das demais unidades que compõem seu conjunto de comparação em cada ano.

Para cada DMU, a média aritmética dos seis escores anuais é utilizada apenas como síntese descritiva de sua posição relativa recorrente nas seis fronteiras contemporâneas. Essa média não constitui um escore calculado em relação a uma fronteira intertemporal comum e, portanto, não representa uma medida direta de desempenho acumulado ou de evolução ao longo do período. Nas tabelas de resultados, essa média é apresentada na coluna localizada à extrema direita, enquanto a primeira linha apresenta a média das DMUs em cada ano e a média geral do respectivo *cluster* no período.

3.2.1 ODS 4. Educação de Qualidade

A aplicação do ODS 4 compreende as 86 DMUs consideradas na análise e preserva a classificação contextual definida anteriormente pelo procedimento de clusterização. Dessa forma, os escores BoD são estimados dentro dos grupos formados a partir das características contextuais das regiões, permitindo que cada DMU seja comparada com unidades pertencentes ao mesmo *cluster*. Essa mesma estrutura de classificação é retomada na aplicação do ODS 8, na Seção 3.2.2.

Os resultados obtidos para o ODS 4 foram reunidos nas Tabelas 3.5, 3.6 e 3.7. A organização das tabelas permite observar tanto os escores anuais de cada DMU quanto seu comportamento recorrente ao longo das seis estimações. A Figura 3.4 complementa essa apresentação ao sintetizar as médias anuais dos escores BoD dos três *clusters* no período analisado.

Figura 3.4: Médias anuais dos escores BoD por *cluster* (2014–2019)

Fonte: Elaboração própria.

A Figura 3.4 evidencia relativa estabilidade das médias anuais nos três agrupamentos. Os Clusters 1 e 2 apresentam trajetórias próximas, com elevação até 2018 e redução em 2019, enquanto o Cluster 3 permanece com médias mais elevadas e menor variação ao longo do período. Essas diferenças devem ser interpretadas exclusivamente em relação às fronteiras próprias de cada *cluster* e ano, não constituindo uma classificação absoluta entre os grupos.

Tabela 3.5: Cluster 1: escores BoD anuais (%)

		Média	90,91	91,58	91,51	91,71	92,25	90,61	91,43
Cluster	DMU	2014	2015	2016	2017	2018	2019	Média	
1	AT1	92,12	92,32	93,18	92,60	92,66	90,66	92,26	
1	AT2	91,60	92,00	92,07	93,36	92,64	89,16	91,80	
1	AT3	89,86	90,80	91,45	91,50	90,51	88,33	90,41	
1	BE1	94,26	93,93	93,97	96,08	96,55	94,30	94,85	
1	BE3	89,54	88,93	89,64	90,02	90,87	88,82	89,64	
1	CY0	90,07	92,17	90,72	90,80	92,10	90,65	91,08	
1	DE1	91,05	91,11	91,18	90,85	90,80	89,10	90,68	
1	DE2	89,11	90,08	89,01	89,40	89,07	86,59	88,88	
1	DE3	90,60	90,92	91,00	90,30	90,67	88,82	90,39	
1	DE5	86,18	89,61	86,38	87,66	89,79	85,79	87,57	
1	DE6	92,39	92,57	91,54	90,66	90,79	89,28	91,20	
1	DE7	89,03	89,00	88,93	88,66	89,10	87,59	88,72	

Continua na próxima página...

Tabela 3.5 – Cluster 1: escores BoD anuais (%)

	Média	90,91	91,58	91,51	91,71	92,25	90,61	91,43
Cluster	DMU	2014	2015	2016	2017	2018	2019	Média
1	DE9	87,99	88,07	87,13	87,11	87,89	85,93	87,36
1	DEA	87,85	87,96	87,35	86,87	87,58	85,44	87,18
1	DEB	90,10	89,79	90,03	89,52	89,96	87,63	89,51
1	DEC	88,71	87,71	88,53	87,08	87,50	85,96	87,58
1	EE0	87,24	88,05	89,38	90,04	91,47	89,83	89,33
1	FR1	99,22	99,38	99,24	99,66	99,58	99,94	99,50
1	IE0	90,99	90,82	91,50	93,89	96,95	95,36	93,25
1	ITC	85,09	84,94	85,97	85,76	86,64	85,92	85,72
1	ITF	85,53	86,30	87,27	86,72	88,05	86,43	86,72
1	ITF6	85,37	85,31	85,68	85,61	85,45	85,28	85,45
1	LV0	86,83	87,22	88,24	88,60	88,54	87,44	87,81
1	NO0	96,90	97,95	96,74	96,50	96,90	95,01	96,67
1	SE1	100,00	100,00	100,00	100,00	100,00	100,00	100,00
1	UKF	92,65	96,87	95,65	95,57	96,55	94,26	95,26
1	UKG	91,77	94,93	94,83	94,36	95,51	94,20	94,27
1	UKH	91,64	94,70	95,74	95,10	95,74	94,38	94,55
1	UKI	100,00	100,00	100,00	100,00	100,00	100,00	100,00
1	UKJ	93,62	94,09	92,88	97,08	97,56	96,13	95,23

Fonte: Elaboração própria.

O Cluster 1 é composto por 30 regiões e foi caracterizado, na etapa de clusterização, pelo menor nível médio de desemprego (6,17%) e pela menor proporção de residentes com cidadania nacional (85%). No modelo BoD, o grupo apresentou escore médio de 91,43% no período. As médias anuais variaram entre 90,61%, em 2019, e 92,25%, em 2018, sem formar uma trajetória monotônica.

As regiões SE1 e UKI permaneceram sobre a fronteira em todas as seis estimações, alcançando média de 100%. FR1 também se manteve muito próxima da fronteira, com média de 99,50%, seguida por NO0, com 96,67%. Entre as regiões do Reino Unido, UKF, UKG, UKH e UKJ apresentaram médias entre 94,27% e 95,26%. Esses resultados identificam as unidades que ocuparam as posições superiores da distribuição interna do Cluster 1. A concentração de algumas regiões de determinados países entre os maiores escores é um achado descritivo da amostra e, por si só, não permite atribuir o resultado a características nacionais, institucionais ou econômicas específicas.

Na extremidade inferior da distribuição encontram-se ITF6, ITC e ITF, com médias de 85,45%, 85,72% e 86,72%, respectivamente. Também aparecem nessa faixa DEA, DE9,

DE5, DEC e LV0, cujas médias permaneceram entre 87,18% e 87,81%. Esses valores indicam maior distância em relação às melhores combinações de desempenho observadas dentro do Cluster 1, mas não representam necessariamente resultados educacionais baixos em termos absolutos. A identificação dos fatores associados a essas diferenças exigiria examinar, para cada DMU, os pesos atribuídos aos indicadores, suas contribuições para o escore e as respectivas referências de comparação; o resultado agregado do BoD, isoladamente, não permite determinar suas causas.

Tabela 3.6: Cluster 2: escores BoD anuais (%)

	Média	90,13	90,83	90,68	90,95	91,27	90,06	90,66
Cluster	DMU	2014	2015	2016	2017	2018	2019	Média
2	BE2	93,42	93,27	93,95	93,89	94,54	93,13	93,70
2	BG3	76,26	76,21	74,91	76,34	75,88	72,88	75,41
2	BG4	84,69	84,90	84,14	85,34	85,97	83,56	84,77
2	CZ0	89,54	89,68	89,32	90,20	89,79	87,57	89,35
2	DE4	87,38	87,67	87,16	86,37	86,27	85,34	86,70
2	DE8	87,43	87,71	87,87	87,37	86,86	86,42	87,28
2	DED	89,91	90,27	89,73	89,23	89,32	87,82	89,38
2	DEE	87,63	87,19	86,46	85,50	87,62	84,52	86,49
2	DEF	88,36	88,29	87,83	87,25	88,88	85,86	87,74
2	DEG	89,78	89,44	88,61	89,41	89,55	88,01	89,13
2	FI1	96,91	96,38	96,82	96,91	97,87	96,37	96,88
2	FRB	95,81	97,08	96,36	96,73	97,52	96,11	96,60
2	FRC	95,90	95,08	96,42	96,05	95,97	95,26	95,78
2	FRD	94,55	96,57	95,90	95,72	96,15	95,46	95,72
2	FRE	95,98	95,71	95,77	95,62	96,21	95,35	95,77
2	FRF	94,86	96,47	96,47	95,86	96,83	96,50	96,16
2	FRG	97,91	98,50	98,39	99,61	98,79	97,82	98,50
2	FRH	99,38	98,76	99,18	98,10	100,00	98,14	98,93
2	FRI	96,61	97,62	97,09	97,74	97,78	96,82	97,28
2	FRJ	100,00	98,76	98,86	98,90	99,81	98,06	99,06
2	FRK	100,00	100,00	100,00	100,00	100,00	100,00	100,00
2	FRL	96,86	97,89	97,34	96,82	96,37	95,89	96,86
2	HR0	87,93	88,79	88,75	88,59	89,07	88,31	88,57
2	HU1	88,81	89,81	87,89	89,79	90,62	89,86	89,46
2	HU2	82,16	85,28	85,30	84,61	83,67	83,07	84,01
2	HU3	81,59	84,29	84,97	85,32	85,36	84,92	84,41

Continua na próxima página...

Tabela 3.6 – Cluster 2: escores BoD anuais (%)

	Média	90,13	90,83	90,68	90,95	91,27	90,06	90,66
Cluster	DMU	2014	2015	2016	2017	2018	2019	Média
2	LT0	95,26	98,30	98,45	99,35	100,00	97,73	98,18
2	PL2	89,51	89,69	90,71	91,38	92,61	90,09	90,66
2	PL4	86,49	87,02	87,28	87,74	88,50	87,43	87,41
2	PL5	87,26	87,46	86,91	90,20	91,85	89,56	88,87
2	PL6	85,73	86,89	86,63	87,11	86,78	86,30	86,57
2	PT1	82,56	84,88	84,57	85,86	86,37	86,19	85,07
2	PT2	77,03	78,35	78,36	79,69	80,85	80,68	79,16
2	RO1	80,59	80,33	80,52	80,27	77,51	75,78	79,17
2	RO2	73,23	74,17	73,19	72,77	72,53	72,52	73,07
2	RO3	77,09	78,68	78,77	80,10	79,59	79,47	78,95
2	RO4	78,85	80,10	79,48	78,25	80,04	80,72	79,57
2	SE2	100,00	100,00	100,00	100,00	100,00	100,00	100,00
2	SE3	96,48	98,52	97,96	98,83	98,26	97,90	97,99
2	SI0	92,28	92,87	92,67	94,05	93,27	91,78	92,82
2	SK0	85,71	86,29	85,75	85,04	86,01	84,92	85,62
2	UKC	93,21	96,13	95,22	95,01	94,67	93,62	94,64
2	UKD	93,63	96,18	96,75	96,13	96,01	94,83	95,59
2	UKE	92,18	96,79	95,96	95,88	95,77	94,30	95,15
2	UKK	95,33	93,50	94,90	97,81	97,63	96,24	95,90
2	UKL	93,88	91,34	92,53	92,11	94,83	89,88	92,43
2	UKM	100,00	100,00	100,00	100,00	100,00	100,00	100,00

Fonte: Elaboração própria.

O Cluster 2 reúne 47 regiões, sendo o maior dos três grupos, e foi caracterizado por elevada proporção média de residentes com cidadania nacional (96,4%) e baixo nível médio de desemprego (6,91%). Seu escore médio no período foi de 90,66%. As médias anuais permaneceram entre 90,06%, em 2019, e 91,27%, em 2018, apresentando variação limitada.

As regiões FRK, SE2 e UKM permaneceram sobre a fronteira em todos os anos, com média de 100%, enquanto FRJ registrou 99,06%. Outros escores próximos à fronteira foram observados para FRH (98,93%), FRG (98,50%), LT0 (98,18%), SE3 (97,99%) e FRI (97,28%). Verifica-se, assim, a presença recorrente de regiões francesas entre os maiores escores do grupo, juntamente com unidades da Suécia, do Reino Unido e da Lituânia. Essa concentração territorial descreve a composição das unidades de maior escore do Cluster 2, mas não demonstra a existência de um efeito nacional nem identifica quais características dos respectivos sistemas educacionais explicariam essas posições.

O Cluster 2 também apresenta a maior amplitude entre os escores médios individuais. RO2 registrou a menor média do grupo, com 73,07%, seguida por BG3, com 75,41%. Permaneceram abaixo de 80% PT2 (79,16%), RO1 (79,17%), RO3 (78,95%) e RO4 (79,57%). A presença de quatro regiões romenas nessa faixa constitui um padrão territorial relevante para investigação, porém não permite concluir que a localização nacional seja a causa do desempenho observado. O escore BoD informa a distância relativa dessas unidades em relação à fronteira do Cluster 2, mas não mensura diretamente gestão, qualidade das políticas públicas, estrutura institucional ou alocação de recursos.

A dispersão mais ampla do Cluster 2 deve ser interpretada considerando também seu maior número de DMUs e a variedade de perfis reunidos na mesma fronteira. Os resultados permitem identificar unidades mais distantes das referências internas e orientar análises posteriores dos indicadores em que se concentram suas diferenças. Contudo, a determinação de mecanismos explicativos exigiria incorporar variáveis adicionais ou realizar uma análise desagregada dos pesos, das contribuições de cada indicador e dos *benchmarks* específicos de cada DMU.

Tabela 3.7: Cluster 3: escores BoD anuais (%)

		Média	96,32	96,01	95,70	95,49	95,38	96,08	95,83
Cluster	DMU	2014	2015	2016	2017	2018	2019	Média	
3	ES1	97,49	97,58	96,85	97,27	97,33	98,05	97,43	
3	ES2	100,00	100,00	100,00	100,00	100,00	100,00	100,00	
3	ES3	100,00	100,00	100,00	100,00	100,00	100,00	100,00	
3	ES4	96,95	96,62	95,97	96,13	96,18	96,88	96,45	
3	ES5	95,96	95,88	94,78	95,78	96,59	97,11	96,02	
3	ES6	95,51	95,47	95,01	95,10	95,21	95,98	95,38	
3	ES7	94,73	93,74	94,07	94,39	94,04	94,66	94,27	
3	ITH1	94,10	93,55	93,41	92,08	91,06	92,28	92,75	
3	ITI2	92,17	91,26	91,19	88,62	88,03	89,73	90,17	

Fonte: Elaboração própria.

O Cluster 3 contém nove regiões e foi caracterizado pelo maior nível médio de desemprego (18,9%) e por uma proporção média de cidadania nacional de 90%. O grupo apresentou escore médio de 95,83% no período, com médias anuais entre 95,38%, em 2018, e 96,32%, em 2014. Essa pequena amplitude mostra que, em cada execução anual, as unidades permaneceram, em média, próximas à fronteira formada pelas regiões do próprio cluster.


As regiões ES2 e ES3 permaneceram na fronteira em todos os anos e registraram média de 100%. ES1 apresentou média de 97,43%, seguida por ES4, ES5 e ES6, com 96,45%, 96,02% e 95,38%, respectivamente. ES7 registrou 94,27%, enquanto ITH1 e ITI2 apresentaram as menores médias do grupo, com 92,75% e 90,17%. No caso de ITI2, os escores ficaram

abaixo de 90% entre 2017 e 2019, embora sua média dos seis anos tenha permanecido ligeiramente acima desse patamar. A predominância de regiões espanholas entre as unidades mais próximas da fronteira descreve a composição deste cluster, mas não permite concluir que políticas nacionais, mecanismos institucionais ou formas específicas de gestão sejam responsáveis por essa posição.

A concentração dos escores em níveis próximos à fronteira indica baixa dispersão interna no conjunto analisado. Todavia, esse resultado deve ser interpretado com cautela, pois o Cluster 3 possui apenas nove DMUs para cinco indicadores educacionais. O número reduzido de unidades limita o conjunto de comparações disponível para a construção da fronteira e pode diminuir a capacidade de discriminação do modelo. Portanto, a média mais elevada deste cluster não constitui evidência de desempenho educacional absoluto superior aos demais grupos, nem demonstra que o desemprego tenha efeito nulo sobre os resultados. O que se observa é a coexistência, dentro desse conjunto específico de regiões, de maior desemprego médio e escores BoD relativamente próximos à sua própria fronteira.

A Figura 3.5 complementa as tabelas anteriores ao apresentar conjuntamente a distribuição dos escores anuais das DMUs em cada *cluster* ao longo das seis estimações. Cada DMU contribui, portanto, com um escore em cada ano do período; os valores de *n* indicados nos rótulos do gráfico correspondem ao número de DMUs pertencentes a cada *cluster*, e não ao número total de observações anuais representadas.

Figura 3.5: Distribuição da média dos escores anuais do ODS 4 por *cluster* (2014–2019)



Fonte: Elaboração própria.

A Figura 3.5 permite comparar a dispersão dos escores anuais reunidos nas seis execuções de cada agrupamento. O Cluster 1 apresenta concentração intermediária, enquanto o Cluster 2 exibe a maior amplitude visual e reúne observações distribuídas por uma faixa mais ampla de escores. No Cluster 3, a maior parte dos escores anuais permanece concentrada na porção superior da escala, embora apareçam poucos valores abaixo do corpo principal da

distribuição; esses pontos correspondem a resultados de anos específicos e não à média de seis anos das respectivas DMUs. Como cada ano possui uma fronteira própria, a figura deve ser interpretada apenas como síntese descritiva da dispersão dos escores anuais, sem atribuir aos pontos mais afastados significado de erro nos dados ou de trajetória intertemporal.

Complementarmente, a Tabela 3.8 adota outra unidade de síntese: cada DMU aparece uma única vez, classificada segundo a média de seus seis escores anuais. A figura descreve, portanto, a distribuição dos resultados anuais, enquanto a tabela resume a posição média das DMUs no período; em ambos os casos, deve-se preservar a ressalva de que cada *cluster* e cada ano foram avaliados em relação a fronteiras próprias.

Tabela 3.8: Distribuição das DMUs por faixa de escore médio

Faixa de Escore médio (%)	Cluster 1	Cluster 2	Cluster 3
100%	2	3	2
99%	1	1	0
90%	14	20	7
80%	13	17	0
70%	0	6	0
Total	30	47	9

Fonte: Elaboração própria.

A distribuição por faixas mostra que a maior parte das DMUs apresentou escores médios iguais ou superiores a 80%. Essa constatação descreve a proximidade das unidades em relação às fronteiras construídas em seus respectivos grupos, não devendo ser interpretada como comprovação de que as metas do ODS 4 foram plenamente cumpridas. Os escores refletem uma avaliação multidimensional relativa, condicionada às DMUs comparáveis e à flexibilidade dos pesos do modelo BoD.

No Cluster 1, 14 das 30 DMUs encontram-se entre 90,00% e 98,99%, 13 entre 80,00% e 89,99%, duas alcançam 100,00% e uma se encontra entre 99,00% e 99,99%. A distribuição indica que o grupo possui referências claramente definidas e uma parcela relevante de unidades situada a uma distância moderada da fronteira. Como nenhuma DMU apresenta média inferior a 80%, a amplitude interna é menor do que a observada no Cluster 2. Ainda assim, a presença de 13 unidades entre 80,00% e 89,99% mostra que os resultados não são uniformes e que existe espaço para examinar quais indicadores diferenciam essas regiões das referências internas.

O Cluster 2 apresenta a distribuição mais espalhada. Entre suas 47 DMUs, 20 estão entre 90,00% e 98,99%, 17 entre 80,00% e 89,99%, seis entre 70,00% e 79,99%, três alcançam 100,00% e uma se encontra entre 99,00% e 99,99%. O grupo reúne, portanto, unidades posicionadas na fronteira e outras relativamente mais distantes dela. Essa heterogeneidade não deve ser descrita como deficiência na transformação de recursos, pois o BoD empregado utiliza um

input fictício e agrega indicadores educacionais. As unidades das faixas inferiores representam prioridades para uma análise diagnóstica das dimensões em que se afastam de seus *benchmarks*, mas o modelo não permite, isoladamente, prescrever políticas ou atribuir o resultado a falhas de gestão.


No Cluster 3, as nove DMUs estão concentradas entre 90,00% e 98,99% e em 100,00%, com sete e duas unidades, respectivamente. Essa configuração evidencia maior proximidade interna em relação à fronteira específica do grupo. Contudo, ela deve ser analisada juntamente com o tamanho reduzido do cluster, que oferece menos unidades para comparação e pode limitar a discriminação do modelo. Por essa razão, a ausência de DMUs abaixo de 90% não é suficiente para classificar o Cluster 3 como globalmente superior aos demais, cujos escores foram produzidos por fronteiras diferentes e por conjuntos de tamanhos distintos.

Em conjunto, os resultados permitem identificar três padrões intragrupo: concentração intermediária no Cluster 1, maior dispersão no Cluster 2 e maior proximidade à fronteira no Cluster 3. Essas diferenças são úteis para o *benchmarking* contextual, pois SE1, UKI, FRK, SE2, UKM, ES2 e ES3 constituem referências persistentes dentro de seus respectivos grupos ao permanecerem sobre a fronteira em todos os anos. Para avançar nessa direção, seriam necessárias análises complementares que considerassem as contribuições individuais dos indicadores, os pesos ótimos, as referências de cada DMU e variáveis explicativas adicionais.

3.2.2 ODS 8. Trabalho Decente e Crescimento Econômico

A aplicação do ODS 8 reúne 59 DMUs com resultados completos: 23 regiões no *Cluster 1*, 31 no *Cluster 2* e cinco no *Cluster 3*. Como descrito na Seção 2.3, essas regiões preservam a classificação contextual obtida com as 86 DMUs do ODS 4. A redução do número de DMUs decorre apenas da disponibilidade dos dados.

Os resultados foram reunidos nas Tabelas 3.9, 3.10 e 3.11, seguindo a mesma organização adotada para o ODS 4. A Figura 3.6 sintetiza as médias anuais dos escores BoD dos três *clusters* no período analisado.

Figura 3.6: Médias anuais dos escores BoD do ODS 8 por *cluster* (2014–2019)

Fonte: Elaboração própria.

A Figura 3.6 mostra trajetórias distintas entre os três grupos. No Cluster 1, a média anual passou de 92,76% em 2014 para 87,78% em 2015 e terminou o período em 90,55%, com amplitude de 4,98 pontos percentuais entre o maior e o menor valor anual. No Cluster 2, a maior média ocorreu em 2016, com 91,88%, e a menor em 2018, com 82,47%, resultando em amplitude de 9,41 pontos percentuais; em 2019, a média foi de 83,97%.

O Cluster 3 apresentou amplitude de 9,94 pontos percentuais, com média de 93,61% em 2015 e 83,67% em 2016, encerrando 2019 em 92,46%. Como o grupo contém cinco DMUs, cada região representa 20% das observações utilizadas na média anual. As oscilações observadas nos três grupos não representam crescimento ou regressão absoluta do ODS 8, pois as fronteiras e os pesos são recalculados separadamente em cada ano.

Tabela 3.9: Cluster 1: escores BoD anuais do ODS 8 (%)

		Média	92,76	87,78	89,47	88,96	88,86	90,55	89,73
Cluster	DMU	2014	2015	2016	2017	2018	2019	Média	
1	AT1	89,36	86,79	91,95	86,99	88,35	88,26	88,62	
1	AT2	95,29	88,65	89,77	96,62	89,06	93,55	92,16	
1	AT3	93,70	92,57	88,20	92,22	89,57	91,56	91,30	
1	BE1	98,09	89,43	79,19	84,86	94,09	90,02	89,28	
1	BE3	90,40	80,14	82,53	79,37	88,59	91,60	85,44	
1	CY0	79,30	84,41	100,00	86,26	97,88	100,00	91,31	
1	DE1	98,69	93,65	92,80	97,30	91,58	89,26	93,88	

Continua na próxima página...

Tabela 3.9 – Cluster 1: escores BoD anuais do ODS 8 (%)

		Média	92,76	87,78	89,47	88,96	88,86	90,55	89,73
Cluster	DMU	2014	2015	2016	2017	2018	2019	Média	
1	DE2	100,00	92,52	96,66	97,84	86,20	94,35	94,59	
1	DE3	100,00	96,86	100,00	100,00	100,00	100,00	99,48	
1	DE5	91,85	80,82	86,63	82,67	82,46	78,28	83,78	
1	DE6	88,71	91,32	91,33	89,08	86,73	99,59	91,13	
1	DE7	95,59	87,15	94,96	90,82	86,70	91,80	91,17	
1	DE9	97,58	81,40	100,00	83,63	87,27	91,80	90,28	
1	DEA	94,60	87,07	87,35	90,97	86,94	85,88	88,80	
1	DEB	95,70	90,84	88,38	86,68	84,15	88,93	89,11	
1	DEC	99,99	84,36	81,66	88,86	82,91	82,33	86,69	
1	EE0	100,00	86,72	94,94	100,00	100,00	100,00	96,94	
1	FR1	95,85	100,00	95,82	98,18	95,99	100,00	97,64	
1	ITC	83,97	80,18	84,24	82,60	80,35	82,97	82,39	
1	ITF	66,77	68,16	62,94	61,73	67,39	70,90	66,31	
1	ITF6	80,24	75,85	81,88	77,95	77,60	85,01	79,75	
1	LV0	97,75	100,00	91,30	100,00	100,00	86,59	95,94	
1	SE1	100,00	100,00	95,38	91,39	100,00	100,00	97,80	

Fonte: Elaboração própria.

O Cluster 1 contém 23 regiões e apresentou escore médio de 89,73% no período. As médias anuais variaram de 87,78% a 92,76%. Nenhuma DMU do Cluster 1 permaneceu na fronteira nas seis estimações. DE3 apresentou 100% em cinco anos e a maior média do grupo, com 99,48%. SE1 registrou quatro escores de 100% e média de 97,80%, enquanto FR1 apresentou dois escores de 100% e média de 97,64%. Essas unidades aparecem entre as referências recorrentes do grupo, embora a composição dos pesos possa variar entre anos e DMUs.

Na outra extremidade da distribuição, ITF apresentou a menor média do grupo, com 66,31%, seguida por ITF6, com 79,75%, e ITC, com 82,39%. O escore agregado identifica a posição dessas unidades em relação às referências internas, mas não determina qual dos quatro indicadores responde por essa distância. Essa identificação exigiria examinar os pesos, as contribuições de cada indicador e os *benchmarks* específicos de cada DMU.

Tabela 3.10: Cluster 2: escores BoD anuais do ODS 8 (%)

	Média	90,88	90,69	91,88	88,69	82,47	83,97	88,10
Cluster	DMU	2014	2015	2016	2017	2018	2019	Média
2	BE2	95,12	94,01	92,65	85,97	80,69	85,23	88,94
2	BG3	73,75	77,43	99,84	78,23	75,20	69,12	78,93
2	BG4	86,97	100,00	91,03	88,64	82,70	100,00	91,56
2	CZ0	94,90	100,00	93,80	94,90	84,04	88,86	92,75
2	DE4	96,66	89,20	92,99	88,43	79,17	83,79	88,37
2	DE8	93,15	86,63	89,82	91,82	73,40	87,71	87,09
2	DED	97,59	95,32	95,27	89,67	83,69	86,17	91,28
2	DEE	90,03	86,40	92,94	83,53	77,79	84,48	85,86
2	DEF	92,12	90,13	92,63	89,22	79,54	85,56	88,20
2	DEG	100,00	91,82	95,07	90,43	82,50	84,58	90,73
2	FI1	92,56	92,81	96,97	93,78	79,60	85,99	90,28
2	FRD	84,46	86,80	80,56	77,67	73,11	76,28	79,81
2	FRE	81,85	81,73	77,41	80,44	72,32	76,18	78,32
2	FRF	86,19	82,44	80,88	82,90	76,13	78,14	81,11
2	FRH	95,15	91,13	90,97	89,17	77,05	84,05	87,92
2	FRI	88,93	87,46	85,93	83,69	77,20	79,57	83,80
2	FRJ	90,11	86,48	86,77	83,79	77,61	80,38	84,19
2	HR0	76,94	87,37	100,00	81,85	81,28	84,00	85,24
2	HU1	100,00	100,00	100,00	100,00	100,00	100,00	100,00
2	HU2	90,65	97,17	97,67	87,36	82,02	85,07	89,99
2	HU3	85,95	91,85	84,43	89,09	93,37	80,34	87,51
2	LT0	96,41	91,56	93,96	97,65	91,16	87,53	93,04
2	PT1	86,17	88,18	89,05	86,77	81,31	85,37	86,14
2	RO1	100,00	81,16	97,85	100,00	92,77	78,44	91,70
2	RO2	86,56	76,24	79,20	87,94	77,58	74,85	80,40
2	RO3	100,00	94,01	98,20	100,00	96,32	88,00	96,09
2	RO4	86,07	100,00	100,00	86,91	100,00	80,35	92,22
2	SE2	95,19	100,00	92,37	88,71	80,62	87,94	90,81
2	SE3	89,69	93,97	91,55	88,02	78,14	85,87	87,87
2	SI0	95,90	96,60	100,00	98,65	88,09	87,93	94,53
2	SK0	88,10	93,62	88,63	84,24	82,26	81,23	86,35

Fonte: Elaboração própria.

O Cluster 2 reúne 31 regiões e apresentou escore médio de 88,10% no período. As médias anuais variaram de 82,47% a 91,88%. A maior média ocorreu em 2016, seguida por

redução em 2017 e 2018 e valor de 83,97% em 2019.

HU1 permaneceu na fronteira nas seis estimações e apresentou média de 100%. RO3 registrou a segunda maior média do grupo, com 96,09%, seguido por SI0, com 94,53%. Outras DMUs alcançaram a fronteira em anos específicos, mas não permaneceram em 100% durante todo o período.

FRE apresentou a menor média do Cluster 2, com 78,32%, seguida por BG3, com 78,93%, e FRD, com 79,81%. Essas posições identificam as unidades que, sob a ponderação mais favorável permitida pelo modelo, permaneceram abaixo das referências internas do grupo. O escore, isoladamente, não permite associar essa posição a produtividade, inserção dos jovens, estrutura de emprego tecnológico ou crescimento do PIB real por habitante.

Tabela 3.11: Cluster 3: escores BoD anuais do ODS 8 (%)

		Média	85,39	93,61	83,67	87,72	88,73	92,46	88,60
Cluster	DMU	2014	2015	2016	2017	2018	2019	Média	
3	ES3	100,00	100,00	100,00	100,00	100,00	100,00	100,00	100,00
3	ES4	84,47	92,97	90,48	82,43	100,00	98,26	91,43	
3	ES7	81,62	80,02	78,50	100,00	85,33	81,44	84,49	
3	ITH1	100,00	95,05	87,86	89,28	87,70	95,70	92,60	
3	ITI2	60,85	100,00	61,48	66,88	70,64	86,93	74,46	

Fonte: Elaboração própria.


O Cluster 3 contém cinco regiões e apresentou média de 88,60% no período. As médias anuais variaram de 83,67% a 93,61%. Como cada DMU corresponde a 20% do grupo, a distribuição e a quantidade de unidades na fronteira devem ser interpretadas considerando esse tamanho amostral.

ES3 permaneceu na fronteira nas seis estimações e apresentou média de 100%. ITH1 apresentou média de 92,60% e ES4 de 91,43%, enquanto ES7 registrou 84,49% e ITI2 74,46%. Dessa forma, a distância entre a maior e a menor média individual do grupo foi de 25,54 pontos percentuais.

ITI2 registrou 100% em 2015, mas ficou abaixo desse valor nos demais anos. Essa alternância não representa, por si só, progresso ou regressão temporal, pois cada execução utiliza uma nova fronteira e novos pesos. Além disso, a relação entre cinco DMUs e quatro indicadores reduz o número de comparações disponíveis e limita a diferenciação produzida pelo modelo em algumas execuções.

A Figura 3.7 complementa as tabelas individuais ao apresentar a distribuição dos escores médios das DMUs em cada *cluster*. Cada região contribui com uma única observação no gráfico, correspondente à média de seus seis escores anuais.

Figura 3.7: Distribuição da média dos escores do ODS 8 por *cluster* (2014–2019)



Fonte: Elaboração própria.

A Figura 3.7 utiliza uma observação por DMU, correspondente aos escores anuais. No Cluster 1, a mediana foi de 91,13%, com primeiro e terceiro quartis de 87,66% e 94,24%, respectivamente. ITF, com média de 66,31%, aparece como a única observação abaixo do limite inferior representado no boxplot. ITF6, com 79,75%, permanece dentro dos limites da distribuição, embora apresente a segunda menor média do grupo.

No Cluster 2, a mediana foi de 88,20%, com primeiro quartil de 85,55% e terceiro quartil de 91,42%. As médias individuais variaram de 78,32% a 100%, sem observações representadas como outliers no gráfico. No Cluster 3, a mediana foi de 91,43%, com primeiro e terceiro quartis de 84,49% e 92,60%. ITI2 apresentou a menor média, com 74,46%, mas permaneceu dentro dos limites do boxplot. Como esse agrupamento contém apenas cinco regiões, a forma da distribuição deve ser interpretada em conjunto com os valores individuais apresentados na Tabela 3.11.

A leitura conjunta das Figuras 3.6 e 3.7 separa dois aspectos dos resultados. A primeira descreve como a média de cada grupo varia entre as seis fronteiras anuais; a segunda mostra como as médias individuais das DMUs se distribuem no período. Em ambos os casos, as medidas permanecem condicionadas às fronteiras específicas de cada *cluster*, de modo que diferenças entre linhas, medianas ou quartis não constituem uma classificação direta entre os três grupos.

Complementarmente, a Tabela 3.12 sintetiza a distribuição das DMUs segundo as faixas de seus escores médios.

Tabela 3.12: Distribuição das DMUs do ODS 8 por faixa de escore médio

Faixa de Escore médio (%)	Cluster 1	Cluster 2	Cluster 3
100%	0	1	1
99%	1	0	0
90%	12	11	2
80%	8	16	1
70%	1	3	1
60%	1	0	0
Total	23	31	5

Fonte: Elaboração própria.

No Cluster 1, 13 das 23 DMUs apresentaram escore médio igual ou superior a 90%; no Cluster 2, foram 12 de 31; e no Cluster 3, três de cinco. O Cluster 1 também apresentou uma DMU com média entre 60% e 70%, enquanto três DMUs do Cluster 2 e uma do Cluster 3 ficaram na faixa entre 70% e 80%. Esses valores descrevem a posição das unidades em relação às respectivas fronteiras e não o grau de cumprimento das metas do ODS 8.

A distribuição por faixas deve ser lida junto à flexibilidade dos pesos do BoD e ao tamanho de cada grupo. Duas DMUs podem atingir escores semelhantes por combinações diferentes dos quatro indicadores. No Cluster 3, a relação entre cinco DMUs e quatro indicadores acrescenta uma restrição à capacidade de diferenciação entre as unidades.

Em síntese, nenhuma DMU do Cluster 1 permaneceu na fronteira nas seis execuções, embora DE3 tenha registrado 100% em cinco anos. HU1, no Cluster 2, e ES3, no Cluster 3, permaneceram na fronteira em todas as estimações anuais. Os resultados identificam referências internas e unidades mais afastadas dessas referências.

3.2.2.1 Sensibilidade à Escolha de ϵ

O valor de ϵ empregado na translação define a distância entre zero e o menor valor transformado e pode alterar os escores produzidos pelo modelo. Para avaliar a sensibilidade a essa escolha, as 18 estimações do ODS 8 foram repetidas com valores correspondentes a 0,1%, 0,5%, 1%, 5% e 10% do menor valor positivo de cada variável no respectivo cluster e ano. O cenário de 1% corresponde à especificação utilizada nos resultados principais e foi adotado como referência para as comparações.

Tabela 3.13: Médias gerais dos escores do ODS 8 sob diferentes valores de ϵ

Valor de ϵ^*	Cluster 1	Cluster 2	Cluster 3
0,1%	89,7253%	88,0949%	88,5945%
0,5%	89,7274%	88,0963%	88,5951%
1%	89,7300%	88,0981%	88,5959%
5%	89,7505%	88,1125%	88,6022%
10%	89,7760%	88,1304%	88,6101%
Amplitude (p.p.)	0,0507	0,0356	0,0156

* Percentual aplicado ao menor valor positivo de cada variável com pelo menos um valor negativo para o respectivo cluster e ano.

Fonte: Elaboração própria.

A variação de ϵ entre 0,1% e 10% produz alterações pequenas nos escores médios dos três *clusters*. Em todos os grupos, observa-se aumento dos escores à medida que ϵ cresce, indicando uma relação consistente entre o valor adotado para a translação e o resultado do modelo. Entretanto, mesmo entre os valores extremos testados, a amplitude foi de apenas 0,0507 ponto percentual no Cluster 1, 0,0356 no Cluster 2 e 0,0156 no Cluster 3. O Cluster 1 apresentou, portanto, a maior sensibilidade à variação de ϵ , enquanto o Cluster 3 apresentou a menor. Considerando que o parâmetro foi ampliado de 0,1% para 10%, uma variação de cem vezes, as mudanças observadas nos escores permaneceram inferiores a 0,051 ponto percentual. Assim, dentro do intervalo analisado, os resultados agregados do modelo apresentam baixa sensibilidade à escolha de ϵ .

3.2.3 Análise conjunta dos ODS 4 e 8 por *cluster*

Após a análise separada dos dois indicadores compostos, é possível examinar se determinadas posições relativas se repetem entre os ODS 4 e 8 dentro dos mesmos perfis contextuais. Essa leitura considera as 59 DMUs presentes nas duas aplicações, distribuídas em 23 regiões no Cluster 1, 31 no Cluster 2 e cinco no Cluster 3. Os valores dos escores não são comparados de forma aritmética, pois o ODS 4 utiliza cinco indicadores e 86 DMUs, enquanto o ODS 8 utiliza quatro indicadores e 59 DMUs. Além disso, cada aplicação constrói fronteiras próprias para cada *cluster* e ano. A análise conjunta se limita, portanto, à recorrência ou à mudança das posições ocupadas pelas DMUs nas respectivas distribuições e à permanência sobre as fronteiras anuais.

Tabela 3.14: Referências persistentes nos ODS 4 e 8 por *cluster*

Cluster	ODS 4	ODS 8	Referência comum
Cluster 1	SE1; UKI	-	-
Cluster 2	FRK; SE2; UKM	HU1	-
Cluster 3	ES2; ES3	ES3	ES3

Fonte: Elaboração própria.

Começando pelo Cluster 1, as DMUs do ODS 4, SE1 e UKI permaneceram na fronteira nas seis estimações. No ODS 8, nenhuma das 23 DMUs do grupo apresentou essa condição. Entre as referências persistentes do ODS 4, apenas SE1 está presente na amostra do ODS 8; nessa aplicação, a região alcançou 100% em quatro anos e apresentou a segunda maior média do grupo, com 97,80%. FR1 também repetiu uma posição superior, registrando a terceira maior média nas duas aplicações: 99,50% no ODS 4 e 97,64% no ODS 8. Na parte inferior das distribuições, ITF, ITF6 e ITC constituíram as três menores médias do Cluster 1 nos dois objetivos, embora em ordens diferentes. No ODS 4, as médias foram de 85,45% para ITF6, 85,72% para ITC e 86,72% para ITF; no ODS 8, foram de 66,31% para ITF, 79,75% para ITF6 e 82,39% para ITC. Em contraste, DE3 apresentou média de 90,39% no ODS 4, enquanto no ODS 8 registrou a maior média do grupo, com 99,48%, e alcançou 100% em cinco dos seis anos.

Analisando o cluster 2, as regiões do ODS 4, FRK, SE2 e UKM permaneceram na fronteira em todas as estimações. FRK e UKM não integram a amostra do ODS 8, enquanto SE2 alcançou 100% apenas em 2015 e apresentou média de 90,81% nessa aplicação. No ODS 8, HU1 foi a única referência persistente, com 100% nos seis anos, após registrar média de 89,46% no ODS 4. Na parte inferior das distribuições, BG3 apresentou a segunda menor média nas duas aplicações, com 75,41% no ODS 4 e 78,93% no ODS 8. Outras mudanças também foram observadas. FRE apresentou a 16ª maior média entre as 47 DMUs do ODS 4, com 95,77%, mas registrou a menor média entre as 31 DMUs do ODS 8, com 78,32%. Esses resultados mostram que a permanência no mesmo perfil contextual não implica a repetição da posição relativa quando são alterados o domínio avaliado, os indicadores e a composição da fronteira.

No Cluster 3 as regiões ES2 e ES3 permaneceram na fronteira nos seis anos do ODS 4. Como ES2 não integra a amostra do ODS 8, ES3 foi a única referência persistente comum às duas aplicações. ITI2 apresentou a menor média do grupo nos dois objetivos, com 90,17% no ODS 4 e 74,46% no ODS 8. ITH1, por sua vez, ocupou a segunda menor posição entre as nove DMUs do ODS 4 e a segunda maior entre as cinco DMUs do ODS 8. Suas médias foram próximas, com 92,75% e 92,60%, respectivamente, mas as posições nas distribuições foram distintas. Esse caso evidencia que valores numericamente semelhantes podem representar posições diferentes quando mudam os indicadores, o tamanho do grupo e as referências disponíveis.

A análise conjunta identifica apenas ES3 como referência persistente comum aos

dois objetivos. Também foram observadas recorrências na parte inferior das distribuições, formadas por ITF, ITF6 e ITC no Cluster 1, BG3 no Cluster 2 e ITI2 no Cluster 3. Em contraste, casos como DE3, HU1, FRE e ITH1 mostram mudanças nas posições ocupadas entre as duas aplicações. Os agrupamentos definem os contextos de comparação, mas não determinam uma única posição de desempenho para as diferentes dimensões dos ODS. As recorrências identificadas também não demonstram a existência de causas comuns para os resultados educacionais e econômicos.

CAPÍTULO 4

CONCLUSÃO

Esta dissertação propôs uma estratégia sensível ao contexto para avaliar o desempenho multidimensional relativo de regiões europeias NUTS-I nos ODS 4 e 8. A abordagem combinou a formação de grupos contextuais, por meio do método *k-means* aplicado às variáveis desemprego e cidadania, com a estimação do método *Benefit-of-the-Doubt* (BoD) separadamente para cada *cluster* e ano.

A solução com $k = 3$ distribuiu as 86 regiões em 30, 47 e nove DMUs nos Clusters 1, 2 e 3. A análise em diferentes janelas temporais indicou estabilidade da classificação, com alteração apenas de ES2 quando o ano de 2014 foi incorporado à janela completa. Esses agrupamentos representam contextos definidos pelas variáveis utilizadas e não categorias gerais de desenvolvimento socioeconômico.

Os escores BoD devem ser interpretados como medidas relativas às fronteiras específicas de cada *cluster* e ano. Assim, um escore de 100% indica posicionamento sobre a fronteira daquela execução e não cumprimento integral das metas do ODS. Pela mesma razão, os escores e as médias dos diferentes grupos ou ODS não constituem um *ranking* global.

No ODS 4, considerando 86 regiões e cinco indicadores educacionais, as médias foram de 91,43%, 90,66% e 95,83% nos Clusters 1, 2 e 3. SE1 e UKI permaneceram na fronteira no Cluster 1; FRK, SE2 e UKM no Cluster 2; e ES2 e ES3 no Cluster 3. No ODS 8, a disponibilidade dos quatro indicadores reduziu a amostra para 59 regiões, distribuídas em 23, 31 e cinco DMUs nos três grupos. As médias foram de 89,73%, 88,10% e 88,60%, tendo HU1 e ES3 como referências persistentes nos Clusters 2 e 3, enquanto nenhuma DMU apresentou essa condição no Cluster 1.

A análise de sensibilidade para o ODS 8 examinou valores de ε entre 0,1% e 10% do menor valor positivo de cada variável submetida à translação. As amplitudes entre as médias dos cenários extremos foram de 0,0507, 0,0356 e 0,0156 ponto percentual nos Clusters 1, 2 e 3, respectivamente, permitindo observar a influência da magnitude de ε mantendo os demais componentes da especificação inalterados.

A análise conjunta mostrou que pertencer ao mesmo contexto de comparação não implica manter a mesma posição relativa nos ODS 4 e 8. ES3 foi a única referência persistente comum às duas aplicações, enquanto outras regiões alteraram suas posições conforme o domínio avaliado, os indicadores utilizados e a composição das respectivas fronteiras. Os agrupamentos delimitam, portanto, os conjuntos de comparação, mas não determinam o desempenho das regiões nas diferentes dimensões da Agenda 2030.

A principal contribuição metodológica reside na combinação entre clusterização contextual e construção de indicadores compostos por BoD, permitindo comparar regiões com

perfis semelhantes sem incorporar as variáveis contextuais diretamente como componentes do indicador. A escala NUTS-I também possibilita observar diferenças internas aos países que podem ser ocultadas por avaliações nacionais. Os resultados devem, contudo, ser interpretados como medidas de diagnóstico e *benchmarking* relativo, sem atribuição causal ou prescrição automática de políticas públicas.

Entre as limitações, destacam-se o uso de apenas duas variáveis contextuais, a definição retrospectiva dos *clusters* com base nas médias de 2014 a 2019, a redução da amostra do ODS 8 para 59 regiões e, especialmente, para cinco DMUs no Cluster 3, além das escolhas relacionadas à translação dos valores negativos e ao limite de contribuição mínima de 5%. As aplicações também representam recortes dos ODS 4 e 8 e não abrangem todas as metas e indicadores oficiais de cada objetivo.

Como continuidade da pesquisa, podem ser avaliados outros métodos e variáveis de clusterização, diferentes limites de contribuição mínima e alternativas à translação aditiva. Fronteiras comuns, metafronteiras e outras estruturas temporais podem ampliar as possibilidades de comparação entre grupos e períodos. A análise dos pesos e das contribuições dos indicadores, bem como a ampliação do número de regiões, do período e dos ODS analisados, também constitui possibilidade de desenvolvimento futuro.

Além dos resultados obtidos, este trabalho também reforça a importância de escolher adequadamente as unidades que serão comparadas em uma análise DEA. Quando países inteiros são utilizados como unidades de análise, diferenças importantes entre suas regiões podem acabar sendo ocultadas. Um mesmo país pode reunir territórios com características econômicas, sociais e institucionais bastante distintas, o que pode tornar algumas comparações pouco representativas.

Nesse sentido, a análise em escala regional pode oferecer referências mais próximas da realidade de cada território. Uma região pode encontrar seu principal *benchmark* em outra região com características semelhantes, mesmo que ela pertença a outro país. Isso permite que gestores identifiquem experiências e práticas que possam servir como referência para melhorar o desempenho de sua própria região, sempre considerando as diferenças legais, políticas, econômicas e sociais existentes entre os territórios.

Essa lógica também pode ser estendida para diferentes níveis de análise. Um país pode ser avaliado de forma geral, enquanto suas regiões, estados ou municípios podem ser analisados separadamente quando houver dados adequados. A proposta não é assumir que unidades menores são sempre melhores, mas reconhecer que uma análise mais desagregada pode revelar diferenças que uma avaliação nacional não consegue mostrar. Dessa forma, a DEA pode contribuir não apenas para medir o desempenho relativo, mas também para identificar referências mais específicas e úteis para apoiar a tomada de decisão e o planejamento de políticas públicas.

Essa lógica também pode ser aplicada ao setor privado. Em organizações compostas por diferentes unidades, como filiais, fábricas, departamentos ou unidades de negócio, uma análise com maior nível de detalhamento pode permitir comparações entre unidades com funções e

características semelhantes. Dessa forma, a DEA pode auxiliar na identificação de benchmarks mais específicos e fornecer referências para a melhoria do desempenho em diferentes níveis da organização.

REFERÊNCIAS

ADLER, Nicole; BERECHMAN, Joseph. Measuring airport quality from the airlines' viewpoint: An application of data envelopment analysis. **Transport Policy**, v. 8, n. 3, p. 171–181, 2001. DOI: 10.1016/S0967-070X(01)00011-7.

AHMADABADI, Habib Zare; ZAMZAM, Fatemeh; EMROUZNEJAD, Ali; SADRABADI, Alireza Naser; SHARIFABADI, Ali Morovati. Measuring sustainable performance of OECD countries considering CO2 emissions: A new optimistic-pessimistic distance friction Minimization Model. **Socio-Economic Planning Sciences**, v. 96, p. 102055, 2024. DOI: 10.1016/j.seps.2024.102055.

ALBERT, Bill; TULLIS, Tom. **Measuring the user experience: Collecting, analyzing, and presenting UX metrics**. [S. l.]: Morgan Kaufmann, 2022. DOI: 10.1016/C2018-0-00693-3.

ALDIERI, Luigi; GATTO, Andrea; VINCI, Concetto Paolo. Impact of environmental, energy and business efficiency on CO2 emissions: A composite indicator for emerging Asia-Pacific markets. **Applied Energy**, v. 368, p. 123246, 2024. DOI: 10.1016/j.apenergy.2024.123246.

ALI, Agha Iqbal; SEIFORD, Lawrence M. Translation invariance in data envelopment analysis. **Operations Research Letters**, v. 9, n. 6, p. 403–405, 1990. DOI: 10.1016/0167-6377(90)90061-9.

ARHIN, Kwadwo; ASANTE-DARKO, Disraeli. Performance evaluation of national healthcare systems in the prevention and treatment of non-communicable diseases in sub-Saharan Africa. **PLOS ONE**, v. 18, n. 11, e0294653, 2023. DOI: 10.1371/journal.pone.0294653.

BANKER, Rajiv D; CHARNES, Abraham; COOPER, William Wager. Some models for estimating technical and scale inefficiencies in data envelopment analysis. **Management Science**, v. 30, n. 9, p. 1078–1092, 1984. DOI: 10.1287/mnsc.30.9.1078.

BANKER, Rajiv D; COOPER, William W; SEIFORD, Lawrence M; ZHU, Joe. Returns to scale in DEA. In: COOPER, William W; SEIFORD, Lawrence M; ZHU, Joe (ed.). **Handbook on data envelopment analysis**. 2. ed. [S. l.]: Springer, 2011. p. 41–70. DOI: 10.1007/978-1-4419-6151-8_2.

BANKER, Rajiv D.; CHANG, Hsihui. The super-efficiency procedure for outlier identification, not for ranking efficient units. **European Journal of Operational Research**, v. 175, n. 2, p. 1311–1320, 2006. DOI: 10.1016/j.ejor.2005.06.028.

BANKER, Rajiv D.; CHARNES, Abraham; COOPER, William W.; SWARTS, John; THOMAS, David A. An Introduction to Data Envelopment Analysis with Some of Its Models and Their Uses. *In*: CHAN, James L.; PATTON, James M. (ed.). **Research in Governmental and Nonprofit Accounting**. Greenwich, CT: JAI Press, 1989. v. 5. p. 125–163.

BANKER, Rajiv D.; COOPER, William W.; SEIFORD, Lawrence M.; THRALL, Robert M.; ZHU, Joe. Returns to Scale in Different DEA Models. **European Journal of Operational Research**, v. 154, n. 2, p. 345–362, 2004. DOI: 10.1016/S0377-2217(03)00174-7.

BANKER, Rajiv D.; MOREY, Richard C. Efficiency Analysis for Exogenously Fixed Inputs and Outputs. **Operations Research**, v. 34, n. 4, p. 513–521, 1986a. DOI: 10.1287/opre.34.4.513.

BANKER, Rajiv D.; MOREY, Richard C. The Use of Categorical Variables in Data Envelopment Analysis. **Management Science**, v. 32, n. 12, p. 1613–1627, 1986b. DOI: 10.1287/mnsc.32.12.1613.

BEN LAHOUEL, Béchir; BEN ZAIED, Younes; TALEB, Lotfi; KOČIŠOVÁ, Kristína. The assessment of socio-environmental performance change: A Benefit of the Doubt indicator based on Directional Distance Function and Malmquist productivity index. **Finance Research Letters**, v. 49, p. 103164, 2022. DOI: 10.1016/j.frl.2022.103164.

BEN MABROUK, Mohsen; ELMSALMI, Manel; ALJUAID, Awad M.; HACHICHA, Wafik; HAMMAMI, Sami. Joined Efficiency and Productivity Evaluation of Tunisian Commercial Seaports Using DEA-Based Approaches. **Journal of Marine Science and Engineering**, v. 10, n. 5, p. 626, 2022. DOI: 10.3390/jmse10050626.

BERTSIMAS, Dimitris; TSITSIKLIS, John N. **Introduction to Linear Optimization**. Belmont, MA: Athena Scientific, 1997. ISBN 9781886529199.

BIERMANN, Frank; KANIE, Norichika; KIM, Rakhyun E. Global Governance by Goal-Setting: The Novel Approach of the UN Sustainable Development Goals. **Current Opinion in Environmental Sustainability**, v. 26–27, p. 26–31, 2017. DOI: 10.1016/j.cosust.2017.01.010.

BILOSLAVO, Roberto; BAGNOLI, Carlo; RUSJAN FIGELJ, Roland. Managing dualities for efficiency and effectiveness of organisations. **Industrial Management & Data Systems**, v. 113, n. 3, p. 423–442, 2013. DOI: 10.1108/02635571311312695.

BLANCAS, Francisco Javier; CONTRERAS, Ignacio. Global SDG composite indicator: A new methodological proposal that combines compensatory and non-compensatory aggregations. **Sustainable Development**, v. 33, n. 1, p. 158–176, 2025. DOI: 10.1002/sd.3109.

BLANCO-MALLO, Eva; MORÁN-FERNÁNDEZ, Laura; REMESEIRO, Beatriz; BOLÓN-CANEDO, Verónica. Do all roads lead to Rome? Studying distance measures in the context of machine learning. **Pattern Recognition**, v. 141, p. 109646, 2023. DOI: 10.1016/j.patcog.2023.109646.

BOEREN, Ellen. Understanding Sustainable Development Goal (SDG) 4 on “Quality Education” from Micro, Meso and Macro Perspectives. **International Review of Education**, v. 65, n. 2, p. 277–294, 2019. DOI: 10.1007/s11159-019-09772-7.

BOGETOFT, Peter; OTTO, Lars. **Benchmarking with dea, sfa, and r**. [S. l.]: Springer Science & Business Media, 2010. v. 157. DOI: 10.1007/978-1-4419-7961-2.

BORGES, Janiele Cristine Peres; BORDIN, Ronaldo. Eficiência em saúde pública: a trajetória de um conceito proveniente da engenharia. **Saúde em Debate**, v. 47, n. 138, p. 616–629, 2023. DOI: 10.1590/0103-1104202313818.

CAMANHO, Ana S.; STUMBRIENĖ, Dovilė; BARBOSA, Flávia; JAKAITIENĖ, Audronė. The assessment of performance trends and convergence in education and training systems of European countries. **European Journal of Operational Research**, v. 305, n. 1, p. 356–372, 2023. DOI: 10.1016/j.ejor.2022.05.048.

CAMPOLI, Jessica Suarez; JUNIOR, Paulo Nocera Alves; KODAMA, Tatiana Kimura; NAGANO, Marcelo Seido; BURNQUIST, Heloisa Lee. G20 countries’ progress on the 7th SDG under circular economy DEA model. **Environmental Science & Policy**, v. 160, p. 103839, 2024. DOI: 10.1016/j.envsci.2024.103839.

CHARNES, Abraham; CLARK, C. T.; COOPER, William W.; GOLANY, Boaz. A developmental study of data envelopment analysis in measuring the efficiency of maintenance units in the U.S. air forces. **Annals of Operations Research**, v. 2, p. 95–112, 1984. DOI: 10.1007/BF01874734.

CHARNES, Abraham; COOPER, William W; RHODES, Edwardo. Measuring the efficiency of decision making units. **European Journal of Operational Research**, v. 2, n. 6, p. 429–444, 1978. DOI: 10.1016/0377-2217(78)90138-8.

CHEN, Ya; LI, Yongjun; WU, Huaqing; LIANG, Liang. Data Envelopment Analysis with Missing Data: A Multiple Linear Regression Analysis Approach. **International Journal of Information Technology & Decision Making**, v. 13, n. 1, p. 137–154, 2014. DOI: 10.1142/S0219622014500060.

CHEN, Yuan; BOUFERGUENE, Ahmed; SHEN, Yinghua; AL-HUSSEIN, Mohamed. Assessing accessibility-based service effectiveness (ABSEV) and social equity for urban bus transit: A sustainability perspective. **Sustainable Cities and Society**, v. 44, p. 499–510, 2019. DOI: 10.1016/j.scs.2018.10.003.

CHERCHYE, Laurens; MOESEN, Willem; ROGGE, Nicky; VAN PUYENBROECK, Tom. An Introduction to ‘Benefit of the Doubt’ Composite Indicators. **Social Indicators Research**, v. 82, n. 1, p. 111–145, 2007. DOI: 10.1007/s11205-006-9029-7.

CHERCHYE, Laurens; MOESEN, Wim; VAN PUYENBROECK, Tom. Legitimately diverse, yet comparable: on synthesizing social inclusion performance in the EU. **JCMS: Journal of Common Market Studies**, v. 42, n. 5, p. 919–955, 2004. DOI: 10.1111/j.0021-9886.2004.00535.x.

CHUNG, Yangho H.; FÄRE, Rolf; GROSSKOPF, Shawna. Productivity and Undesirable Outputs: A Directional Distance Function Approach. **Journal of Environmental Management**, v. 51, n. 3, p. 229–240, 1997. DOI: 10.1006/jema.1997.0146.

COOK, Wade D.; LIANG, Liang; ZHU, Joe. Measuring performance of two-stage network structures by DEA: A review and future perspective. **Omega**, v. 38, n. 6, p. 423–430, 2010. DOI: 10.1016/j.omega.2009.12.001.

COOK, Wade D.; SEIFORD, Lawrence M. Data Envelopment Analysis (DEA) – Thirty Years On. **European Journal of Operational Research**, v. 192, n. 1, p. 1–17, 2009. DOI: 10.1016/j.ejor.2008.01.032.

COOK, Wade D.; TONE, Kaoru; ZHU, Joe. Data Envelopment Analysis: Prior to Choosing a Model. **Omega**, v. 44, p. 1–4, 2014. DOI: 10.1016/j.omega.2013.09.004.

COOK, Wade D.; ZHU, Joe. Classifying inputs and outputs in data envelopment analysis. **European Journal of Operational Research**, v. 180, n. 2, p. 692–699, 2007. DOI: 10.1016/j.ejor.2006.03.048.

COOPER, William W.; SEIFORD, Lawrence M.; TONE, Kaoru. **Data Envelopment Analysis: A Comprehensive Text with Models, Applications, References and DEA-Solver Software**. 2. ed. New York: Springer, 2007. 490 p. ISBN 9780387452814. DOI: 10.1007/978-0-387-45283-8.

DAI, Qi; LIU, Xiao-yan; SUN, Fang-yi; REN, Fang-rong. Ensemble intelligence prediction algorithms and land use scenarios to measure carbon emissions of the Yangtze River Delta: A machine learning model based on Long Short-Term Memory. **PLOS ONE**, v. 19, n. 12, e0311441, 2024. DOI: 10.1371/journal.pone.0311441.

DARAIO, Cinzia; SIMAR, Léopold. Introducing Environmental Variables in Nonparametric Frontier Models: a Probabilistic Approach. **Journal of Productivity Analysis**, v. 24, n. 1, p. 93–121, 2005. DOI: 10.1007/s11123-005-3042-8.

DU PISANI, Jacobus A. Sustainable Development: Historical Roots of the Concept. **Environmental Sciences**, v. 3, n. 2, p. 83–96, 2006. DOI: 10.1080/15693430600688831.

DURÃES, Maria João; BARBOSA, Flávia; D'INVERNO, Giovanna; CAMANHO, Ana S. Are European regions on the right track to achieve the 2030 strategic education and training targets? A comprehensive performance assessment. **Socio-Economic Planning Sciences**, v. 103, p. 102390, 2026. ISSN 0038-0121. DOI: 10.1016/j.seps.2025.102390.

DYSON, Robert G.; ALLEN, Rachel; CAMANHO, Ana S.; PODINOVSKI, Victor V.; SARRICO, Cláudia S.; SHALE, Estelle A. Pitfalls and protocols in DEA. **European Journal of Operational Research**, v. 132, n. 2, p. 245–259, 2001. DOI: 10.1016/S0377-2217(00)00149-1.

EMMENDORFER, Leonardo Ramos; PAULA CANUTO, Anne Magaly de. A generalized average linkage criterion for hierarchical agglomerative clustering. **Applied Soft Computing**, v. 100, p. 106990, 2021. DOI: 10.1016/j.asoc.2020.106990.

EMROUZNEJAD, Ali; AMIN, Gholam R. DEA models for ratio data: Convexity consideration. **Applied Mathematical Modelling**, v. 33, n. 1, p. 486–498, 2009. DOI: 10.1016/j.apm.2007.11.018.

ER-RAYS, Youssef; M'DIOUD, Meriem. Evaluating the effectiveness of maternal, neonatal, and child healthcare in Moroccan hospitals and SDG 3: Using two-stage data envelopment analysis and Tobit regression. **Evaluation Review**, v. 49, n. 2, p. 343–379, 2025. DOI: 10.1177/0193841X241264863.

EUROPEAN COMMISSION. **ARDECO database**. 2024. Disponível em: https://knowledge4policy.ec.europa.eu/territorial/ardeco-database_en. Acesso em: 18 ago. 2026.

EUROSTAT. **High-tech industry and knowledge-intensive services (htec): Reference Metadata**. 2024a. Disponível em: https://ec.europa.eu/eurostat/cache/metadata/en/htec_esms.htm. Acesso em: 18 ago. 2026.

EUROSTAT. **Regions in the European Union: Nomenclature of territorial units for statistics (NUTS) – 2024 edition**. [S. l.], 2024b. ISBN 978-92-68-05481-9. DOI: 10.2785/714519. Disponível em: <https://ec.europa.eu/eurostat/web/products-manuals-and-guidelines/w/ks-gq-23-010>. Acesso em: 18 ago. 2026.

FACHIERI, Daniel N; SUAIDE, Alexandre AP. Introdução a métodos de aprendizado de máquina não supervisionados através de um experimento simples de medidas de densidades de sólidos. **Revista Brasileira de Ensino de Física**, v. 47, e20240443, 2025. DOI: 10.1590/1806-9126-RBEF-2024-0443.

FÄRE, Rolf; GROSSKOPF, Shawna; LOVELL, C. A. Knox; PASURKA, Carl. Multilateral Productivity Comparisons When Some Outputs Are Undesirable: A Nonparametric Approach. **The Review of Economics and Statistics**, v. 71, n. 1, p. 90–98, 1989. DOI: 10.2307/1928055.

FÄRE, Rolf; GROSSKOPF, Shawna; NORRIS, Mary; ZHANG, Zhongyang. Productivity growth, technical progress, and efficiency change in industrialized countries. **American Economic Review**, v. 84, n. 1, p. 66–83, 1994.

FARRELL, Michael James. The measurement of productive efficiency. **Journal of the Royal Statistical Society: Series A (General)**, v. 120, n. 3, p. 253–281, 1957. DOI: 10.2307/2343100.

FÁVERO, Luiz Paulo; BELFIORE, Patrícia. **Manual de análise de dados: estatística e modelagem multivariada com Excel®, SPSS® e Stata®**. [S. l.]: Elsevier Brasil, 2022.

FENG, Ying; YANG, Chih-Yu; LU, Ching-Cheng; TANG, Pao-Yu. Measuring Pollution Control and Environmental Sustainable Development in China Based on Parallel DEA Method. **Energies**, v. 15, n. 15, p. 5697, 2022. DOI: 10.3390/en15155697.

FRIGGE, Michael; HOAGLIN, David C.; IGLEWICZ, Boris. Some Implementations of the Boxplot. **The American Statistician**, v. 43, n. 1, p. 50–54, 1989. DOI: 10.1080/00031305.1989.10475612.

FUKUDA-PARR, Sakiko. From the Millennium Development Goals to the Sustainable Development Goals: Shifts in Purpose, Concept, and Politics of Global Goal Setting for Development. **Gender & Development**, v. 24, n. 1, p. 43–52, 2016. DOI: 10.1080/13552074.2016.1145895.

FUMBWE, Fatuma; LIHAWA, Robert; ANDREW, Felician; KINYANJUI, George; MKUNA, Eliaza. Examination on level of scale efficiency in public hospitals in Tanzania. **Cost Effectiveness and Resource Allocation**, v. 19, n. 1, p. 49, 2021. DOI: 10.1186/s12962-021-00305-4.

FUSCO, Elisa. Potential improvements approach in composite indicators construction: The multi-directional Benefit of the Doubt model. **Socio-Economic Planning Sciences**, v. 85, p. 101447, 2023. DOI: 10.1016/j.seps.2022.101447.

GAN, Lu; WANG, Li; HU, Zhineng; LEV, Benjamin; GANG, Jun; LAN, Hongxing. Do geologic hazards affect the sustainability of rural development? Evidence from rural areas in China. **Journal of Cleaner Production**, v. 339, p. 130693, 2022. DOI: 10.1016/j.jclepro.2022.130693.

GENNITSARIS, Stavros; SOFIANOPOULOU, Stella. Wind turbine end-of-life options based on the UN Sustainable Development Goals (SDGs). **Green Technologies and Sustainability**, v. 2, n. 3, p. 100108, 2024. DOI: 10.1016/j.grets.2024.100108.

GEORGIADIS, Georgios; KOPSACHEILIS, Aristomenis; ANDREADIS, Ioannis Marios; POLITIS, Ioannis. Analyzing efficiency and built environment factors for achieving convenient access to public transport: A Europe-wide DEA application. **Environmental Science & Policy**, v. 158, p. 103792, 2024. DOI: 10.1016/j.envsci.2024.103792.

GIAMBONA, Francesca; MAGRINI, Alessandro; FUSCO, Elisa. Assessing tourism sustainability in European Union countries: A multi-directional benefit of the doubt composite

indicator. **Socio-Economic Planning Sciences**, v. 95, p. 102042, 2024. DOI: 10.1016/j.seps.2024.102042.

GOLANY, Boaz; ROLL, Yaakov. An application procedure for DEA. **Omega**, v. 17, n. 3, p. 237–250, 1989. DOI: 10.1016/0305-0483(89)90029-7.

GRATERON, Ivan Ricardo Guevara. Auditoria de gestão: utilização de indicadores de gestão no setor público. **Caderno de Estudos**, p. 01–18, 1999. DOI: 10.1590/S1413-92511999000200002.

GRECO, Salvatore; ISHIZAKA, Alessio; TASIOU, Menelaos; TORRISI, Gianpiero. On the Methodological Framework of Composite Indices: A Review of the Issues of Weighting, Aggregation, and Robustness. **Social Indicators Research**, v. 141, n. 1, p. 61–94, 2019. DOI: 10.1007/s11205-017-1832-9.

GRIGGS, David; STAFFORD-SMITH, Mark; GAFFNEY, Owen; ROCKSTRÖM, Johan; ÖHMAN, Marcus C.; SHYAMSUNDAR, Priya; STEFFEN, Will; GLASER, Gisbert; KANIE, Norichika; NOBLE, Ian. Sustainable Development Goals for People and Planet. **Nature**, v. 495, n. 7441, p. 305–307, 2013. DOI: 10.1038/495305a.

GUIMARAES, Paula; LEAL, Ricardo P. C.; WANKE, Peter; MOREY, Matthew. Shareholder activism impact on efficiency in Brazil. **Corporate Governance: The International Journal of Business in Society**, v. 19, n. 1, p. 141–157, 2019. DOI: 10.1108/CG-01-2018-0010.

HALME, Merja; JORO, Tarja; KOIVU, Matti. Dealing with interval scale data in data envelopment analysis. **European Journal of Operational Research**, v. 137, n. 1, p. 22–27, 2002. DOI: 10.1016/S0377-2217(01)00090-X.

HAN, J.; KAMBER, M.; PEI, J. **Data Mining: Concepts and Techniques**. [S. l.]: Morgan Kaufmann, 2011. (The Morgan Kaufmann Series in Data Management Systems). ISBN 9780123814807. DOI: 10.1016/C2009-0-61819-5.

HARTIGAN, John A.; WONG, Manchek A. Algorithm AS 136: A K-Means Clustering Algorithm. **Journal of the Royal Statistical Society: Series C (Applied Statistics)**, v. 28, n. 1, p. 100–108, 1979. DOI: 10.2307/2346830.

HATAMI-MARBINI, Adel; ASU, John Otu; KHOSHNEVIS, Pegah. Environmental performance assessment in the transport sector using nonparametric frontier analysis: A

systematic literature review. **Computers & Industrial Engineering**, v. 189, p. 109968, 2024. DOI: 10.1016/j.cie.2024.109968.

HATAMI-MARBINI, Adel; TOLOO, Mehdi. Data envelopment analysis models with ratio data: A revisit. **Computers & Industrial Engineering**, v. 133, p. 331–338, 2019. DOI: 10.1016/j.cie.2019.04.041.

HOAGLIN, David C.; IGLEWICZ, Boris; TUKEY, John W. Performance of Some Resistant Rules for Outlier Labeling. **Journal of the American Statistical Association**, v. 81, n. 396, p. 991–999, 1986. DOI: 10.1080/01621459.1986.10478363.

HOLLINGSWORTH, Bruce; SMITH, Peter. Use of ratios in data envelopment analysis. **Applied Economics Letters**, v. 10, n. 11, p. 733–735, 2003. DOI: 10.1080/1350485032000133381.

HOLOD, Dmytro; LEWIS, Herbert F. Resolving the deposit dilemma: A new DEA bank efficiency model. **Journal of Banking & Finance**, v. 35, n. 11, p. 2801–2810, 2011. DOI: 10.1016/j.jbankfin.2011.03.007.

HOPWOOD, Bill; MELLOR, Mary; O'BRIEN, Geoff. Sustainable Development: Mapping Different Approaches. **Sustainable Development**, v. 13, n. 1, p. 38–52, 2005. DOI: 10.1002/sd.244.

HOUNSHELL, David A. **From the American System to Mass Production, 1800–1932: The Development of Manufacturing Technology in the United States**. Baltimore: Johns Hopkins University Press, 1984. 411 p. (Studies in Industry and Society, 4). ISBN 9780801829758. DOI: 10.56021/9780801829758.

HU, Peng; WANG, Derek D. Which Method Prevails? Benchmarking Missing Data Techniques in Data Envelopment Analysis. **European Journal of Operational Research**, v. 334, n. 3, p. 963–979, 2026. DOI: 10.1016/j.ejor.2026.02.012.

HUONG, Ta-Thi; DONG, Liang; SHAH, Izhar Hussain; PARK, Hung-Suck. Exploring the sustainability of resource flow and productivity transition in Vietnam from 1978 to 2017: MFA and DEA-based malmquist productivity index approach. **Sustainability**, v. 13, n. 21, p. 11761, 2021. DOI: 10.3390/su132111761.

ISSEVER GROCHOVÁ, Ladislava; LITZMAN, Marek. The efficiency in meeting measurable sustainable development goals. **International Journal of Sustainable Development & World Ecology**, v. 28, n. 8, p. 709–719, 2021. DOI: 10.1080/13504509.2021.1882606.

JAIN, Anil K. Data clustering: 50 years beyond K-means. **Pattern Recognition Letters**, v. 31, n. 8, p. 651–666, 2010. DOI: 10.1016/j.patrec.2009.09.011.

JAIN, Anil K; DUBES, Richard C. **Algorithms for clustering data**. [S. l.]: Prentice-Hall, Inc., 1988. DOI: 10.5555/42779.

JAIN, Anil K.; MURTY, M. Narasimha; FLYNN, Patrick J. Data Clustering: A Review. **ACM Computing Surveys**, v. 31, n. 3, p. 264–323, 1999. DOI: 10.1145/331499.331504.

JIAKUI, Chen; ABBAS, Jaffar; NAJAM, Hina; LIU, Jiani; ABBAS, Jawad. Green technological innovation, green finance, and financial development and their role in green total factor productivity: Empirical insights from China. **Journal of Cleaner Production**, v. 382, p. 135131, 2023. DOI: 10.1016/j.jclepro.2022.135131.

JOOS, Lennart. “Only One Earth”: Environmental Perceptions and Policies before the Stockholm Conference, 1968–1972. **Journal of Global History**, v. 18, n. 2, p. 281–303, 2023. DOI: 10.1017/S1740022823000013.

KAO, Chiang. Measuring efficiency in a general production possibility set allowing for negative data. **European Journal of Operational Research**, v. 282, n. 3, p. 980–988, 2020. DOI: 10.1016/j.ejor.2019.10.027.

KAUFMAN, Leonard; ROUSSEEUW, Peter J. **Finding groups in data: an introduction to cluster analysis**. [S. l.]: John Wiley & Sons, 2009. DOI: 10.1002/9780470316801.

KOÇAK, Deniz; TÜRE, Hasan; ATAN, Murat. Efficiency measurement with network DEA: An application to sustainable development goals 4. **International Journal of Assessment Tools in Education**, v. 6, n. 3, p. 415–435, 2019. DOI: 10.21449/ijate.539487.

KOURTIT, Karima; NIJKAMP, Peter; SUZUKI, Soushi. Comparative urban performance assessment of safe cities through data envelopment analysis. **Regional Science Policy & Practice**, v. 13, n. 3, p. 591–603, 2021. DOI: 10.1111/rsp3.12276.

KUOSMANEN, Timo. Data envelopment analysis with missing data. **Journal of the Operational Research Society**, v. 60, n. 12, p. 1767–1774, 2009. DOI: 10.1057/jors.2008.132.

ŁAĆKA, Irena; BRZEZICKI, Łukasz. Joint Analysis of National Eco-Efficiency, Eco-Innovation and SDGs in Europe: DEA Approach. **Technological and Economic Development of Economy**, v. 28, n. 6, p. 1739–1767, 2022. DOI: 10.3846/tede.2022.17702.

LE BLANC, David. Towards Integration at Last? The Sustainable Development Goals as a Network of Targets. **Sustainable Development**, v. 23, n. 3, p. 176–187, 2015. DOI: 10.1002/sd.1582.

LEE, Hsuan-Shih; ZHU, Joe. Super-efficiency infeasibility and zero data in DEA. **European Journal of Operational Research**, v. 216, n. 2, p. 429–433, 2012. DOI: 10.1016/j.ejor.2011.07.050.

LI, Fanbo; ZHANG, Hongfeng; ZHANG, Di; YAN, Haoqun. Structural diffusion model and urban green innovation efficiency—A hybrid study based on DEA-SBM, NCA, and fsQCA. **Sustainability**, v. 15, n. 17, p. 12705, 2023a. DOI: 10.3390/su151712705.

LI, Jing; ZHENG, Zhican; XU, Yan; HANG, Sheng; GONG, Huarui. Optimization of coupling crop and livestock production system's eco-efficiency in northern China based on a life cycle assessment and data envelopment analysis method. **Science of The Total Environment**, v. 921, p. 170852, 2024. DOI: 10.1016/j.scitotenv.2024.170852.

LI, Shuangjie; DIAO, Hongyu; WANG, Liming; LI, Chunqi. Energy Efficiency Measurement: A VO TFEE Approach and Its Application. **Sustainability**, v. 13, n. 4, p. 1605, 2021. DOI: 10.3390/su13041605.

LI, Xiaotuan; YANG, Panfei; ZOU, Yuntao. An Empirical Investigation of the “Mezzogiorno Trap” in China's Agricultural Economy: Insights from Data Envelopment Analysis (2015–2021). **Agriculture**, v. 13, n. 9, p. 1806, 2023b. DOI: 10.3390/agriculture13091806.

LIN, Sheng-Wei; LU, Wen-Min. Using inverse DEA and machine learning algorithms to evaluate and predict suppliers' performance in the apple supply chain. **International Journal of Production Economics**, v. 271, p. 109203, 2024. DOI: 10.1016/j.ijpe.2024.109203.

LIN, Tai-Yu; CHIU, Yung-Ho; LU, Jia Sheng; LU, Liang-Chun; CHIEN, Hsiu-Fang. Evaluating European countries' progress towards SDGs: Insights from parallel SBM DEA analysis of economic, healthcare, environmental, and educational efficiencies. **Journal of Environmental Management**, v. 378, p. 124782, 2025. DOI: 10.1016/j.jenvman.2025.124782.

LIU, Jiawei; JI, Li; SUN, Yanan; CHIU, Yung-ho; ZHAO, Haoxiang. Unleashing the Convergence Between SDG 9 and SDG 8 Towards Pursuing SDGs: Evidence from Two Urban Agglomerations in China During the 13th Five-Year Plan. **Journal of Cleaner Production**, v. 434, p. 139924, 2024. DOI: 10.1016/j.jclepro.2023.139924.

LIU, Zhen; XU, Jinhang; WEI, Yiming; HATAB, Assem Abu; LAN, Jing. Nexus between green financing, renewable energy generation, and energy efficiency: empirical insights through DEA technique. **Environmental Science and Pollution Research**, v. 30, n. 22, p. 61290–61303, 2023. DOI: 10.1007/s11356-021-17092-3.

LOVELL, C. A. Knox; PASTOR, Jesús T. Units Invariant and Translation Invariant DEA Models. **Operations Research Letters**, v. 18, n. 3, p. 147–151, 1995. DOI: 10.1016/0167-6377(95)00044-5.

LOZANO, Sebastian; BORREGO-MARIN, Maria M. A metafrontier network DEA approach for water usage efficiency assessment in the light of SDG target 6.4. **Environmental Science & Policy**, v. 160, p. 103857, 2024. ISSN 1462-9011. DOI: 10.1016/j.envsci.2024.103857.

MACQUEEN, James B. Some Methods for Classification and Analysis of Multivariate Observations. *In: PROCEEDINGS of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*. Berkeley, CA: University of California Press, 1967. v. 1, p. 281–297.

MAIA, Rodrigo Gomes Tavora; JUNIOR, Amaro Olimpio Pereira; PESSANHA, Jose Francisco Moreira; GARCIA, Katia Cristina. Methodology for setting corporate sustainability targets. **Journal of Cleaner Production**, v. 369, p. 133359, 2022. DOI: 10.1016/j.jclepro.2022.133359.

MALEŠEVIĆ PEROVIĆ, Lena; MIHALJEVIĆ KOSOR, Maja. The efficiency of universities in achieving sustainable development goals. **Amfiteatru Economic**, v. 22, n. 54, p. 516–532, 2020. DOI: 10.24818/EA/2020/54/516.

MALEŠEVIĆ PEROVIĆ, Lena; MIHALJEVIĆ KOSOR, Maja; ALFIREVIĆ, Nikša. Assessing university contributions to sustainability in Europe: A data-driven analysis of SDG 12 (responsible consumption) and SDG 13 (climate action). **World**, v. 6, n. 1, p. 11, 2025. DOI: 10.3390/world6010011.

MARICUȚ, Alin; GRĂDINARU, Giani-Ionel; MARIN, Erika; VASILE, Valentina. Efficiency of Urban Development: Gaps in Continental Profile. **Management & Marketing**, v. 18, S1, p. 398–410, 2023. DOI: 10.2478/mmcks-2023-0021.

MARUTHO, Dhendra; HANDAKA, Sunarna Hendra; WIJAYA, Ekaprana; MULJONO. The Determination of Cluster Number at K-Mean Using Elbow Method and Purity Evaluation on Headline News. *In: IEEE. 2018 International Seminar on Application for Technology of Information and Communication. [S. l.: s. n.], 2018. p. 533–538. DOI: 10.1109/ISEMANTIC.2018.8549751.*

MATOS, Eliane; PIRES, Denise. Teorias administrativas e organização do trabalho: de Taylor aos dias atuais, influências no setor saúde e na enfermagem. **Texto & Contexto - Enfermagem**, v. 15, p. 508–514, 2006. DOI: 10.1590/S0104-07072006000300017.

MATULOVÁ, Markéta. Ranking of European universities by DEA-based sustainability indicator. **Journal on Efficiency and Responsibility in Education and Science**, v. 16, n. 4, p. 287–298, 2023. DOI: 10.7160/eriesj.2023.160403.

MAY, Andréia; FRIES, Carlos Ernani; VILARINHO, Hermilio; CAMANHO, Ana S. Evolution of performance in the water and sewage sector in Brazil: A robust directional Benefit-of-the-Doubt assessment of municipalities from Santa Catarina state. **Annals of Operations Research**, v. 351, n. 2, p. 1489–1535, 2025. DOI: 10.1007/s10479-024-06321-w.

MEADOWS, Donella H.; MEADOWS, Dennis L.; RANDERS, Jørgen; BEHRENS III, William W. **The Limits to Growth: A Report for the Club of Rome's Project on the Predicament of Mankind**. New York: Universe Books, 1972.

MEBRATU, Desta. Sustainability and Sustainable Development: Historical and Conceptual Review. **Environmental Impact Assessment Review**, v. 18, n. 6, p. 493–520, 1998. DOI: 10.1016/S0195-9255(98)00019-5.

MERGONI, Anna; D'INVERNO, Giovanna; CAROSI, Laura. A composite indicator for measuring the environmental performance of water, wastewater, and solid waste utilities. **Utilities Policy**, v. 74, p. 101285, 2022. DOI: 10.1016/j.jup.2021.101285.

MICHALI, Maria; EMROUZNEJAD, Ali; AMIN, Gholam R. Revisiting the inverse transformation of undesirable factors in data envelopment analysis: A novel iterative algorithm. **European Journal of Operational Research**, v. 331, n. 2, p. 587–600, 2026. DOI: 10.1016/j.ejor.2025.10.009.

MOHAMMADI, Ali; VENKATESH, G; ESKANDARI, Samieh; RAFIEE, Shahin. Eco-efficiency analysis to improve environmental performance of wheat production. **Agriculture**, v. 12, n. 7, p. 1031, 2022. DOI: 10.3390/agriculture12071031.

MUSSABAYEV, Rustam. Optimizing Euclidean Distance Computation. **Mathematics**, v. 12, n. 23, 3787, 2024. ISSN 2227-7390. DOI: 10.3390/math12233787.

NATARAJA, Niranjan R.; JOHNSON, Andrew L. Guidelines for using variable selection techniques in data envelopment analysis. **European Journal of Operational Research**, v. 215, n. 3, p. 662–669, 2011. DOI: 10.1016/j.ejor.2011.06.045.

NING, Youliang; LIU, Zhen; NING, Zekui; ZHANG, Han. Measuring eco-efficiency of state-owned forestry enterprises in northeast China. **Forests**, v. 9, n. 8, p. 455, 2018. DOI: 10.3390/f9080455.

OLESEN, Ole Bent; PETERSEN, Niels Christian; PODINOVSKI, Victor V. Efficiency analysis with ratio measures. **European Journal of Operational Research**, v. 245, n. 2, p. 446–462, 2015. DOI: 10.1016/j.ejor.2015.03.013.

OSMAN, Ibrahim H; ZABLITH, Fouad. Re-evaluating electronic government development index to monitor the transformation toward achieving sustainable development goals. **Journal of Business Research**, v. 131, p. 426–440, 2021. DOI: 10.1016/j.jbusres.2020.10.027.

ÖZDEMİR, Aydın; KITAPÇI, Hakan; GÖK, Mehmet Şahin; CİĞERİM, Erşan. Efficiency Assessment of Operations Strategy Matrix in Healthcare Systems of US States Amid COVID-19: Implications for Sustainable Development Goals. **Sustainability**, v. 13, n. 21, p. 11934, 2021. DOI: 10.3390/su132111934.

PASTOR, Jesús T. Translation invariance in data envelopment analysis: A generalization. **Annals of Operations Research**, v. 66, p. 91–102, 1996. DOI: 10.1007/BF02187295.

PEDRAJA-CHAPARRO, F.; SALINAS-JIMÉNEZ, J.; SMITH, P. On the Role of Weight Restrictions in Data Envelopment Analysis. **Journal of Productivity Analysis**, v. 8, n. 2, p. 215–230, 1997. DOI: 10.1023/A:1007715912664.

PEREIRA, Miguel Alves; D'INVERNO, Giovanna; CAMANHO, Ana S. Learning mobility in European higher education: How has the Union's flagship initiative progressed? **Annals of Operations Research**, v. 351, n. 2, p. 1589–1619, 2025. DOI: 10.1007/s10479-024-06195-y.

PODINOVSKI, Victor V.; BOUZDINE-CHAMEEVA, Tatiana. Optimal Solutions of Multiplier DEA Models. **Journal of Productivity Analysis**, v. 56, p. 45–68, 2021. DOI: 10.1007/s11123-021-00610-3.

PRADHAN, Prajal; COSTA, Luís; RYBSKI, Diego; LUCHT, Wolfgang; KROPP, Jürgen P. A Systematic Study of Sustainable Development Goal Interactions. **Earth's Future**, v. 5, n. 11, p. 1169–1179, 2017. DOI: 10.1002/2017EF000632.

PRIYADARSHINI, Priya; ABHILASH, Purushothaman Chirakkuzhyil. An empirical analysis of resource efficiency and circularity within the agri-food sector of India. **Journal of Cleaner Production**, v. 385, p. 135660, 2023. DOI: 10.1016/j.jclepro.2022.135660.

PRODANOV, Cleber Cristiano; DE FREITAS, Ernani Cesar. **Metodologia do Trabalho Científico: Métodos e Técnicas da Pesquisa e do Trabalho Acadêmico**. 2. ed. [S. l.]: Editora Feevale, 2013.

RADOVANOVIĆ, Sandro; SAVIĆ, Gordana; DELIBAŠIĆ, Boris; SUKNOVIĆ, Milija. FairDEA—Removing disparate impact from efficiency scores. **European Journal of Operational Research**, v. 301, n. 3, p. 1088–1098, 2022. DOI: 10.1016/j.ejor.2021.12.001.

RANA, Md Sohel; BANNA, Hasanul; MIA, Md Aslam; ISMAIL, Izlin Binti; ISMAIL, Mohd Nazari Bin. How Productive Are the Microfinance Institutions in Bangladesh? An Application of Malmquist Productivity Index. **Studies in Microeconomics**, v. 10, n. 2, p. 155–177, 2022. DOI: 10.1177/23210222211024445.

RODRÍGUEZ-CORNEJO, Vanessa; GARCÍA-VALDERRAMA, Teresa; SÁNCHEZ-ORTIZ, Jaime; CABRERA-MONROY, Francisca. R&D&I efficiency AS one OF the Sustainable Development Goals (SDGS) in Europe: Application of a dynamic model with network structure and Cumulative Divisional Malmquist index (CDMI). **Expert Systems with Applications**, v. 238, p. 122338, 2024. DOI: 10.1016/j.eswa.2023.122338.

ROUSSEEUW, Peter J. Silhouettes: a graphical aid to the interpretation and validation of cluster analysis. **Journal of Computational and Applied Mathematics**, v. 20, p. 53–65, 1987. DOI: 10.1016/0377-0427(87)90125-7.

RUSYDIANA, Aam S; LAILA, Nisful; TUBASTUVI, Naelati; IBRAHIM, Mohamad Andri; MARLINA, Lina. Energy efficiency in OIC countries: SDG 7 output. **International Journal of Energy Economics and Policy**, v. 11, n. 1, p. 74–81, 2021. DOI: 10.32479/ijeep.10499.

SACHS, Jeffrey D. From Millennium Development Goals to Sustainable Development Goals. **The Lancet**, v. 379, n. 9832, p. 2206–2211, 2012. DOI: 10.1016/S0140-6736(12)60685-0.

SAISANA, Michaela; SALTELLI, Andrea; TARANTOLA, Stefano. Uncertainty and sensitivity analysis techniques as tools for the quality assessment of composite indicators. **Journal of the Royal Statistical Society: Series A (Statistics in Society)**, v. 168, n. 2, p. 307–323, 2005. DOI: 10.1111/j.1467-985X.2005.00350.x.

SAKR, Mohamed F; SELIM, Kamal Samy; TAHA, Sherin Gamaleldin. Measuring countries relative efficiencies in using development assistance: a data envelopment analysis approach. **Future Business Journal**, v. 10, n. 1, p. 40, 2024. DOI: 10.1186/s43093-024-00325-5.

SANWAL, Mukul. Rio+20, Climate Change and Development: The Evolution of Sustainable Development, 1972–2012. **Climate and Development**, v. 4, n. 2, p. 157–166, 2012. DOI: 10.1080/17565529.2012.729504.

SARKIS, Joseph. Preparing Your Data for DEA. In: ZHU, Joe; COOK, Wade D. (ed.). **Modeling Data Irregularities and Structural Complexities in Data Envelopment Analysis**. New York: Springer, 2007. p. 305–320. DOI: 10.1007/978-0-387-71607-7_17.

SARRICO, C. S.; DYSON, R. G. Restricting Virtual Weights in Data Envelopment Analysis. **European Journal of Operational Research**, v. 159, n. 1, p. 17–34, 2004. DOI: 10.1016/S0377-2217(03)00402-8.

SCHAFER, Joseph L.; GRAHAM, John W. Missing Data: Our View of the State of the Art. **Psychological Methods**, v. 7, n. 2, p. 147–177, 2002. DOI: 10.1037/1082-989X.7.2.147.

SCHEEL, Holger. Undesirable Outputs in Efficiency Valuations. **European Journal of Operational Research**, v. 132, n. 2, p. 400–410, 2001. DOI: 10.1016/S0377-2217(00)00160-0.

SEIFORD, Lawrence M.; THRALL, Robert M. Recent Developments in DEA: The Mathematical Programming Approach to Frontier Analysis. **Journal of Econometrics**, v. 46, n. 1–2, p. 7–38, 1990. DOI: 10.1016/0304-4076(90)90045-U.

SEIFORD, Lawrence M.; ZHU, Joe. Modeling Undesirable Factors in Efficiency Evaluation. **European Journal of Operational Research**, v. 142, n. 1, p. 16–20, 2002. DOI: 10.1016/S0377-2217(01)00293-4.

SEIFORD, Lawrence M.; ZHU, Joe. Sensitivity analysis of DEA models for simultaneous changes in all the data. **Journal of the Operational Research Society**, v. 49, n. 10, p. 1060–1071, 1998a. DOI: 10.1057/palgrave.jors.2600620.

SEIFORD, Lawrence M.; ZHU, Joe. Stability regions for maintaining efficiency in data envelopment analysis. **European Journal of Operational Research**, v. 108, n. 1, p. 127–139, 1998b. DOI: 10.1016/S0377-2217(97)00103-3.

SHARP, John A.; MENG, Wei; LIU, Wenbin. A modified slacks-based measure model for data envelopment analysis with ‘natural’ negative outputs and inputs. **Journal of the Operational Research Society**, v. 58, n. 12, p. 1672–1677, 2007. DOI: 10.1057/palgrave.jors.2602318.

SILVA PORTELA, Maria C. A.; THANASSOULIS, Emmanuel; SIMPSON, Gary. Negative data in DEA: A directional distance approach applied to bank branches. **Journal of the Operational Research Society**, v. 55, n. 10, p. 1111–1121, 2004. DOI: 10.1057/palgrave.jors.2601768.

SIMAR, Léopold; WILSON, Paul W. Estimation and inference in two-stage, semi-parametric models of production processes. **Journal of Econometrics**, v. 136, n. 1, p. 31–64, 2007. DOI: 10.1016/j.jeconom.2005.07.009.

SINGPAI, Bodin; WU, Desheng. Using a DEA–AutoML approach to track SDG achievements. **Sustainability**, v. 12, n. 23, p. 10124, 2020. DOI: 10.3390/su122310124.

SMITH, Peter. Model misspecification in Data Envelopment Analysis. **Annals of Operations Research**, v. 73, p. 233–252, 1997. DOI: 10.1023/A:1018981212364.

SU, Weihua; CHEN, Sibao; ZHANG, Chonghui; LI, Kevin W. A subgroup dominance-based Benefit of the Doubt method for addressing rank reversals: A case study of the Human Development Index in Europe. **European Journal of Operational Research**, v. 307, n. 3, p. 1299–1317, 2023. DOI: 10.1016/j.ejor.2022.11.030.

SUÁREZ-FERNÁNDEZ, Óscar; MASIDE-SANFIZ, José Manuel; LÓPEZ-PENABAD, M^a Celia; ALZGHOUL, Mohammad Omar. Do diversity & inclusion of human capital affect ecoefficiency? Evidence for the energy sector. **Green Finance**, v. 6, n. 3, p. 430–456, 2024. DOI: 10.3934/GF.2024017.

TAYLOR, Frederick Winslow. **The Principles of Scientific Management**. New York e London: Harper & Brothers, 1911. Disponível em: <https://www.loc.gov/item/11010339/>.

THANASSOULIS, Emmanuel. **Introduction to the Theory and Application of Data Envelopment Analysis: A Foundation Text with Integrated Software**. New York: Springer, 2001. DOI: 10.1007/978-1-4615-1407-7.

THOMPSON, Russell G.; DHARMAPALA, P. S.; THRALL, Robert M. Importance for DEA of zeros in data, multipliers, and solutions. **Journal of Productivity Analysis**, v. 4, p. 379–390, 1993. DOI: 10.1007/BF01073546.

THORE, Sten. Sustainable development goal deficits and the Covid 19 pandemic. **Technological Forecasting and Social Change**, v. 174, p. 121204, 2022. DOI: 10.1016/j.techfore.2021.121204.

TIBSHIRANI, Robert; WALTHER, Guenther; HASTIE, Trevor. Estimating the number of clusters in a data set via the gap statistic. **Journal of the Royal Statistical Society: Series B (Statistical Methodology)**, v. 63, n. 2, p. 411–423, 2001. DOI: 10.1111/1467-9868.00293.

TOLOO, Mehdi. On classifying inputs and outputs in DEA: A revised model. **European Journal of Operational Research**, v. 198, n. 1, p. 358–360, 2009. DOI: 10.1016/j.ejor.2008.08.017.

TONE, Kaoru. A slacks-based measure of super-efficiency in data envelopment analysis. **European Journal of Operational Research**, v. 143, n. 1, p. 32–41, 2002. DOI: 10.1016/S0377-2217(01)00324-1.

TONE, Kaoru; CHANG, Tsung-Sheng; WU, Chen-Hui. Handling negative data in slacks-based measure data envelopment analysis models. **European Journal of Operational Research**, v. 282, n. 3, p. 926–935, 2020. DOI: 10.1016/j.ejor.2019.09.055.

TRNOVSKÁ, Mária; HALICKÁ, Margaréta; HRDINA, Jakub. Path-Based DEA Models in Multiplier Form and Returns-to-Scale Analysis. **Annals of Operations Research**, v. 351, p. 1705–1741, 2025. DOI: 10.1007/s10479-024-06384-9.

TULKENS, Henry; VANDEN EECKAUT, Philippe. Non-parametric efficiency, progress and regress measures for panel data: Methodological aspects. **European Journal of Operational Research**, v. 80, n. 3, p. 474–499, 1995. DOI: 10.1016/0377-2217(94)00132-V.

UMARGONO, Edy; SUSENO, Jatmiko Endro; GUNAWAN, SK Vincensius. K-means clustering optimization using the elbow method and early centroid determination based on mean and median formula. *In: ATLANTIS PRESS. THE 2nd international seminar on science and technology (ISSTEC 2019). [S. l.: s. n.], 2020. p. 121–129. DOI: 10.2991/assehr.k.201010.019.*

UNITED NATIONS STATISTICS DIVISION. **SDG Indicators Metadata Repository: Goal 8**. 2026. Disponível em: <https://unstats.un.org/sdgs/metadata/?Goal=8&Target=>. Acesso em: 18 ago. 2026.

VAN PUYENBROECK, Tom. On the Output Orientation of the Benefit-of-the-Doubt Model. **Social Indicators Research**, v. 139, n. 2, p. 415–431, 2018. DOI: 10.1007/s11205-017-1734-x.

VARTANIAN, Thomas P. **Secondary data analysis**. [S. l.]: Oxford University Press, 2010. DOI: 10.1093/acprof:oso/9780195388817.001.0001.

VIDOLI, Francesco; FUSCO, Elisa; PIGNATARO, Giacomo; GUCCIO, Calogero. Multi-directional robust Benefit of the Doubt model: An application to the measurement of the quality of acute care services in OECD countries. **Socio-Economic Planning Sciences**, v. 93, p. 101877, 2024. DOI: 10.1016/j.seps.2024.101877.

WAGNER, Janet M.; SHIMSHAK, Daniel G. Stepwise selection of variables in data envelopment analysis: Procedures and managerial perspectives. **European Journal of Operational Research**, v. 180, n. 1, p. 57–67, 2007. DOI: 10.1016/j.ejor.2006.02.048.

WALHEER, Barnabé. A sequential benefit-of-the-doubt composite indicator. **European Journal of Operational Research**, v. 316, n. 1, p. 228–239, 2024. DOI: 10.1016/j.ejor.2024.01.029.

WANG, Chengyuan; LIU, Shenghui; FENG, Tiantian; LIU, Yuan; LIU, Yuwen; HU, ZhiBo; YANG, Liwei; NIU, Qian; MAO, Xuegang. Is the assessment approach of Sustainable Development Goal 11.3.1 justified? Evidence from the drivers of future urban land use efficiency. **Journal of Cleaner Production**, v. 444, p. 141147, 2024a. DOI: 10.1016/j.jclepro.2024.141147.

WANG, Jianlin; TONG, Junbo; FANG, Zhong. Assessing the drivers of sustained agricultural economic development in China: Agricultural productivity and poverty reduction efficiency. **Sustainability**, v. 16, n. 5, p. 2073, 2024b. DOI: 10.3390/su16052073.

WANG, Jianlin; YOU, Zhanglan; SONG, Pengfei; FANG, Zhong. Rainfall's impact on agricultural production and government poverty reduction efficiency in China. **Scientific Reports**, v. 14, n. 1, p. 9320, 2024c. DOI: 10.1038/s41598-024-59282-2.

WANG, Xuan; LU, Yonglong; CHEN, Chunci; YI, Xiaojie; CUI, Haotian. Total-factor energy efficiency of ten major global energy-consuming countries. **Journal of Environmental Sciences**, v. 137, p. 41–52, 2024d. DOI: 10.1016/j.jes.2023.02.031.

WILSON, Paul W. Detecting influential observations in data envelopment analysis. **Journal of Productivity Analysis**, v. 6, n. 1, p. 27–45, 1995. DOI: 10.1007/BF01073493.

WOJCIK, Victoria; DYCKHOFF, Harald; CLERMONT, Marcel. Is Data Envelopment Analysis a Suitable Tool for Performance Measurement and Benchmarking in Non-Production Contexts? **Business Research**, v. 12, p. 559–595, 2019. DOI: 10.1007/s40685-018-0077-z.

WOMACK, James P.; JONES, Daniel T.; ROOS, Daniel. **The Machine That Changed the World: The Story of Lean Production—Toyota's Secret Weapon in the Global Car Wars That Is Now Revolutionizing World Industry**. Revised. New York: Free Press, 2007. 352 p. ISBN 9780743299794.

WONG, Y. H. B.; BEASLEY, J. E. Restricting Weight Flexibility in Data Envelopment Analysis. **Journal of the Operational Research Society**, v. 41, n. 9, p. 829–835, 1990. DOI: 10.1057/jors.1990.120.

XIA, Bing; DONG, Suocheng; LI, Zehong; ZHAO, Minyan; SUN, Dongqi; ZHANG, Wenbiao; LI, Yu. Eco-efficiency and its drivers in tourism sectors with respect to carbon emissions from the supply chain: An integrated EEIO and DEA approach. **International Journal of Environmental Research and Public Health**, v. 19, n. 11, p. 6951, 2022. DOI: 10.3390/ijerph19116951.

XUE, Yaozu. Evaluation analysis on industrial green total factor productivity and energy transition policy in resource-based region. **Energy & Environment**, v. 33, n. 3, p. 419–434, 2022. DOI: 10.1177/0958305X211005428.

YANG, Li; CHEN, Shiyang; CHIU, Yung-ho; CHANG, Tzu-Han; WANG, Yue. Reassessment of industrial eco-efficiency in China under the sustainable development goals: A meta two-stage parallel entropy dynamic DDF-DEA model. **Journal of Cleaner Production**, v. 447, p. 141275, 2024. DOI: 10.1016/j.jclepro.2024.141275.

YANG, Yiqu; SUBHANI, Ghulam; SAKINA; ZHOU, Yaying. Natural Resource and Energy Efficiency in BRICS Countries: Can Green Innovation Capabilities Really Change the Game? **Gondwana Research**, v. 145, p. 228–239, 2025. DOI: 10.1016/j.gr.2024.03.014.

YUAN, Chunhui; YANG, Haitao. Research on K-value selection method of K-means clustering algorithm. **J**, v. 2, n. 2, p. 226–235, 2019. DOI: 10.3390/j2020016.

ZANELLA, Andreia; CAMANHO, Ana S.; DIAS, Teresa G. Undesirable Outputs and Weighting Schemes in Composite Indicators Based on Data Envelopment Analysis. **European Journal of Operational Research**, v. 245, n. 2, p. 517–530, 2015. DOI: 10.1016/j.ejor.2015.03.036.

ZHANG, Hongjun; ZHANG, Youliang; ZHANG, Rui. Dimension-Specific Efficiency Measurement Using Data Envelopment Analysis. **Mathematical Problems in Engineering**, v. 2014, 247248, p. 1–9, 2014. DOI: 10.1155/2014/247248.

ZHANG, Yuhan; YANG, Yirui; YE, Wei; CHEN, Mo; GU, Xinchun; LI, Xue; JIANG, Pan; LIU, Liang. Assessing and gauging the carbon emission efficiency in China in accordance with the sustainable development goals. **Scientific Reports**, v. 14, n. 1, p. 25993, 2024. DOI: 10.1038/s41598-024-75903-2.

ZIARI, Shokrollah; RAISSI, Sadigh. Ranking Efficient DMUs Using Minimizing Distance in DEA. **Journal of Industrial Engineering International**, v. 12, p. 237–242, 2016. DOI: 10.1007/s40092-016-0141-2.

APÊNDICE A**Outras nomenclaturas e simbologias**

Outras nomenclaturas e simbologias

Categoria	Símbolo usado	Alternativas na literatura	Significado	Modelo Formulação Orientação Fonte acadêmica						
				CCR	BCC	Multiplicadores	Envelope	Input	Output	
Modelo	<i>CCR</i>	<i>CRS</i>	Designação alternativa, no contexto de DEA, para o modelo/tecnologia clássica de Charnes, Cooper e Rhodes sob retornos constantes de escala.	✓		✓	✓	✓	✓	Charnes <i>et al.</i> (1978); Podinovski e Bouzdine-Chameeva (2021)
Modelo	<i>BCC</i>	<i>VRS</i>	Designação alternativa, no contexto de DEA, para o modelo/tecnologia de Banker, Charnes e Cooper sob retornos variáveis de escala.		✓	✓	✓	✓	✓	Banker <i>et al.</i> (1984); Podinovski e Bouzdine-Chameeva (2021)
Índice da DMU avaliada	<i>o</i>	$0, k, p$	Identifica a unidade cuja eficiência está sendo calculada. O caractere pode variar sem alterar o papel matemático do índice.	✓	✓	✓	✓	✓	✓	Ziari e Raissi (2016); Ben Mabrouk <i>et al.</i> (2022); Zhang <i>et al.</i> (2014)
Índice das DMUs	<i>k</i>	<i>j</i>	Identifica cada DMU observada ou cada unidade candidata a compor a referência.	✓	✓	✓	✓	✓	✓	Ziari e Raissi (2016); Wojcik <i>et al.</i> (2019)

Continua na página seguinte.

Tabela A.1 – continuação

Categoria	Símbolo usado	Alternativas na literatura	Significado	Modelo						Formulação	Orientação	Fonte acadêmica
				CCR	BCC	Multiplicadores	Envelope	Input	Output			
Índice de <i>output</i>	j	r	Identifica cada tipo de <i>output</i> . Adotado, $j = 1, \dots, s$; mas é comum empregar $r = 1, \dots, s$. Portanto, j e r são alternativas funcionais quando usados exclusivamente como índices dos resultados.	✓	✓	✓	✓	✓	✓			Ziari e Raissi (2016); Zhang <i>et al.</i> (2014)
Número de <i>inputs</i>	r	m	Representa a quantidade total de <i>inputs</i> considerados por cada DMU. O índice de <i>input</i> percorre $i = 1, \dots, r$; nos artigos auditados, a forma mais comum é $i = 1, \dots, m$.	✓	✓	✓	✓	✓	✓			Ziari e Raissi (2016); Zhang <i>et al.</i> (2014)
Intensidade	h_k	λ_j ; vetor λ	Coefficiente que combina as DMUs observadas para formar a referência virtual. λ é a alternativa mais recorrente nos artigos auditados.	✓	✓		✓	✓	✓			Ziari e Raissi (2016); Wojcik <i>et al.</i> (2019); Trnovská <i>et al.</i> (2025)

Continua na página seguinte.

Tabela A.1 – continuação

Categoria	Símbolo usado	Alternativas na literatura	Significado	Modelo						Formulação	Orientação	Fonte acadêmica
				CCR	BCC	Multiplicadores	Envelope	Input	Output			
Fator radial de <i>input</i>	h_o	$\theta; \theta_o$	Fator de contração dos <i>inputs</i> no envelope orientado aos <i>inputs</i> .	✓	✓		✓	✓				Ziari e Raissi (2016); Wojcik <i>et al.</i> (2019)
Fator radial de <i>output</i>	h_o	$\phi; \eta_o; \varphi; \gamma$	Fator de expansão dos <i>outputs</i> .	✓	✓		✓		✓			Ziari e Raissi (2016); Wojcik <i>et al.</i> (2019); Ben Mabrouk <i>et al.</i> (2022); Trnovská <i>et al.</i> (2025)
Folga de <i>input</i>	s_i^{-*}	$s_i^-; IS_i$	Excesso não radial do <i>input</i> ; o asterisco acrescentado no capítulo indica o valor ótimo.	✓	✓		✓	✓	✓			Ziari e Raissi (2016); Ben Mabrouk <i>et al.</i> (2022)
Folga de <i>output</i>	s_j^{+*}	$s_r^+; OS_r$	Insuficiência não radial do <i>output</i> ; o asterisco acrescentado no capítulo indica o valor ótimo.	✓	✓		✓	✓	✓			Ziari e Raissi (2016); Ben Mabrouk <i>et al.</i> (2022)
Valor ótimo / escore calculado	E_o^*	$z_p; \theta_o^*; \varphi_1^*$	Valor da função objetivo na solução ótima. Em Zhang <i>et al.</i> (2014), z_p é o escore CCR calculado após a resolução do modelo.	✓	✓	✓	✓	✓	✓			Zhang <i>et al.</i> (2014); Podinovski e Bouzdine-Chameeva (2021)

Continua na página seguinte.

Tabela A.1 – continuação

Categoria	Símbolo usado	Alternativas na literatura	Significado	Modelo Formulação Orientação Fonte acadêmica					
				CCR	BCC	Multiplicadores	Envelope	Input	Output
Eficiência recíproca de <i>output</i>	$\theta_o^* = \frac{1}{E_o^*}$	$\frac{1}{\phi^*}; \frac{1}{\eta_o^*}; \frac{1}{\gamma^*}$	Escore limitado a uma unidade obtido como recíproco do fator direto de expansão dos <i>outputs</i> .	✓	✓	✓	✓		✓
Eficiência de escala – notação geral	EE	SE	Medida que compara o desempenho sob a tecnologia CRS/CCR com a eficiência técnica pura sob VRS/BCC.	✓	✓	✓	✓	✓	✓
Projeção radial de <i>input</i>	x_{io}^{rad}	$\theta_o^* x_{io}$	Valor do <i>input</i> i após somente a contração radial comum a todos os recursos, antes da incorporação de eventual folga.	✓	✓		✓	✓	
Projeção completa de <i>input</i>	x_{io}^{proj}	$\hat{x}_{io}; \phi_o^x(\theta)$	Valor-alvo do <i>input</i> i sobre a fronteira, incorporando o ajuste radial e, quando aplicável, a folga de <i>input</i> .	✓	✓		✓	✓	✓

Continua na página seguinte.

Tabela A.1 – continuação

Categoria	Símbolo usado	Alternativas na literatura	Significado	Modelo Formulação Orientação Fonte acadêmica					
				CCR	BCC	Multiplicadores	Envelope	Input	Output
Projeção completa de <i>output</i>	y_{jo}^{proj}	$\hat{y}_{jo}; \phi_o^y(\theta)$	Valor-alvo do <i>output</i> j sobre a fronteira, incorporando a expansão radial e, quando aplicável, a folga de <i>output</i> .	✓	✓		✓	✓	✓
Lagrangiana – <i>input</i>	$\mathcal{L}_I$	L_o	Função Lagrangiana empregada na derivação da formulação orientada aos <i>inputs</i> .		✓	✓	✓	✓	
Lagrangiana – <i>output</i>	$\mathcal{L}_O$	L_o	Função Lagrangiana empregada na derivação da formulação orientada aos <i>outputs</i> .		✓	✓	✓		✓

Fonte: Elaboração Própria.